Planejamento e Otimização de Experimentos

Análise da Variância

Planejamento e Otimização de Experimentos (DoE)

Análise da Variância

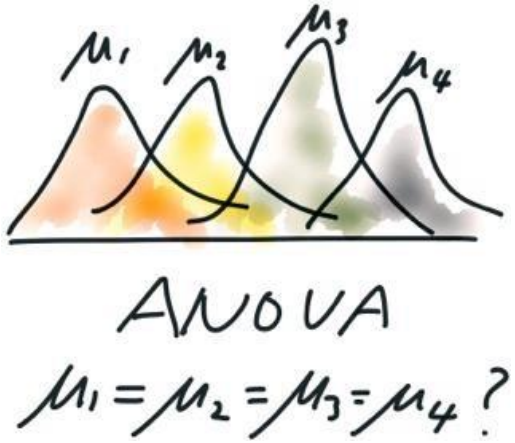

Exemplo

- *Circuitos Integrados*
  - Wafers (fatia fina de um material semicondutor)
  - O processo de gravação por plasma é empregado para remover material indesejado
  - A energia é fornecida por um gerador de radiofrequência (RF) fazendo com que o plasma seja gerado no espaço entre os eletrodos
  - Potência do RF × taxa de gravação
    - C_2F_6 e 0,80 cm (gap)
    - Potência da RF: 160, 180, 200, 220 W (quatro níveis)
    - Quatro wafers para cada nível da RF

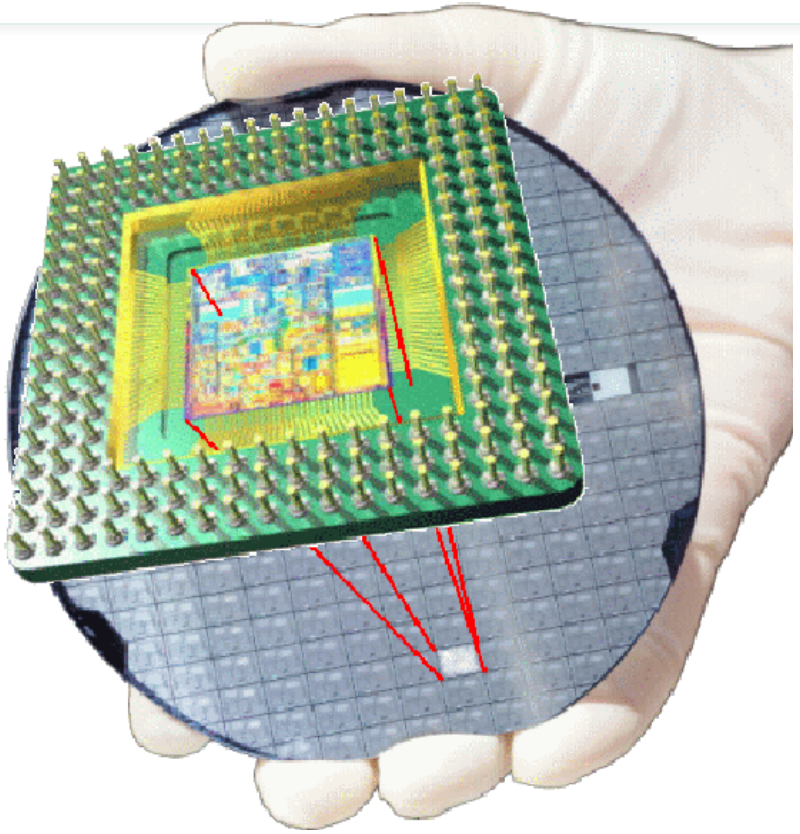

D.C. Montgmery *Design and Analysis of Experiments*, 8th. Ed., John Wiley Sons: New York, 2012, p 66.

- Experimento de Fator Único
  - $a = 4$ níveis do fator
  - $n = 5$ replicatas
  - 20 ensaios
    - Ordem aleatória
      - Como gerar a ordem dos ensaios?
        - » Ex: números aleatórios usando uma função aleatória em uma planilha; classificar por esse número
      - Prevenir os efeitos de variáveis incômodas desconhecidas
        - » Ordem não randomizada (5x160; 5x180 ...)
          - Ex: a ferramenta de gravação exibe um efeito de aquecimento: quanto mais tempo estiver ligada, menores serão as leituras de classificação de gravação observadas
          - Isso **destruirá** a validade do experimento

```
power<-factor(rep(c(160, 180, 200, 220),5))
set.seed(826)
run<-sample(power,20)
crd<-data.frame(Power=run);crd
Power
1     180
2     180
3     220
4     160
5     220
6     160
7     160
8     160
9     160
10    200
11    180
12    220
13    200
14    180
15    220
16    200
17    180
18    200
19    200
20    220
```

Para randomizar a ordem das corridas, a função sample pode ser usada para criar uma ordem aleatória dos números dos ensaios de 1 a 20.

Finalmente, o **data frame crd** é gerado.
Um quadro de dados é usado para armazenar tabelas de dados

Power (W)	1	2	3	4	5	Soma	Média
160	575	542	530	539	570	2756	551,2
180	565	593	590	579	610	2937	587,4
200	600	651	610	637	629	3127	625,4
220	725	700	715	685	710	3535	707,0

```
P160    <- c(575,542,530,539,570)
P180    <- c(565,593,590,579,610)
P200    <- c(600,651,610,637,629)
P220    <- c(725,700,715,685,710)
RF.df <- data.frame("160"=P160, "180"=P180, "200"=P200,
                    "220"=P220, check.names = F)
RF.df
  160 180 200 220
1 575 565 600 725
2 542 593 651 700
3 530 590 610 715
4 539 579 637 685
5 570 610 629 710
```

boxplot

Quartis são os valores que dividem uma lista de números em quartos

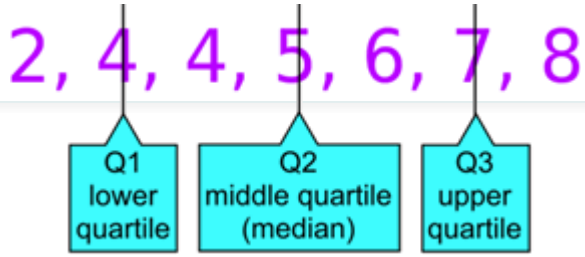

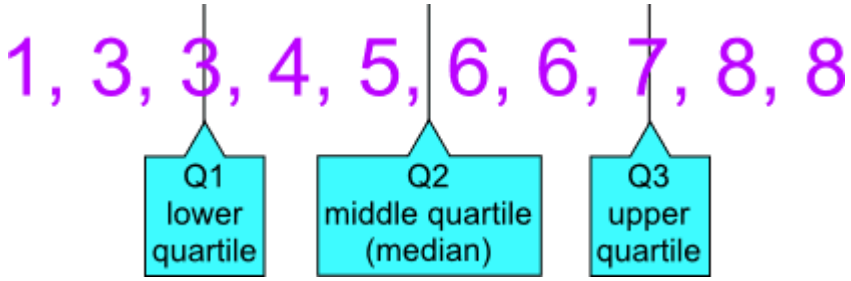

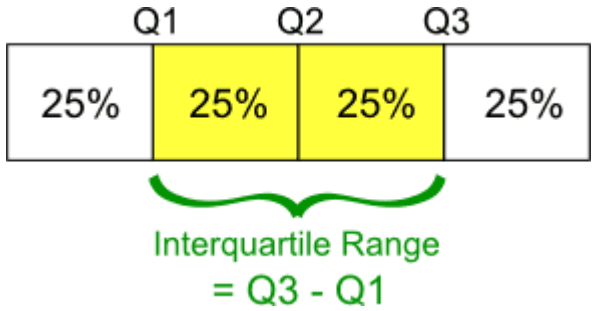

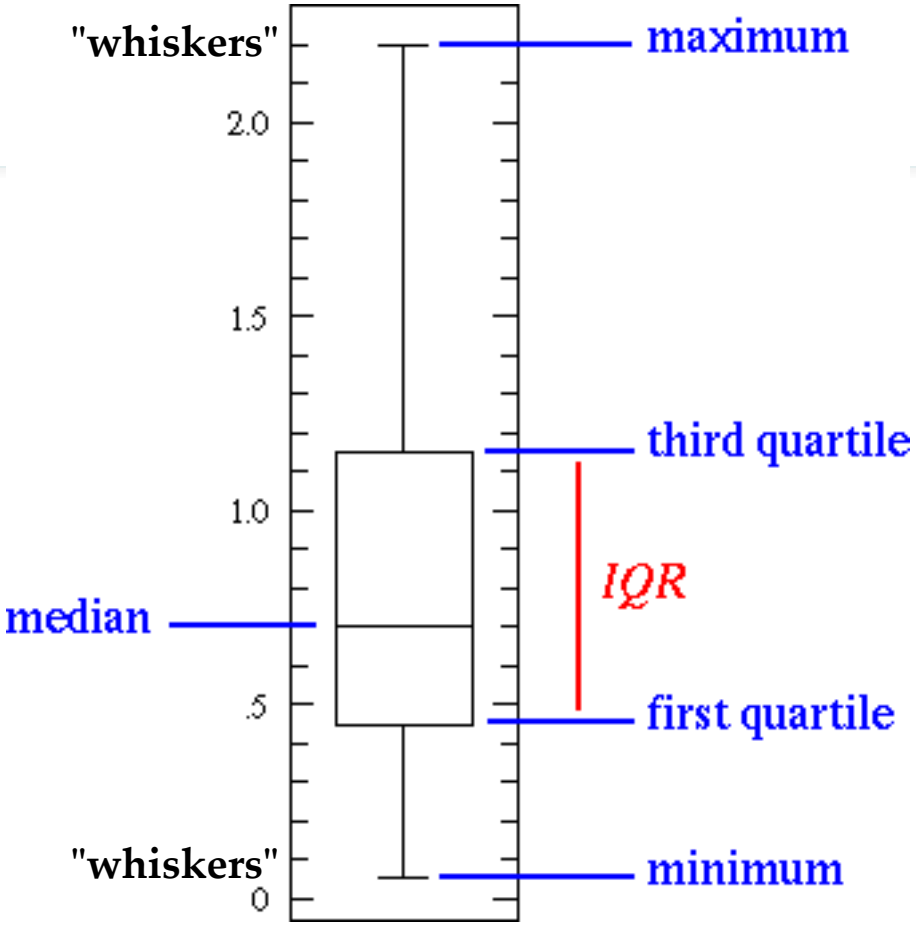

http://www.physics.csbsju.edu/stats/box2.html

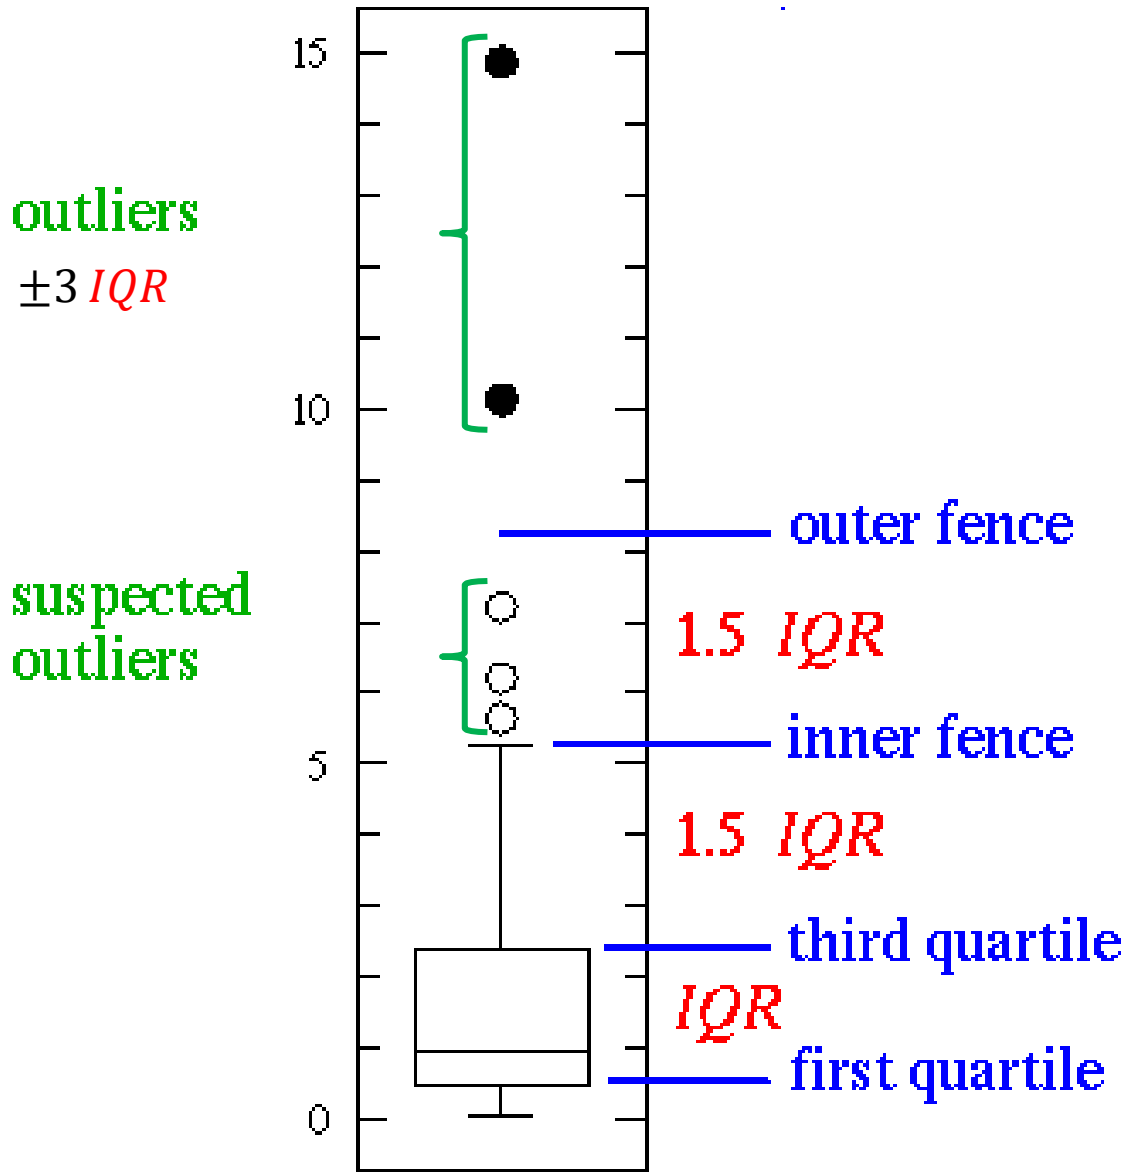
15
10
5
0
outliers
±3 IQR
suspected
outliers
outer fence
1.5 IQR
inner fence
1.5 IQR
third quartile
IQR
first quartile

```
par(font.axis = 2, font.lab=2, lwd=2)
boxplot(RF.df, col=(c("aliceblue","lightcyan1","lightgoldenrod1",
"peachpuff")),main="Plasma etching process",
          xlab="RF Power Setting (W)",ylab="Etch Rate (A/min)")
```

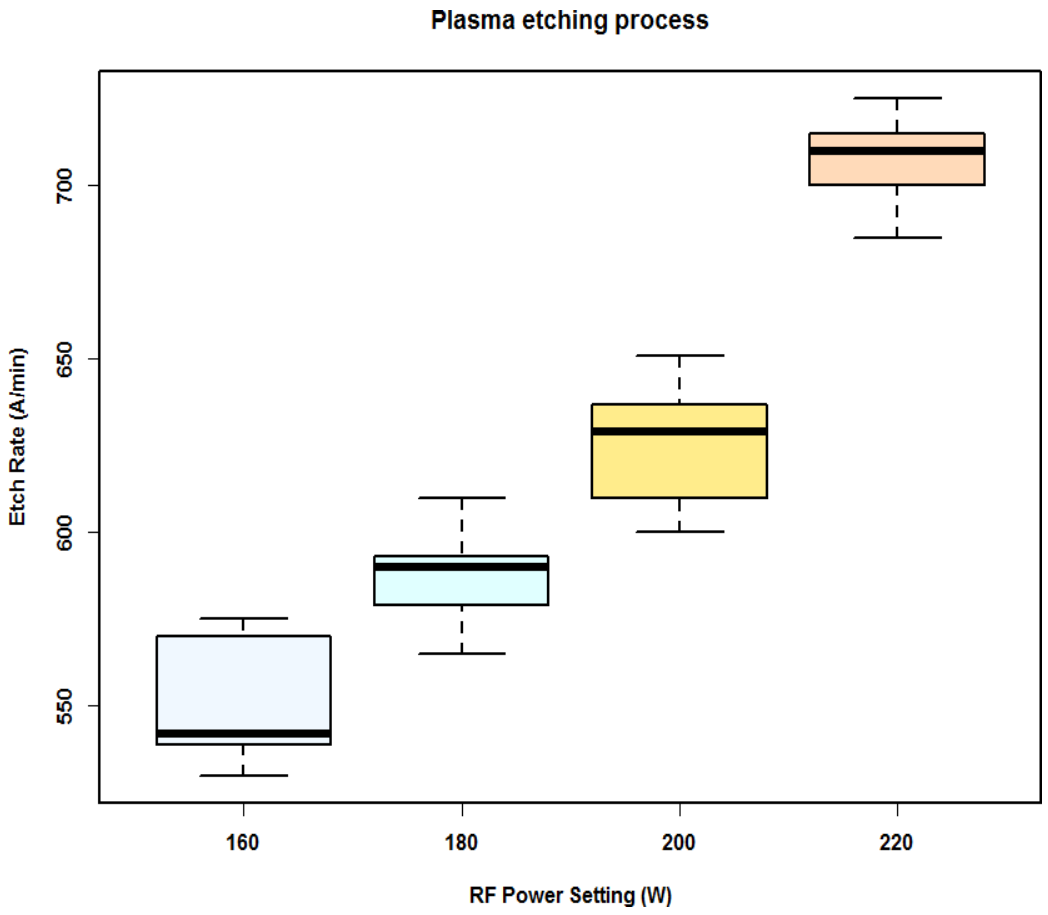

- A taxa de gravação aumenta à medida que a potência da RF aumenta.

-Não há evidências fortes para sugerir que a variabilidade em cada taxa em torno da média depende da potência da RF.

-Suponha que desejamos testar as diferenças entre as taxas médias de ataque:

a)teste t para todos os seis pares de médias possíveis.

- É preciso muito esforço
- Ele infla o erro tipo I (rejeitando a hipótese *nula* quando é de fato verdadeira)

b) Análise da variância

Análise da Variância (ANOVA)

a *tratamentos* ou *níveis* diferentes de um *único fator*

Tratamento (Nível)	Observações				Soma	Média
1	y_{11}	y_{12}	...	y_{1n}	$y_{1.}$	$y_{1.}$
2	y_{21}	y_{22}	...	y_{2n}	$y_{2.}$	$y_{2.}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	$\vdots$	$\vdots$
a	y_{a1}	y_{a2}	...	y_{an}	$y_{a.}$	$y_{a.}$
					$y_{..}$	$y_{..}$

- Modelagem Estatística
  - Modelo da Média

$$y_{ij} = \mu_i + \epsilon_{ij} \begin{cases} i = 1,2,\dots,a \\ j = 1,2,\dots,n \end{cases}$$

y_{ij} é a *ij*-ésima observação

μ_i é a média do *i´-ésimo* nível do fator ou tratamento

ϵ_{ij} é o *erro aleatório*

É conveniente pensar nos erros como tendo média zero, de modo que $E\left(y_{ij}\right) = \mu_i$

  - Modelo dos Efeitos

$$\mu_i = \mu + r_i, \quad i = 1,2,\dots,a$$

Análise da Variância de Fator Único

$$y_{ij} = \mu + r_i + \epsilon_{ij} \quad j = 1,2,\dots,n$$

μ é a *média global*

r_i é o *i-ésimo* efeito do tratamento

- O planejamento experimental é inteiramente aleatorizado
  - Os experimentos devem ser realizados em ordem aleatória
  - O ambiente em que os tratamentos são aplicados é o mais uniforme possível (*unidades experimentais*)
  - Teste de Hipóteses
    - $y_{ij} \sim N(\mu + r_i, \sigma^2)$
    - As observações mutuamente independentes

Análise do Modelo de Efeitos Fixos

a *tratamentos*

Teste as hipóteses sobre as médias de tratamento, e as conclusões se aplicarão apenas aos níveis de fatores considerados na análise

$$y_{i.} = \sum_{j=1}^{n} y_{ij} \qquad \bar{y}_{i.} = \frac{y_{i.}}{n} \qquad i = 1,2,\ldots,a$$

$$y_{..} = \sum_{i=1}^{a}\sum_{j=1}^{n} y_{ij} \qquad \bar{y}_{..} = \frac{y_{..}}{N} \qquad N = an$$

Número total de observações

– Testando a igualdade das médias dos tratamentos

$$E\ (y_{ij}) = \mu + r_i = \mu_i, \quad i = 1,2,\ldots,a$$

$$H_0\colon \mu_1 = \mu_2 = \cdots = \mu_a$$

$H_1\colon \mu_i \neq \mu_j$ para no mínimo um par (i,j)

$$\mu = \frac{\sum_{i=1}^{a} \mu_i}{a} \Longrightarrow \sum_{i=1}^{a} \tau_i = 0$$

os efeitos do tratamento ou fator podem ser considerados como desvios da média geral

$$H_0\colon \tau_1 = \tau_2 = \cdots = \tau_a = 0$$

$H_1\colon \tau_i \neq 0$ para no mínimo i

– Assim, falamos de testar a igualdade das médias dos tratamentos ou testar que os efeitos do tratamento (τ_i) são nulos

- **Decomposição da Soma Quadrática Total**
- O termo ***Análise da Variância*** é derivado de uma partição da variabilidade total em suas partes componentes

$$SS_T = \sum_{i=1}^{a}\sum_{j=1}^{n}\left(y_{ij} - \bar{y}_{..}\right)^2$$

$$= n\sum_{i=1}^{a}(\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^{a}\sum_{j=1}^{n}\left(y_{ij} - \bar{y}_{i.}\right)^2$$

soma dos quadrados das diferenças entre as médias de tratamento e a média global

soma dos quadrados das diferenças de observações dentro dos tratamentos em relação à média do tratamento

$$SS_T = SS_{Treatments} + SS_E$$

– Graus de liberdade

$SS_T: N - 1$

$SS_{Treatments}: a - 1$

$SS_E: a(n-1) = an - a = N - a$

– Média quadrática

$$MS_{Treatments} = \frac{SS_{Treatments}}{a-1}$$

$$MS_E = \frac{SS_E}{N-a}$$

– Valor esperado

$E(MS_E) = \sigma^2$

$$E(MS_{Treatments}) = \sigma^2 + \frac{n\sum_{i=1}^{a} r_i^2}{a-1}$$

Se não houver diferenças entre as médias dos tratamento ($\tau_i = 0$), MSTreatments também estima σ^2

- **Análise Estatística**

  Se a hipótese nula de nenhuma diferença nas médias de tratamento for verdadeira, a razão

$$F_0 = \frac{SS_{Treatments}/(a-1)}{SS_E/(N-a)} = \frac{MS_{Treatments}}{MS_E}$$

  É distribuída como F com $a-1$ e $N-a$ graus de liberdade.

Rejeita-se H_0 se $F_0 > F_{\alpha,a-1,N-a}$

ANOVA Tabela

Fonte de variação	Soma Quadrática	Graus de Liberdade	Média Quadrática	F_0
Entre os tratamentos	$SS_{Treatments} = \frac{1}{n}\sum_{i=1}^{a} y_{i.}^2 - \frac{y_{..}^2}{N}$	$a-1$	$MS_{Treatments}$	$F_0 = \frac{MS_{Treatments}}{MS_E}$
Erro (dentro dos tratamentos)	$SS_E = SS_T - SS_{Treatments}$	$N-a$	MS_E	
Total	$SS_T = \sum_{i=1}^{a}\sum_{j=1}^{n}\left(y_{ij} - y_{..}\right)^2$	$N-1$		

Potência (W)	1	2	3	4	5	Soma $y_{i.}$	Média $y_{i.}$
160	575	542	530	539	570	2756	551,2
180	565	593	590	579	610	2937	587,4
200	600	651	610	637	629	3127	625,4
220	725	700	715	685	710	3535	707,0

$y_{..}$ =**12355** $y_{..}$ = **617,75**

$$\boldsymbol{SS_T} = \sum_{i=1}^{a}\sum_{j=1}^{n}(y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^{4}\sum_{j=1}^{5} y_{ij}^2 - \frac{y_{..}^2}{N}$$

$$= 575^2 + 542^2 + \cdots + 710^2 - \frac{12{,}355^2}{20} = \mathbf{72{,}209.75}$$

$$\boldsymbol{SS_{Treatments}} = \frac{1}{n}\sum_{i=1}^{4} y_{i.}^2 - \frac{y_{..}^2}{N}$$

$$= \frac{1}{5}[2756^2 + \cdots + 3535^2] - \frac{12{,}355^2}{20} = \mathbf{66{,}870.55}$$

$$\boldsymbol{SS_E} = SS_T - SS_{Treatments} = \mathbf{5339.20}$$

ANOVA Tabela

Fonte de variação	Soma Quadrática	Graus de liberdade	Média Quadrática	F_0	*p-Value*
RF Potência	66,870.55	3	22,290.18	66.80	<0.01
Erro	5339.20	16	333,70		
Total	72,209.75	19			

RF Potência (entre-média quadrática dos tratamentos) ≫ Erro (dentro-tratamentos)

- é improvável que as médias de tratamento sejam iguais

$F_{0,05,3,16} = 3,24$ (*F* tabela)

- Como $F_0 = 66,80 > 3,24$, rejeitamos H_0 e concluímos que as médias de tratamento diferem

- *A potência da RF afeta significativamente a taxa média de gravação*

```
r = c(t(as.matrix(RF.df))); r
 [1] 575 565 600 725 542 593 651 700 530 590 610 715
[13] 539 579 637 685 570 610 629 710
f = c("160","180","200","220"); f
[1] "160" "180" "200" "220"
k = 4      #factors
n = 5      #replicates
tm = gl(k, 1, n*k, factor(f)); tm
 [1] 160 180 200 220 160 180 200 220 160 180 200 220
[13] 160 180 200 220 160 180 200 220
Levels: 160 180 200 220
av = aov(r~tm)
summary(av)
            Df Sum Sq Mean Sq F value   Pr(>F)
tm           3  66871   22290    66.8 2.88e-09
Residuals   16   5339     334

tm          ***
Residuals
---
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

- **Estimação dos Parâmetros do Modelo**

$$y_{ij} = \mu + \tau_i + \epsilon_{ij}$$
$$\hat{\mu} = \bar{y}_{..}$$
$$\hat{\tau} = \bar{y}_{i.} - \bar{y}_{..}$$
$$\hat{y}_{ij} = \bar{y}_{i.}$$

Um intervalo de confiança de $100(1-a)$ por cento na i-ésima média de tratamento μ_i:

$$y_{i.} - t_{\alpha/2,N-a}\sqrt{\frac{MS_E}{n}} \leq \mu_i \leq y_{i.} + t_{\alpha/2,N-a}\sqrt{\frac{MS_E}{n}}$$

Um intervalo de confiança de $100\ (1-a)$ por cento na diferença em quaisquer duas médias de tratamento :

$$\bar{y}_{i.} - \bar{y}_{j.} - t_{\alpha/2,N-a}\sqrt{\frac{2MS_E}{n}} \leq \mu_i - \mu_j \leq \bar{y}_{i.} - \bar{y}_{j.} + t_{\alpha/2,N-a}\sqrt{\frac{2MS_E}{n}}$$

Verificação da adequação do modelo

A suposição de normalidade

Gráfico de probabilidade normal dos resíduos

```
> av.stdres = rstandard(av)
> qqnorm(av.stdres,
        ylab="Standardized Residuals",
        xlab="Normal Scores",
        main="Normal Probability Plot",
        col="blue")
> qqline(av.stdres, col="red")
```

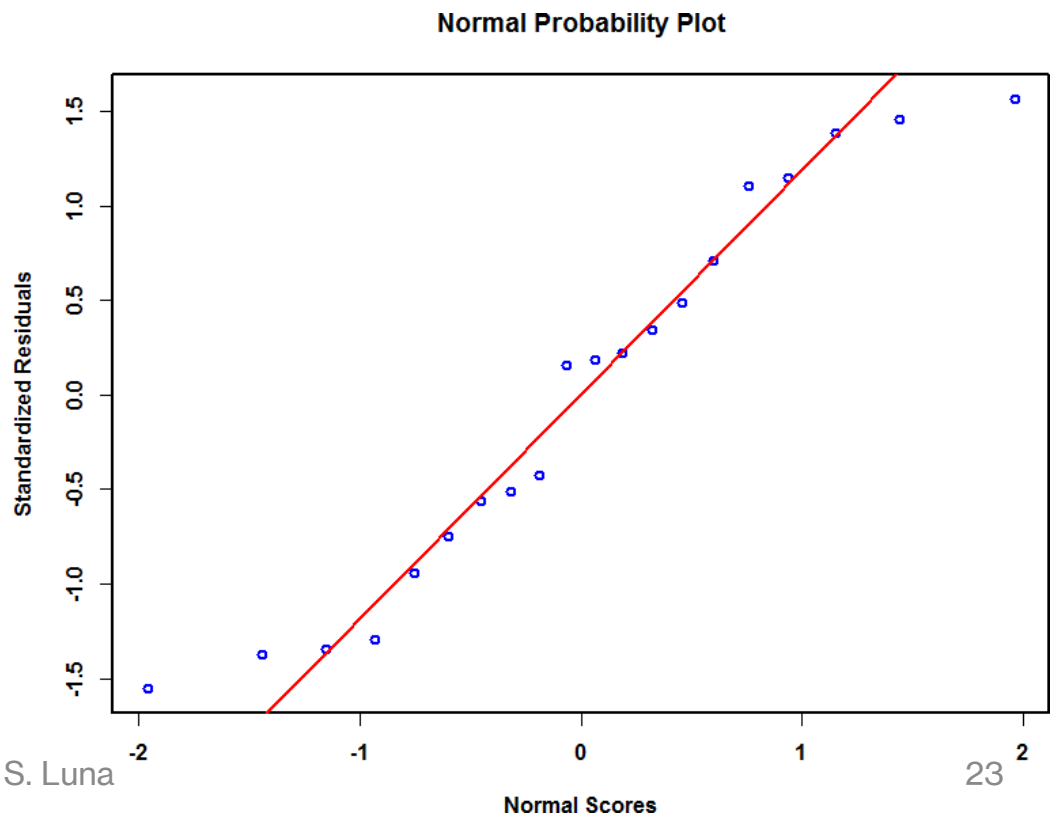

- *Resíduos padronizados*

Outliers ou valores atípicos

$$d_{ij} = \frac{e_{ij}}{s_i} \text{ ou } \frac{e_{ij}}{\sqrt{MS_E}}$$

Se os erros são $N(0, \sigma^2)$ os resíduos padronizados devem ser aproximamente normal com média zero e variância unitária

~68% de d_{ij} devem estar dentro dos limites ±1

~95% ... ±2

~100% ... ±3

Usando o maior resíduo padronizado:

```
> av$residuals
    1     2     3     4     5     6     7     8     9    10
 23.8 -22.4 -25.4  18.0  -9.2   5.6  25.6  -7.0 -21.2   2.6
   11    12    13    14    15    16    17    18    19    20
-15.4   8.0 -12.2  -8.4  11.6 -22.0  18.8  22.6   3.6   3.0
> av.stdres
         1          2          3          4          5
 1.4566455 -1.3709604 -1.5545712  1.1016646 -0.5630730
         6          7          8          9         10
 0.3427401  1.5668119 -0.4284251 -1.2975161  0.1591293
        11         12         13         14         15
-0.9425353  0.4896287 -0.7466838 -0.5141102  0.7099617
        16         17         18         19         20
-1.3464790  1.1506275  1.3832012  0.2203329  0.1836108
```

$d = 1.55$ não deve causar preocupação

- **Gráfico de Resíduos na Sequência de Tempo**
  - Colocar os resíduos em ordem de tempo de coleta de dados é útil para detectar uma forte correlação entre os resíduos
  - Uma tendência a ter execuções de resíduos positivos e negativos indica correlação positiva:
  - A suposição de independência dos erros teria sido violada

```
plot(av$residuals,xlab="Run",ylab="Residuals", cex=2)
```

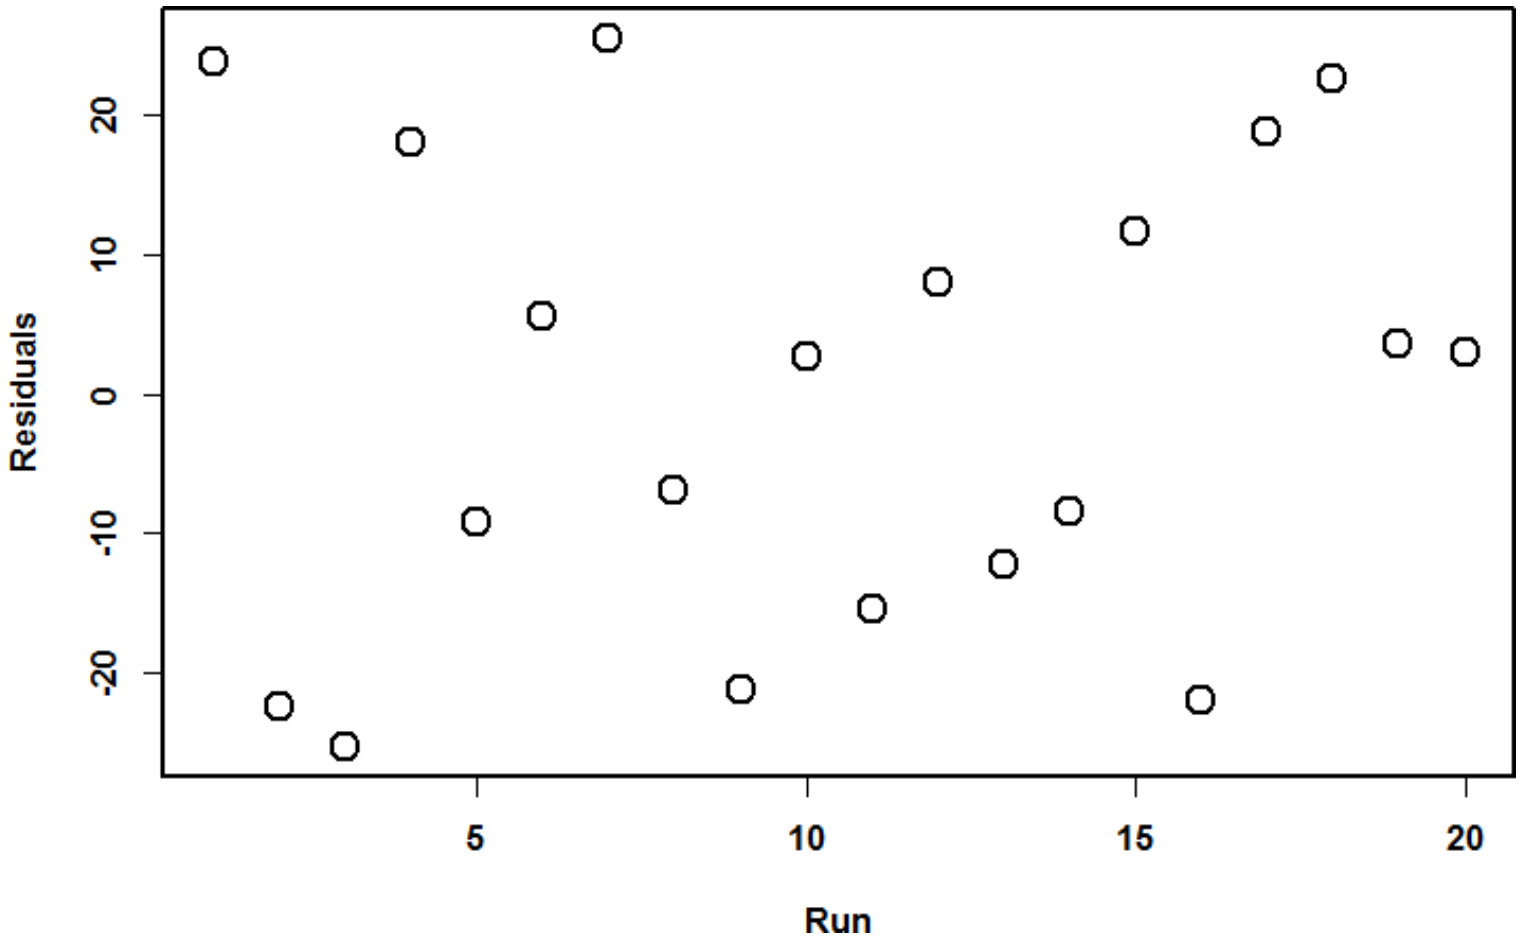

- **Gráfico de Resíduos Versus Valores Preditos**

  Se o modelo estiver correto e as premissas forem satisfeitas, os resíduos não devem ser estruturados; em particular, eles não devem estar relacionados a qualquer outra variável, incluindo a *resposta prevista*

  – Experiência de gravação por plasma

$$\hat{y}_{ij} = \bar{y}_{i.}$$
$$e_{ij} = \bar{y}_{i.} - \hat{y}_{ij}$$

```
plot(av$fitted.values,av$residuals,
xlab="Fitted values",ylab="Residuals", cex=2)
```

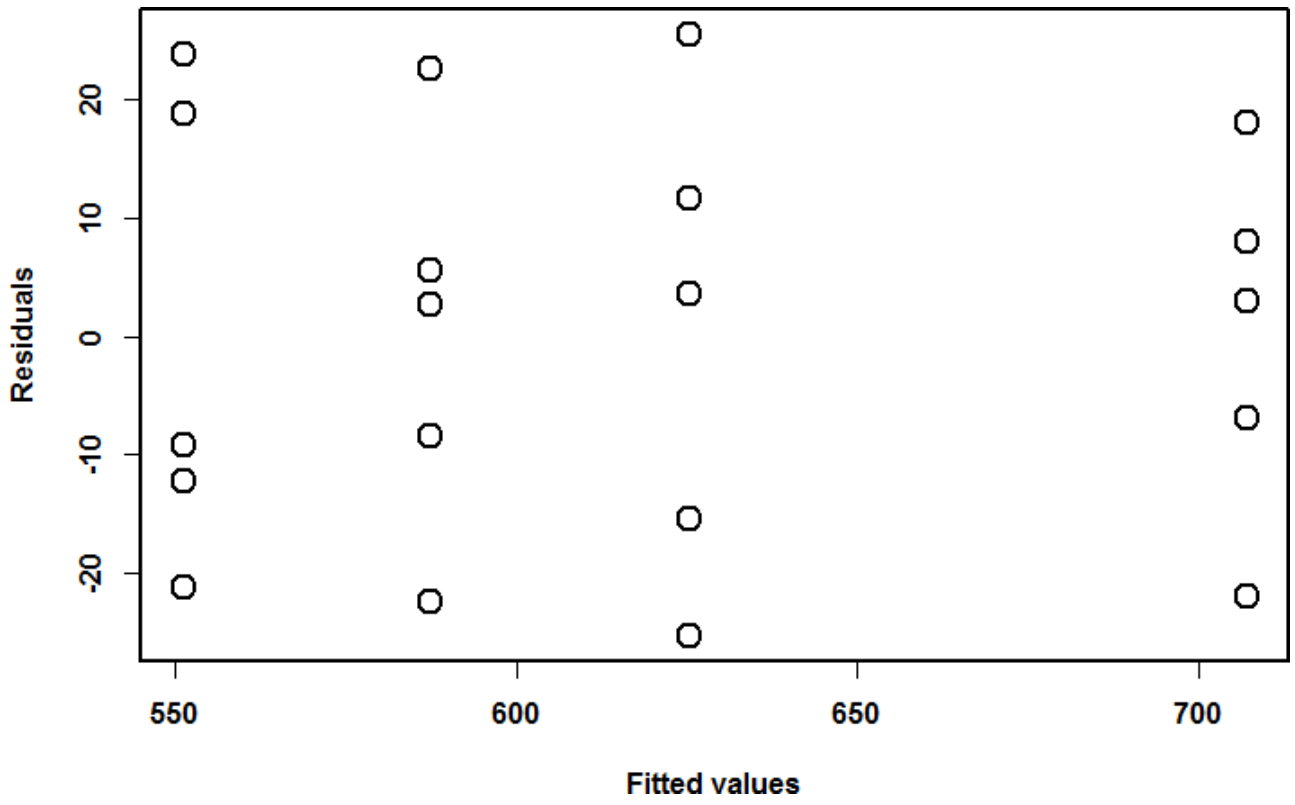

Não há *desigualdade de variância*: a variância das observações não aumenta à medida que a grandeza da observação aumenta

Ou

…

```
plot(av)
Hit <Return> to see next plot:
```

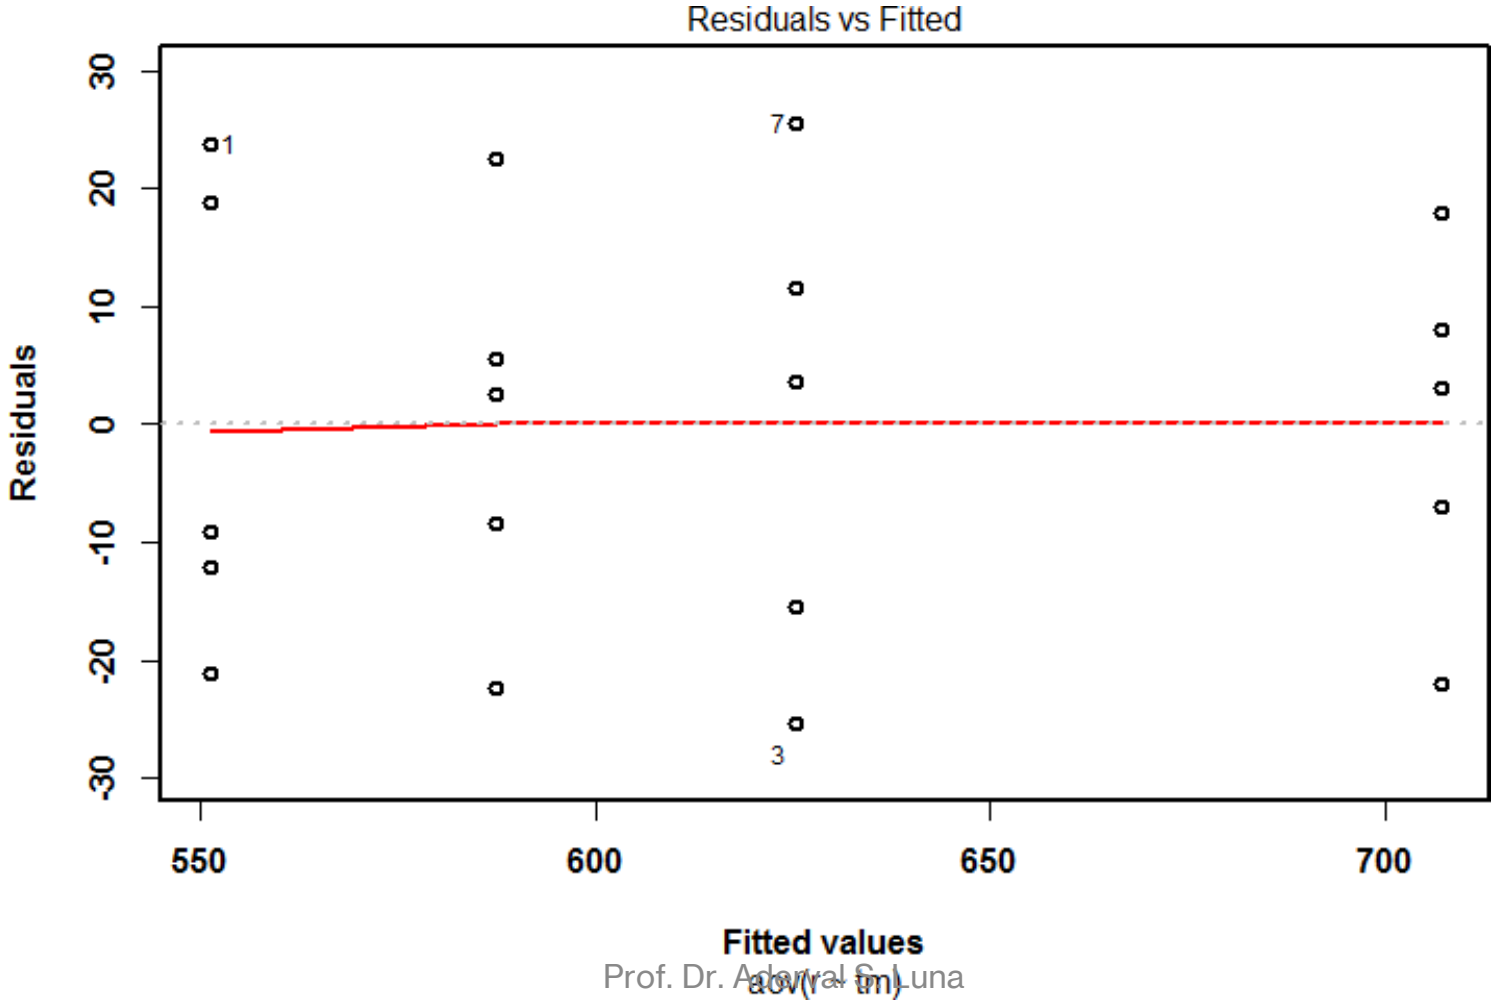

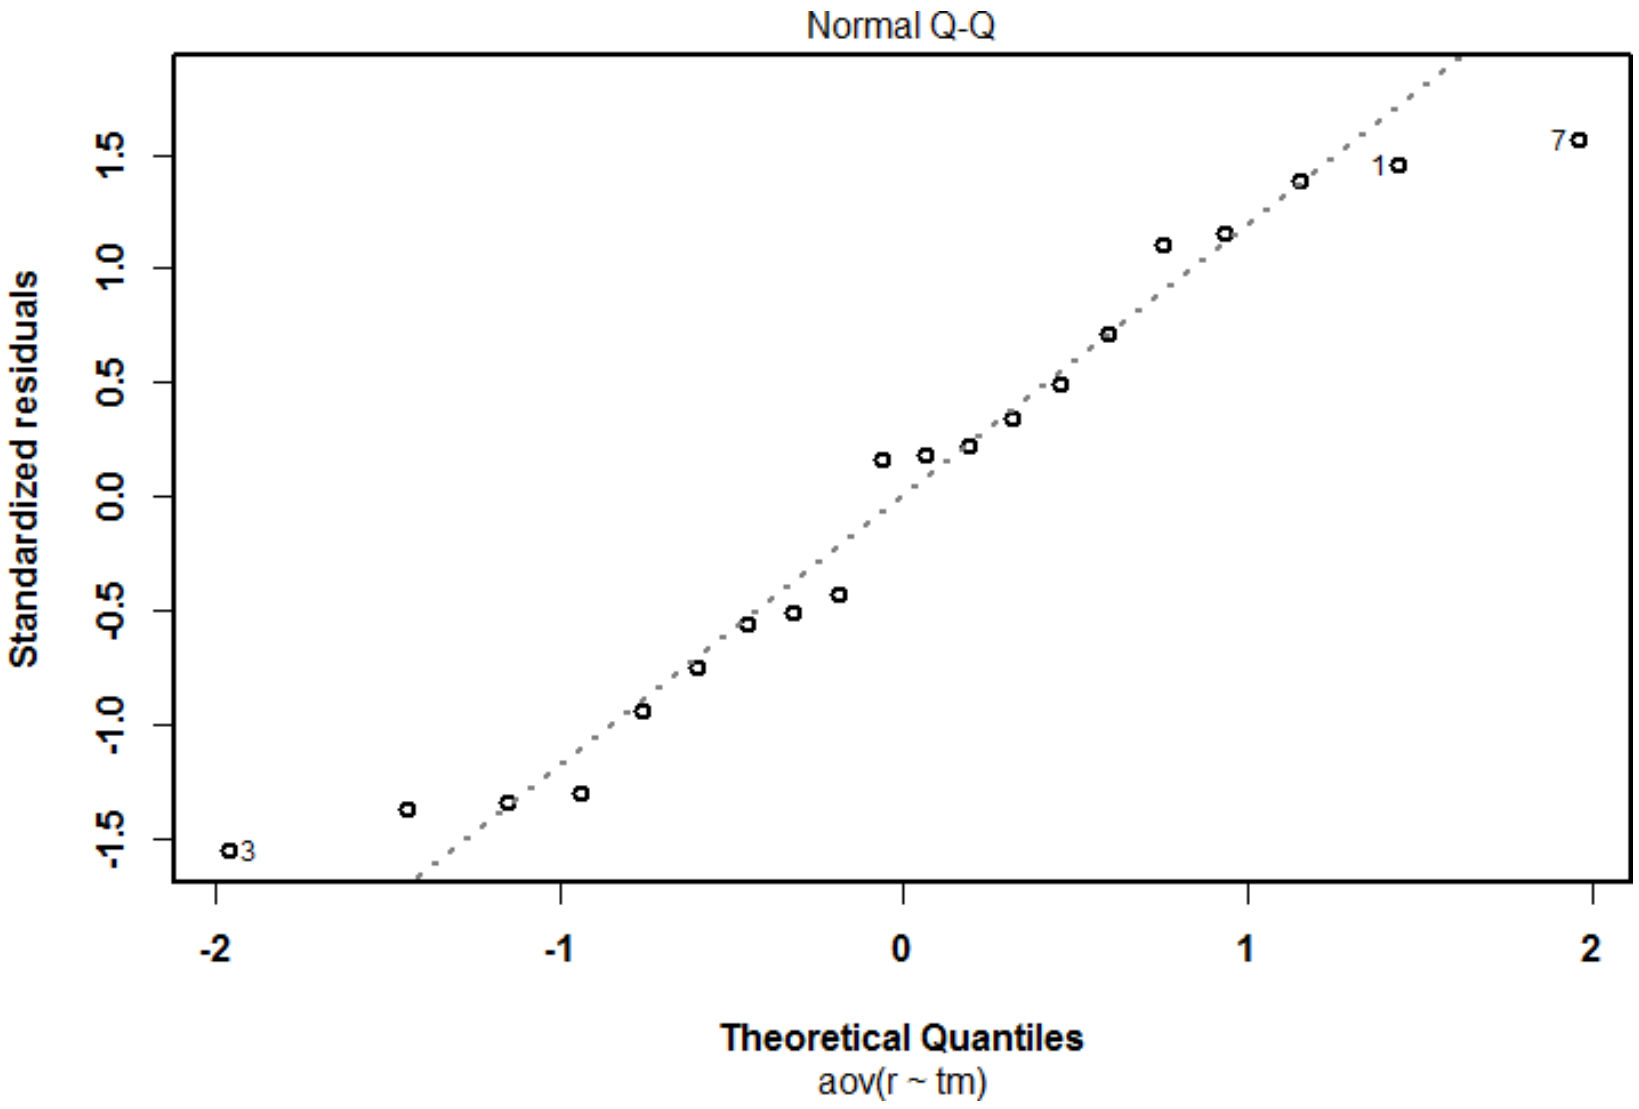
Normal Q-Q
Standardized residuals
1.5
1.0
0.5
0.0
-0.5
-1.0
-1.5
3
1
7
-2
-1
0
1
2
Theoretical Quantiles
aov(r ~ tm)

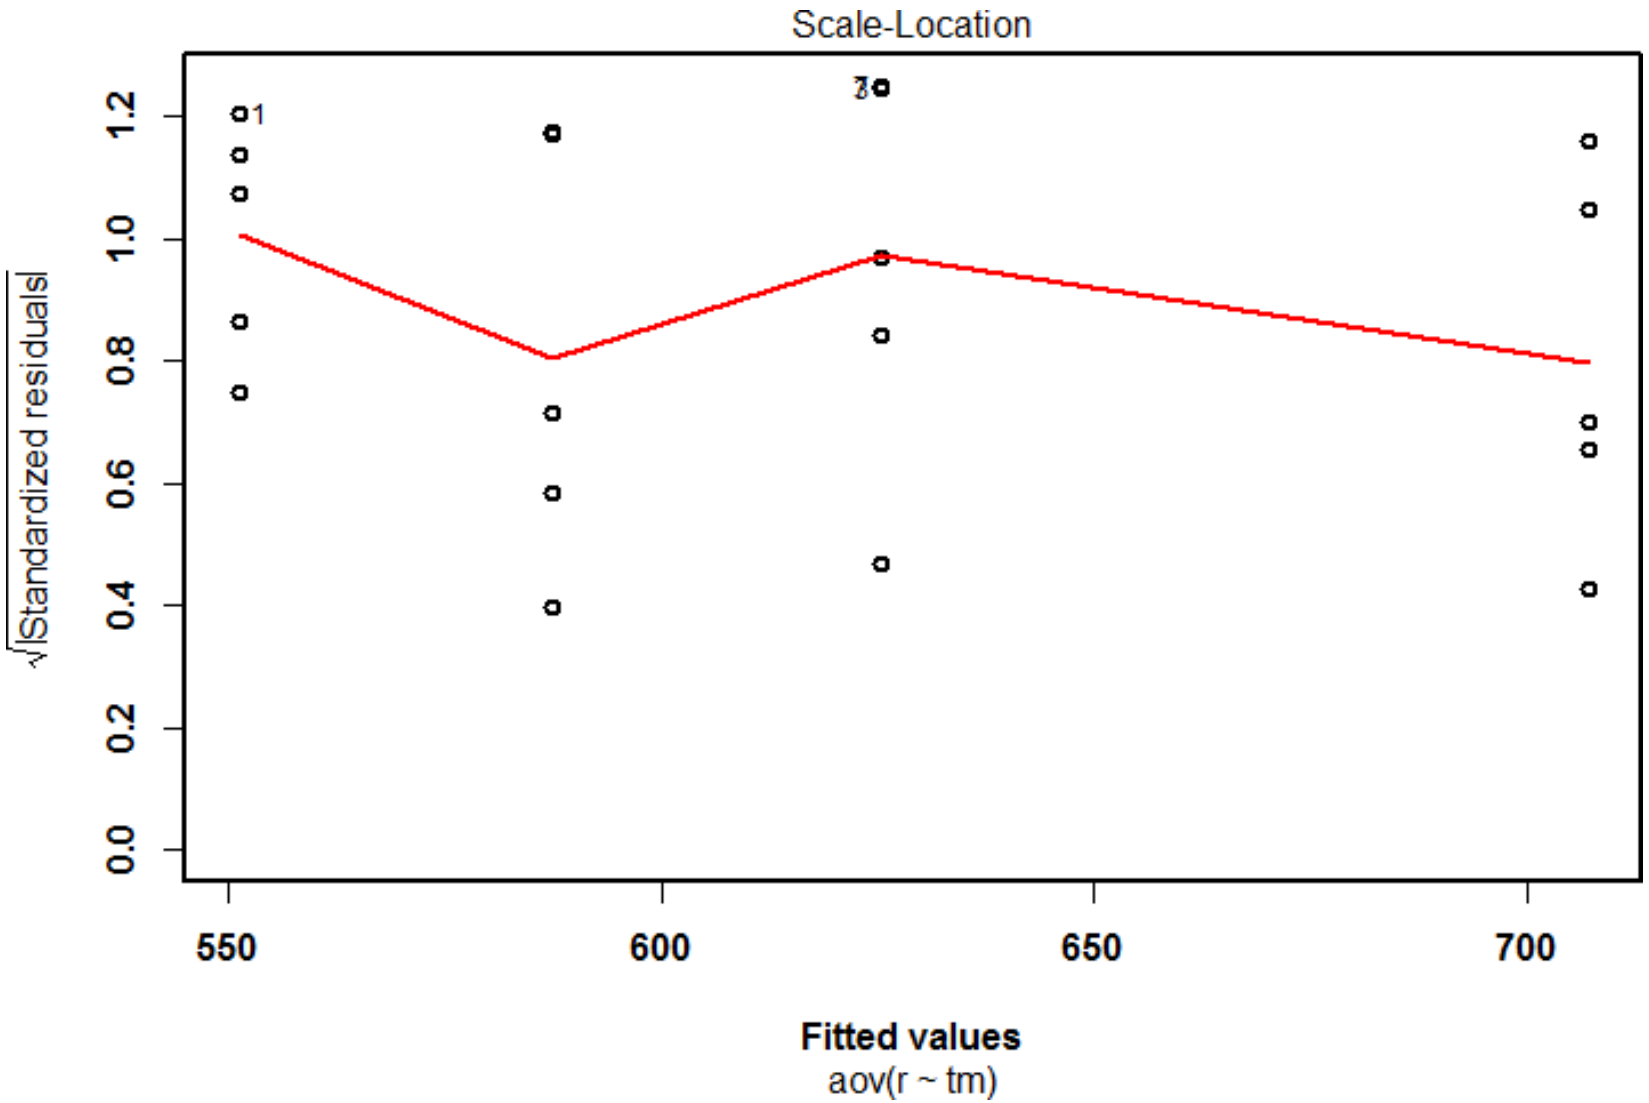
Scale-Location
√|Standardized residuals|
0.0
0.2
0.4
0.6
0.8
1.0
1.2
1
3
550
600
650
700
Fitted values
aov(r ~ tm)

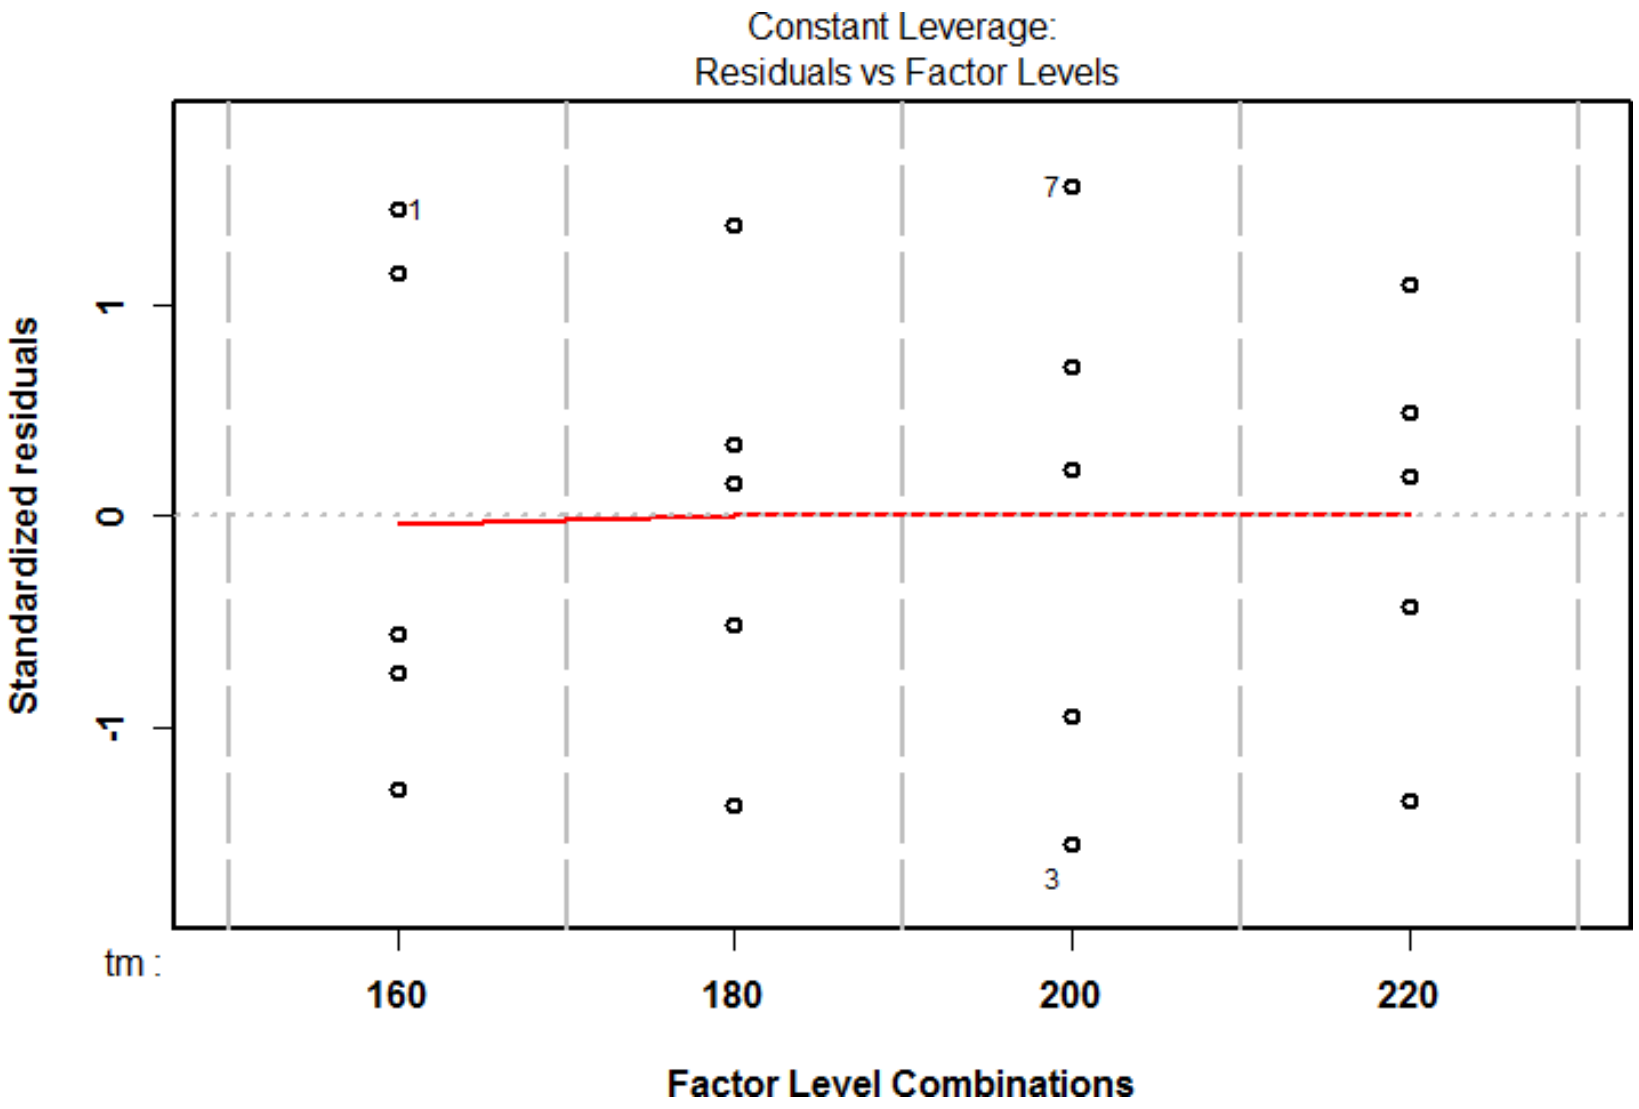
Constant Leverage:
Residuals vs Factor Levels
Standardized residuals
1
0
-1
1
7
3
tm :
160
180
200
220
Factor Level Combinations

- **Teste Estatístico para Igualdade de Variância (em cada tratamento)**

  H_0: $\sigma_1^2 = \sigma_2^2 = \cdots = \sigma_a^2 = 0$

  H_1: $\sigma^2 \neq 0$ para no mínimo um i

  – Gráfico dos resíduos

  – *Teste de Bartlett*

    - χ^2 distribuição com $a - 1$ graus de liberdade
    - a amostras aleatórias de populações normais independentes

a = 4 (160,180,200 e 220)

$$\chi_0^2 = 2.3026\frac{q}{c}$$

$$q = (N - a)logS_p^2 - \sum_{i=1}^{a}(n_i - 1)\, logS_i^2$$

n_i = 5 (replicatas)

N = 20 ($a \times n_i$)

$$c = 1 + \frac{1}{3(a-1)}\left[\sum_{i=1}^{a}(n_i - 1)^{-1} - (N - a)^{-1}\right]$$

$$S_p^2 = \frac{\sum_{i=1}^{a}(n_i - 1)S_i^2}{N - a}$$

e S^2 é a variância amostral da *i*-ésima população.

- A quantidade q é grande quando as variâncias das amostras S^2 diferem grandemente e é igual a zero quando todas são iguais.

  - Rejeita-se H_0 $\quad \chi_0^2 > \chi_{\alpha,\alpha-1}^2$

Teste de Bartlett

$$q = (N-a)\log S_p^2 - \sum_{i=1}^{a} (n_i - 1)\log S^2$$

$$S_p^2 = \frac{\sum_{i=1}^{a} (n_i - 1)S^2}{N-a}$$

```
a<-4
ni<-5
N<-a*ni
library(matrixStats)
#install.packages("matrixStats") to run colVars
Si2<-colVars(as.matrix(RF.df));Si2
ni.log.Si2<-4*log10(Si2);ni.log.Si2
sum.ni.log.Si2<-sum(ni.log.Si2);sum.ni.log.Si2

S2p<-sum(4*Si2)/(N-a);S2p

q<-(N-a)*log10(S2p)-sum.ni.log.Si2;q
```

$$c = 1 + \frac{1}{3(a-1)}\left[\sum_{i=1}^{a} (n_i - 1)^{-1} - (N-a)^{-1}\right]$$

```
c<-1+1/(3*(a-1))*(a/(5-1)-1/(N-a));c
```

$$\chi_0^2 = 2.3026\frac{q}{c}$$

```
chi2o<-2.3026*q/c;chi2o
```

Rejeita H_0 ($\sigma_1^2 = \sigma_2^2 = \cdots = \sigma_a^2 = 0$:)

a) $\chi_0^2 > \chi_{\alpha,\alpha-1}^2$

```
qchisq(.95,3) #95%conf, df=3
chi2o>qchisq(.95,3)
```

b) $p(\chi_0^2) < 0{,}05$ (95% confiança)

```
1-pchisq(chi2o,3)
1-pchisq(chi2o,3)<0.05
```

Ou…

```
bartlett.test(r~tm)

        Bartlett test of homogeneity of variances

data:  r by tm
Bartlett's K-squared = 0.43349, df = 3,
p-value = 0.9332
```
→ we cannot reject the null hypothesis

- Os testes retornam um valor p que descreve o resultado do teste.
- Assumindo que a hipótese de teste é verdadeira, o valor p é a probabilidade de obter um resultado pior do que o observado.
- Valores p grandes correspondem a um teste bem-sucedido.
- **Normalmente, uma hipótese de teste é aceita se o valor de p exceder a 0,05**

não há evidências para contrariar a alegação de que todas as quatro variações são iguais (gráfico: resíduos x valores preditos)

Interpretação Prática dos Resultados

Após

realizar o experimento,

conduzido a análise estatística, e

investigar as suposições subjacentes,

o pesquisador está pronto para tirar conclusões práticas sobre o problema que está estudando

- **Modelo de Regressão**
  - Os fatores envolvidos em um experimento podem ser *quantitativos* ou *qualitativos*
  - *Modelo empírico* do processo
    - Uma equação de interpolação para a variável de resposta no experimento
    - *Análise de Regressão*
      - *Método dos mínimos quadrados*

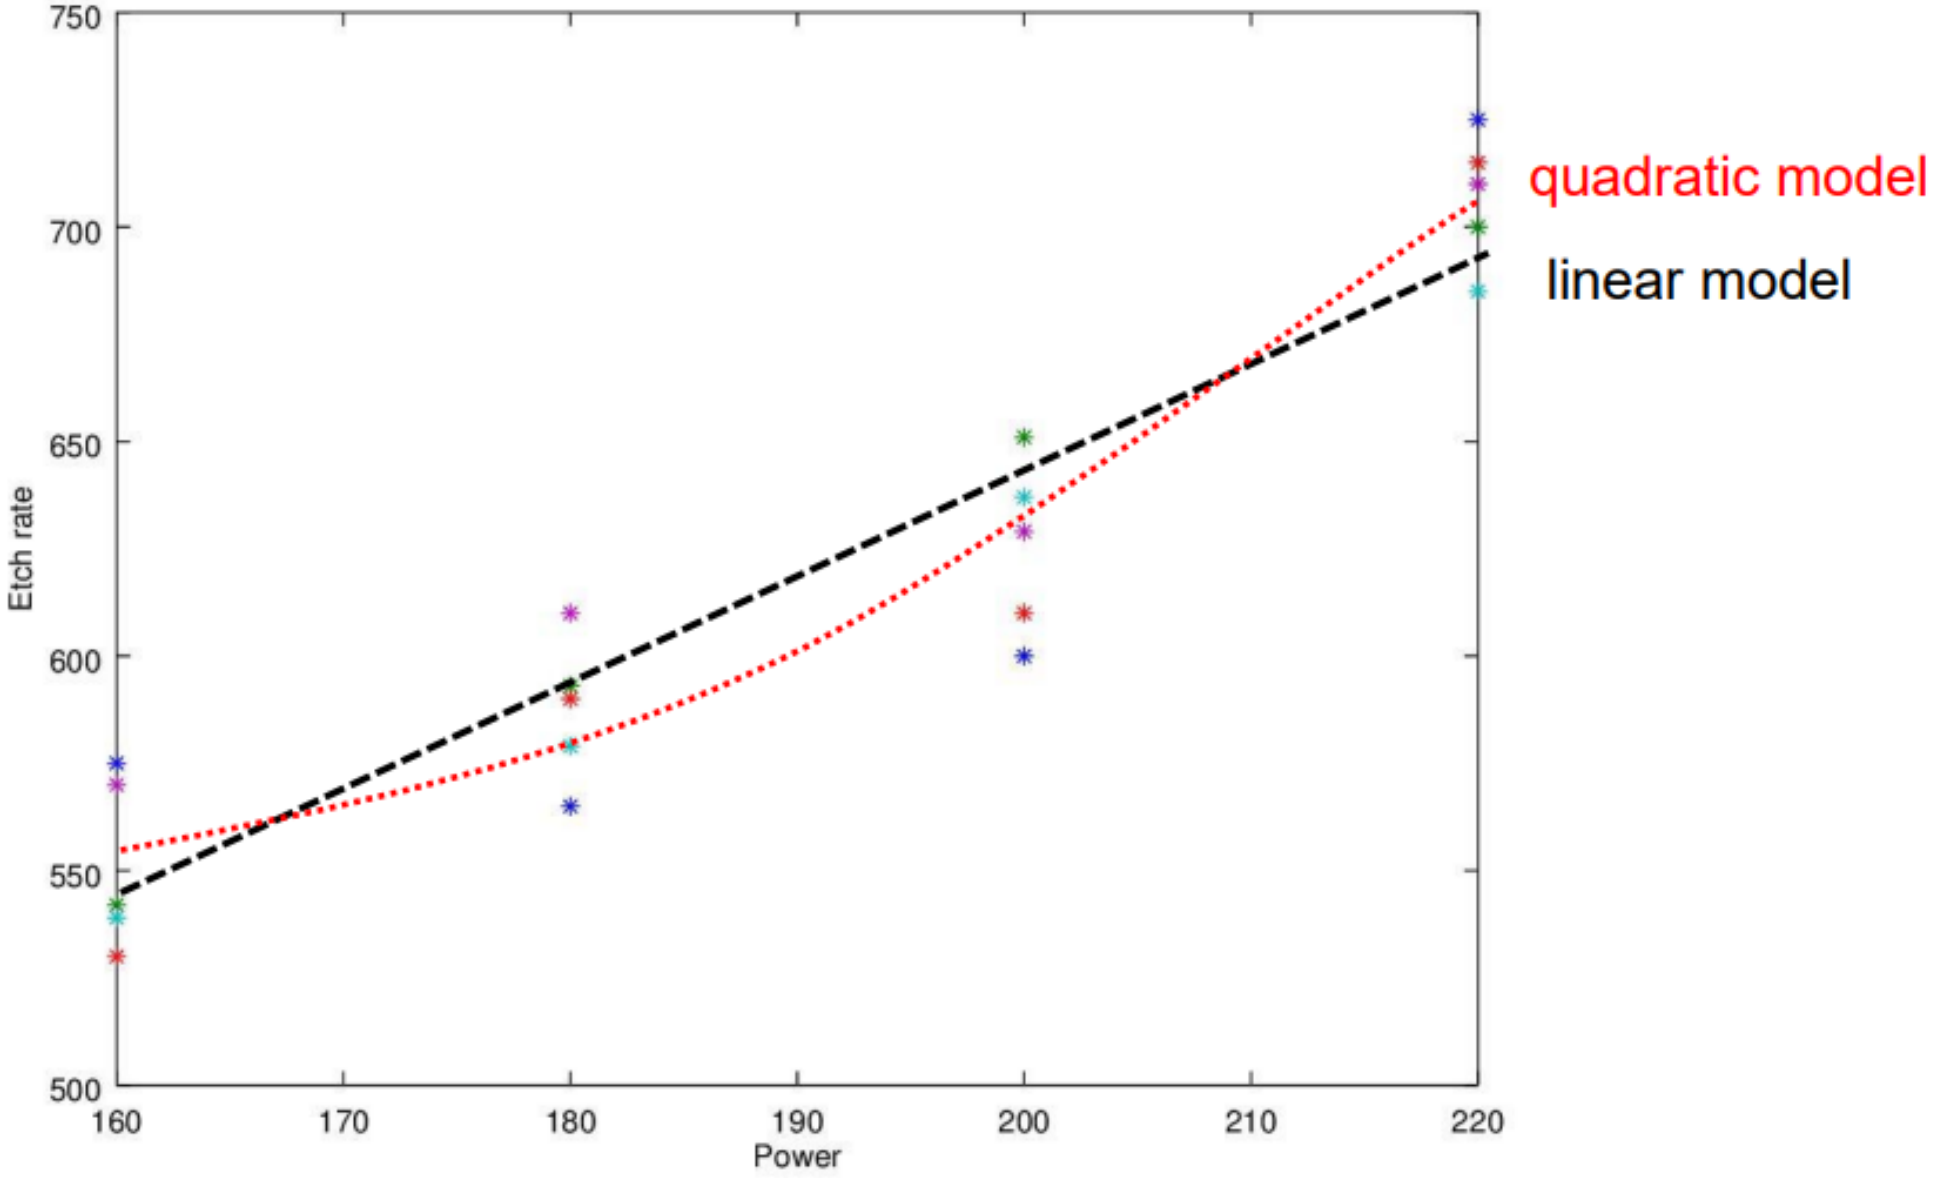
750
700
650
600
550
500
Etch rate
160
170
180
190
200
210
220
Power
quadratic model
linear model

- **Comparando Pares de Médias de Tratamentos**
  - *Teste de Tukey*
    - Após uma ANOVA em que a hipótese nula de igualdade de tratamento foi rejeitada
    - Teste todas as comparações de médias em pares (para todo $i \neq j$)

$$H_0: \mu_i = \mu_j$$
$$H_1: \mu_i \neq \mu_j$$

    - Amostra de tamanho igual ou desigual (Teste de*Tukey-Kramer*)00
    - Distribuição da *estatística de amplitude estudentizada, q*, tabela

$$T_\alpha = q_\alpha(a, f)\sqrt{\frac{MS_E}{n}}$$

- **Experiência de gravação por plasma**
- $a = 4$
- $\alpha = 0.05$

$f = 16$ graus de liberdade $(N - a)$

$MS_E = 333.7$

$n = 5$

$q_{0,05}(4,16) \rightarrow$ q tabela

$q_{0.05}(4,16) = 4,046$

$$T_{0.05} = 4,046\sqrt{\frac{333,7}{5}} = \mathbf{33,1}$$

quaisquer pares de médias de tratamento que diferem em valor absoluto em mais de 33,1 implicaria que o par correspondente de médias populacionais é significativamente diferente

$y_{1.} = 551,2 \quad y_{2.} = 587,4$

$y_{3.} = 625,4 \quad y_{4.} = 707,0$

$y_{1.} - y_{2.} = -36,2$

$y_{1.} - y_{3.} = -74,2$

...

o procedimento de Tukey indica que todos os pares de médias diferem

Ou...

```
tukey<-TukeyHSD(x=av, 'tm', conf.level=0.95);tukey
```

```
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = r ~ tm)

$tm
         diff        lwr       upr     p adj
180-160  36.2   3.145624  69.25438 0.0294279
200-160  74.2  41.145624 107.25438 0.0000455
220-160 155.8 122.745624 188.85438 0.0000000
200-180  38.0   4.945624  71.05438 0.0215995
220-180 119.6  86.545624 152.65438 0.0000001
220-200  81.6  48.545624 114.65438 0.0000146
```

$y_{1.} - y_{2.}$

$y_{1.} - y_{3.}$

o procedimento de Tukey indica que todos os pares de médias diferem ($p < 0.05$)

```
plot(tukey)
```

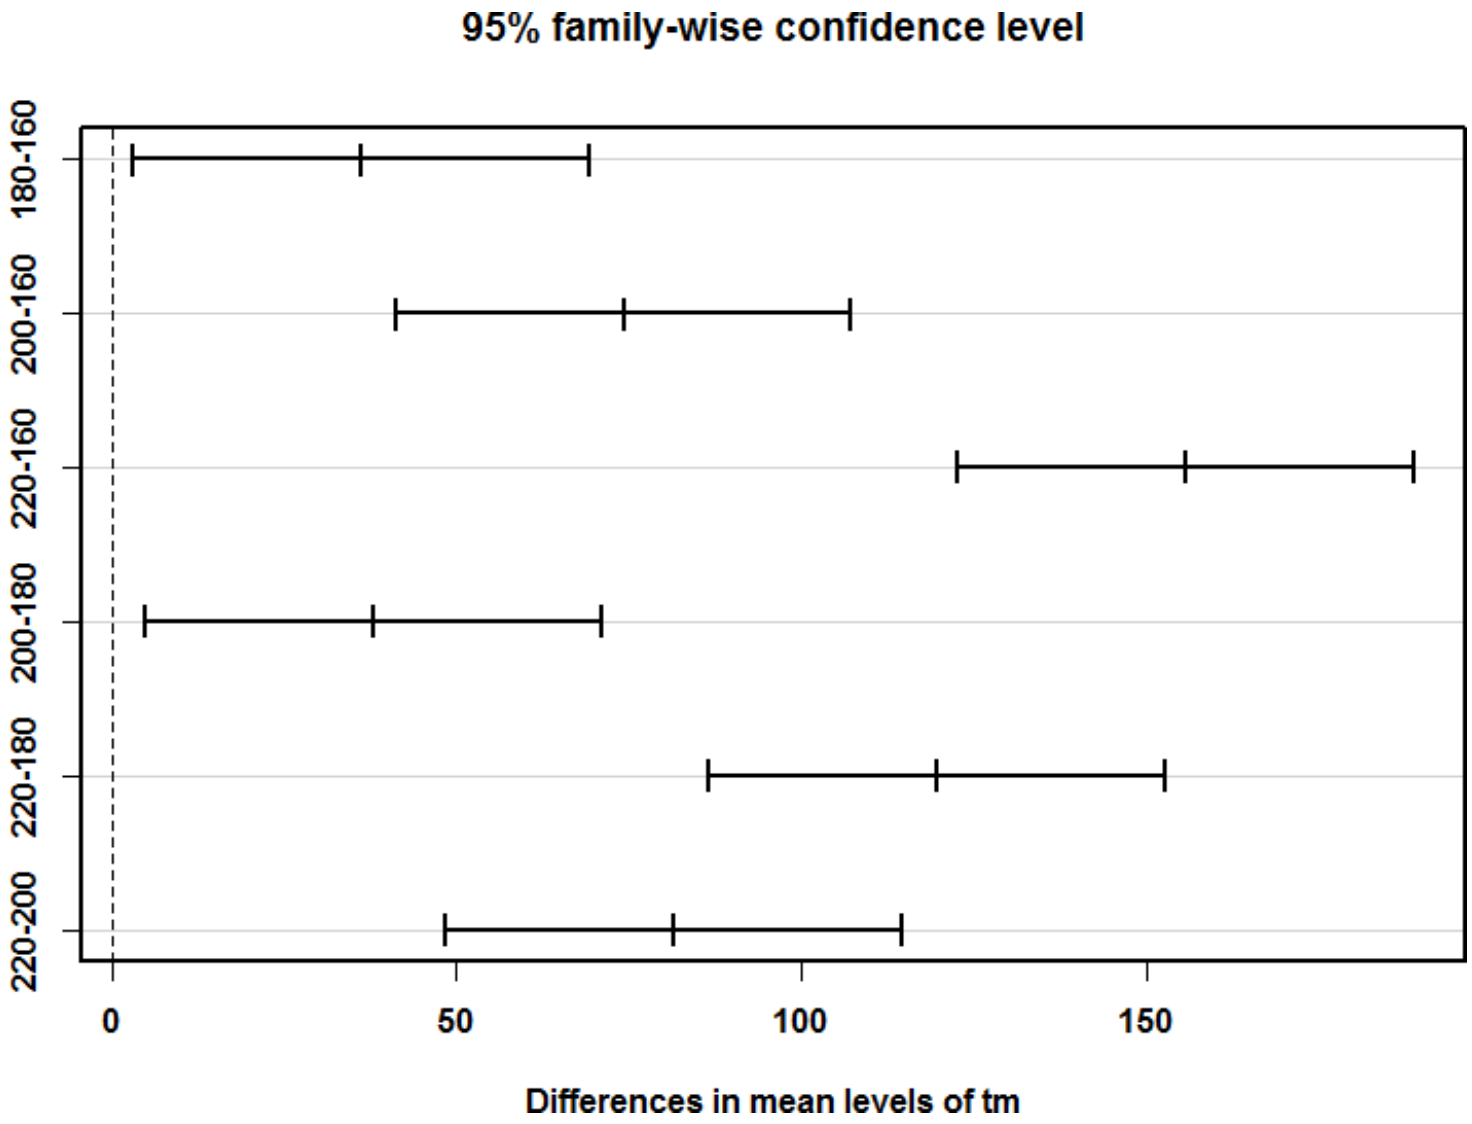
95% family-wise confidence level
180-160
200-160
220-160
200-180
220-180
220-200
0
50
100
150
Differences in mean levels of tm

Método não paramétrico na ANOVA

- **Teste Kruskal-Wallis**
  - Em situações em que a suposição de normalidade não é observada
  - Rejeita-se H_0 se $p < 0{,}05$

```
kruskal.test(r~tm)

        Kruskal-Wallis rank sum test data:

       r by tm
Kruskal-Wallis chi-squared = 16.907, df = 3, p-value = 0.0007386
```

Rejeita-se a hipótese nula

Esta é a mesma conclusão dada pelo teste F usado na análise de variância (ANOVA)

Experimento Fatorial com dois Fatores

Table 5-2 General Arrangement for a Two-Factor Factorial Design

		Factor B			
		1	2	...	b
Factor A	1	$y_{111}, y_{112}, \ldots, y_{11n}$	$y_{121}, y_{122}, \ldots, y_{12n}$		$y_{1b1}, y_{1b2}, \ldots, y_{1bn}$
	2	$y_{211}, y_{212}, \ldots, y_{21n}$	$y_{221}, y_{222}, \ldots, y_{22n}$		$y_{2b1}, y_{2b2}, \ldots, y_{2bn}$
	$\vdots$				
	a	$y_{a11}, y_{a12}, \ldots, y_{a1n}$	$y_{a21}, y_{a22}, \ldots, y_{a2n}$		$y_{ab1}, y_{ab2}, \ldots, y_{abn}$

a níveis do fator *A*; *b* níveis do fator *B*; *n* replicatas

Isto é um **planejamento completamente randomizado**

Table 5-2 General Arrangement for a Two-Factor Factorial Design

		Factor B			
		1	2	...	b
Factor A	1	$y_{111}, y_{112}, \ldots, y_{11n}$	$y_{121}, y_{122}, \ldots, y_{12n}$		$y_{1b1}, y_{1b2}, \ldots, y_{1bn}$
	2	$y_{211}, y_{212}, \ldots, y_{21n}$	$y_{221}, y_{222}, \ldots, y_{22n}$		$y_{2b1}, y_{2b2}, \ldots, y_{2bn}$
	$\vdots$				
	a	$y_{a11}, y_{a12}, \ldots, y_{a1n}$	$y_{a21}, y_{a22}, \ldots, y_{a2n}$		$y_{ab1}, y_{ab2}, \ldots, y_{abn}$

Modelo estatístico (efeitos):

$$y_{ijk} = \mu + \tau_i + \beta_j + (\tau\beta)_{ij} + \varepsilon_{ijk} \begin{cases} i = 1, 2, \ldots, a \\ j = 1, 2, \ldots, b \\ k = 1, 2, \ldots, n \end{cases}$$

Outros modelos (modelo da média, modelos de regressão) podem ser úteis

Extensão da ANOVA para o Planejamento Fatorial (Caso dos Efeitos Fixos)

$$\sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n}(y_{ijk}-\bar{y}_{...})^2 = bn\sum_{i=1}^{a}(\bar{y}_{i..}-\bar{y}_{...})^2 + an\sum_{j=1}^{b}(\bar{y}_{.j.}-\bar{y}_{...})^2$$

$$+n\sum_{i=1}^{a}\sum_{j=1}^{b}(\bar{y}_{ij.}-\bar{y}_{i..}-\bar{y}_{.j.}+\bar{y}_{...})^2 + \sum_{i=1}^{a}\sum_{j=1}^{b}\sum_{k=1}^{n}(y_{ijk}-\bar{y}_{ij.})^2$$

$$SS_T = SS_A + SS_B + SS_{AB} + SS_E$$

df breakdown:

$$abn-1 = a-1+b-1+(a-1)(b-1)+ab(n-1)$$

ANOVA – Efeitos Fixos

Table 5-3 The Analysis of Variance Table for the Two-Factor Factorial, Fixed Effects Model

Source of Variation	Sum of Squares	Degrees of Freedom	Mean Square	F_0
A treatments	SS_A	$a - 1$	$MS_A = \frac{SS_A}{a-1}$	$F_0 = \frac{MS_A}{MS_E}$
B treatments	SS_B	$b - 1$	$MS_B = \frac{SS_B}{b-1}$	$F_0 = \frac{MS_B}{MS_E}$
Interaction	SS_{AB}	$(a-1)(b-1)$	$MS_{AB} = \frac{SS_{AB}}{(a-1)(b-1)}$	$F_0 = \frac{MS_{AB}}{MS_E}$
Error	SS_E	$ab(n-1)$	$MS_E = \frac{SS_E}{ab(n-1)}$	
Total	SS_T	$abn - 1$		

ANOVA de dois fatores (Efeitos Fixos)

- Você supervisiona a produção da Perfect Parachutes Company. Os paraquedas são de uma fibra sintética adquirida de um dentre quatro diferentes fornecedores.
- A resistência dessas fibras é uma característica importante que garante paraquedas de qualidade.
- Você precisa decidir se as fibras sintéticas de cada um de seus quatro fornecedores resultam em paraquedas com igual resistência.

ANOVA de dois fatores (Efeitos Fixos)

- Além disso, sua fábrica utiliza dois tipos de teares para produzir paraquedas: Jetta e *Turk*.
- Avalie se quaisquer diferenças entre os quatro fornecedores, em termos da resistência dos paraquedas, são dependentes do tipo de tear utilizado.

Dados do experimento

Tear	Fornecedor 1	Fornecedor 2	Fornecedor 3	Fornecedor 4
jetta	20,6	22,6	27,7	21,5
jetta	18,0	24,6	18,6	20,0
jetta	19,0	19,6	20,8	21,1
jetta	21,3	23,8	25,1	23,9
jetta	13,2	27,1	17,7	16,0
turk	18,5	26,3	20,6	25,4
turk	24,0	25,3	25,2	19,9
turk	17,2	24,0	20,8	22,6
turk	19,9	21,2	24,7	17,5
turk	18,0	24,5	22,9	20,4

Resolução usando o R Studio

- tear.fornec <- c(20.6, 22.6, 27.7, 21.5, 18.0, 24.6, 18.6, 20.0, 19.0, 19.6, 20.8, 21.1, 21.3, 23.8, 25.1, 23.9, 13.2, 27.1, 17.7, 16.0, 18.5, 26.3, 20.6, 25.4, 24.0, 25.3, 25.2, 19.9, 17.2, 24.0, 20.8, 22.6, 19.9, 21.2, 24.7, 17.5, 18.0, 24.5, 22.9, 20.4)
- f<-rep(gl(4,1, label=c(paste("Fornecedor",1:4))),1)
- t<-gl(2, 20,label=c("Jetta","Turk"))
- tabela <- data.frame(tear=t, fornecedor=f, dados=tear.fornec)
- resultado.anova <- anova(aov(dados~fornecedor+tear+fornecedor:tear, data=tabela))

Resolução usando o R Studio

- resultado.anova

Analysis of Variance Table

Response: dados

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
fornecedor	3	134.349	44.783	5.1999	0.004866
tear	1	6.972	6.972	0.8096	0.374968
Fornec.:tear	3	0.287	0.096	0.0111	0.998365
Residuals	32	275.592	8.612		

Resolução usando o R Studio

- # para o fator A (fornecedores), o teste de Tukey-Kramer
- qtukey(.95, 4, 32) # Qs, com prob, c=4 (gl numerador) e rc(n'-1)=32 (gl denominador)
- [1] 3.831616
- resultado <- aov(dados~fornecedor+tear+fornecedor:tear, data=tabela)
- tcm <- TukeyHSD(resultado, "fornecedor", ordered = TRUE, conf.level=0.95)

Resolução usando o R Studio

- > tcm

Tukey multiple comparisons of means

95% family-wise confidence level

factor levels have been ordered

Fit: aov(formula = dados ~ fornecedor + tear + fornecedor:tear, data = tabela)

$fornecedor

	diff	lwr	upr	p adj
Fornec. 4-Fornec. 1	1.86	-1.6958243	5.415824	0.4981796
Fornec. 3-Fornec. 1	3.44	-0.1158243	6.995824	0.0608501
Fornec. 2-Fornec. 1	4.93	1.3741757	8.485824	0.0036713
Fornec. 3-Fornec. 4	1.58	-1.9758243	5.135824	0.6289186
Fornec. 2-Fornec. 4	3.07	-0.4858243	6.625824	0.1102811
Fornec. 2-Fornec. 3	1.49	-2.0658243	5.045824	0.6708279

plot(tcm)

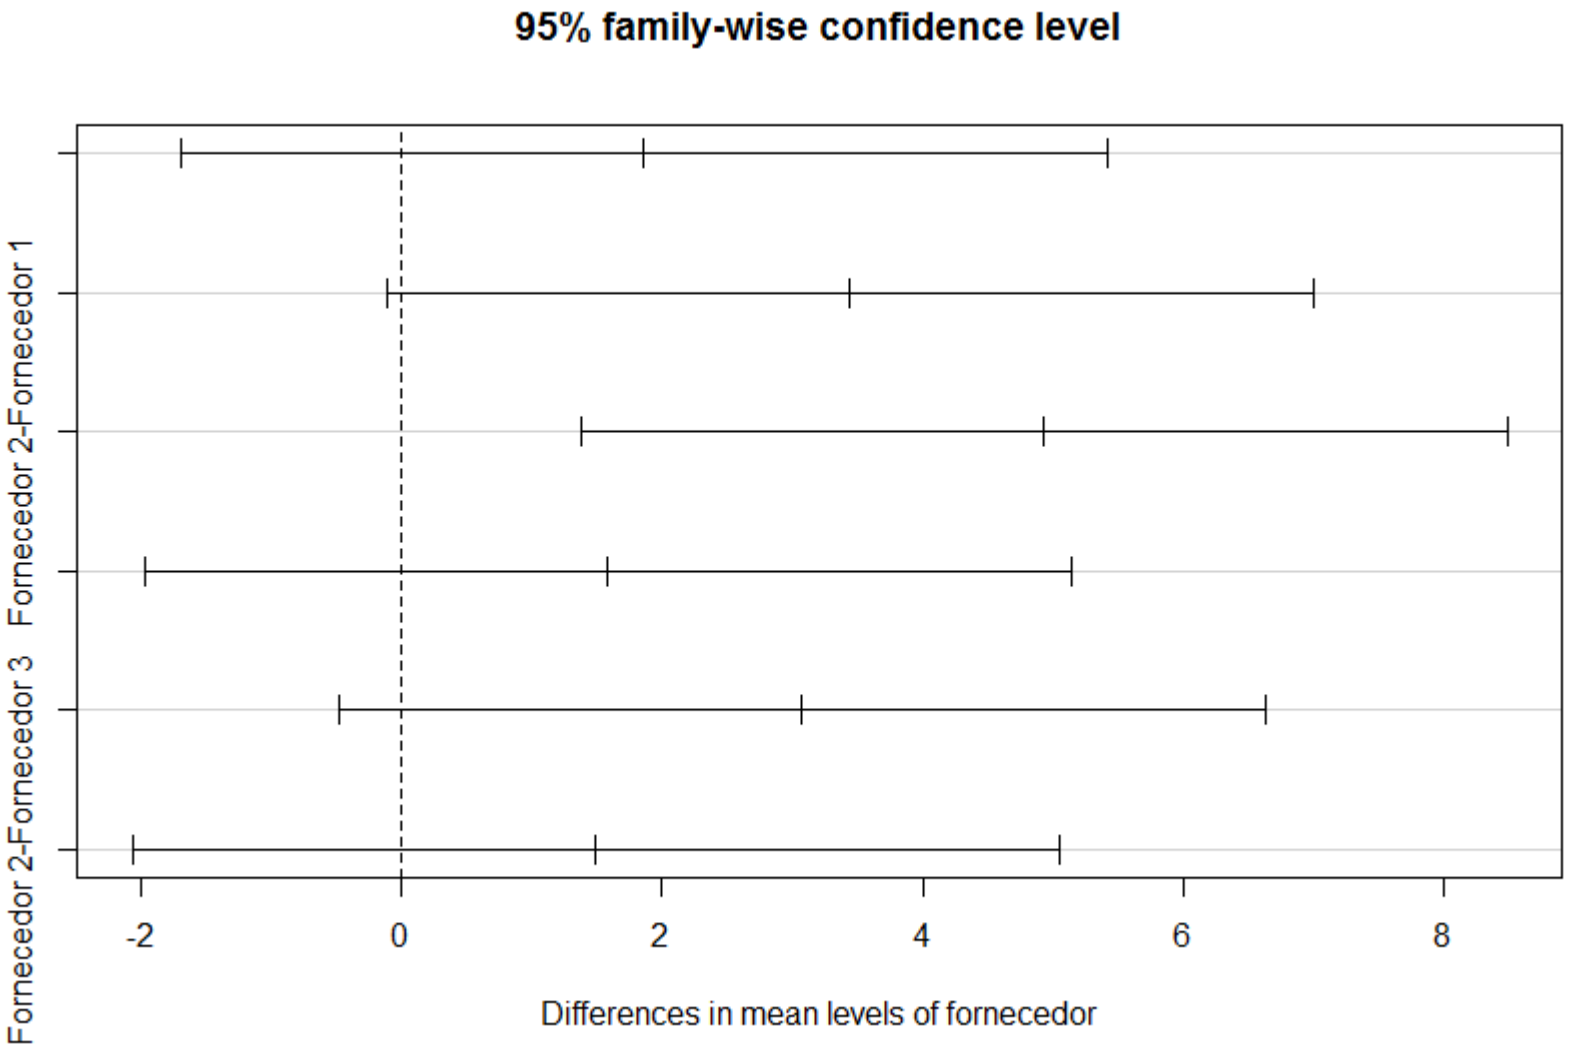
95% family-wise confidence level
Fornecedor 2-Fornecedor 1
Fornecedor 2-Fornecedor 3
-2
0
2
4
6
8
Differences in mean levels of fornecedor

Fatores Quantitativos e Qualitativos

- O procedimento básico da ANOVA trata cada fator como se ele fosse **qualitativo.**
- Algumas vezes, o experimento envolve fatores **quantitativos** e **qualitativos**.
- Isto deve levado em conta na análise que produz os **modelos de regressão** para os fatores quantitativos em cada nível (ou combinação dos níveis) dos fatores qualitativos
- As **curvas de nível** e/ou **as superfícies de resposta** oferecem uma ajuda considerável na interpretação prática dos resultados.

Planejamentos com três ou mais Fatores

- O procedimento básico é similar ao caso de dois fatores; todas as *abc...kn* combinações de tratamentos são conduzidos em ordem randômica.
- ANOVA é similar:

$$SS_T = SS_A + SS_B + \cdots + SS_{AB} + SS_{AC} + \cdots$$
$$+ SS_{ABC} + \cdots + SS_{AB\cdots K} + SS_E$$

ANOVA DE DOIS FATORES

```
# ANOVA de dois fatores no R
install.packages("dplyr")
library("dplyr")
# Adicione a semente para obter resultados reprodutíveis
set.seed(1234)
```

ANOVA DE DOIS FATORES

Aqui, usaremos o conjunto de dados R integrado chamado ToothGrowth. O comprimento do dente foi medido e uma amostra dos dados é mostrada a seguir.

Ele contém dados de um estudo que avaliou o efeito da vitamina C no crescimento dos dentes em cobaias.

O experimento foi realizado em 60 porcos, onde cada animal recebeu um dos três níveis de dose de vitamina C (0,5 / 1 / 2 mg/dia) por um dos dois métodos de administração (suco de laranja ou ácido ascórbico (uma forma de vitamina C e codificado como VC).

O comprimento do dente foi medido e uma amostra dos dados é mostrada a seguir

Armazene os dados na variável my_data

```
my_data <- ToothGrowth
```

ANOVA DE DOIS FATORES

```
dplyr::sample_n(my_data, 10)
 len supp dose
1  21.5   VC  2.0
2  17.3   VC  1.0
3  27.3   OJ  2.0
4  18.5   VC  2.0
5   8.2   OJ  0.5
6  26.4   OJ  1.0
7  25.8   OJ  1.0
8   5.2   VC  0.5
9   6.4   VC  0.5
10  9.4   OJ  0.5
```

ANOVA DE DOIS FATORES

```
# Verifique a estrutura do objeto
str(my_data)
'data.frame':  60 obs. of  3 variables:
 $ len : num  4.2 11.5 7.3 5.8 6.4 10 11.2 11.2 5.2 7 ...
 $ supp: Factor w/ 2 levels "OJ","VC": 2 2 2 2 2 2 2 2 2 2 ...
 $ dose: num  0.5 0.5 0.5 0.5 0.5 0.5 0.5 0.5 0.5 0.5 ...
```

ANOVA DE DOIS FATORES

```
# Converta as doses como fator e recodifique os níveis como "D0.5", "D1", "D2"
my_data$dose <- factor(my_data$dose, levels = c(0.5, 1, 2), labels = c("D0.5", "D1", "D2"))
head(my_data)
   len supp dose
1  4.2   VC D0.5
2 11.5   VC D0.5
3  7.3   VC D0.5
4  5.8   VC D0.5
5  6.4   VC D0.5
6 10.0   VC D0.5
```

ANOVA DE DOIS FATORES

```
# Criar uma tabela de dados
table(my_data$supp, my_data$dose)

     D0.5 D1 D2
  OJ   10 10 10
  VC   10 10 10
```

ANOVA DE DOIS FATORES

```
# Construa o gráfico do comprimento do dente ("len") por grupos ("dose")
# Gráfico de caixa de cores por um segundo grupo: "supp“
# Adicione a barra de erro: mean_se
# (outros valores incluem: mean_sd, mean_ci, median_iqr, ....)
library("ggpubr")
# Gráfico de caixa com dois fatores
boxplot(len ~ supp * dose, data=my_data, frame = FALSE,
        col = c("#00AFBB", "#E7B800"), ylab="Tooth Length")
```

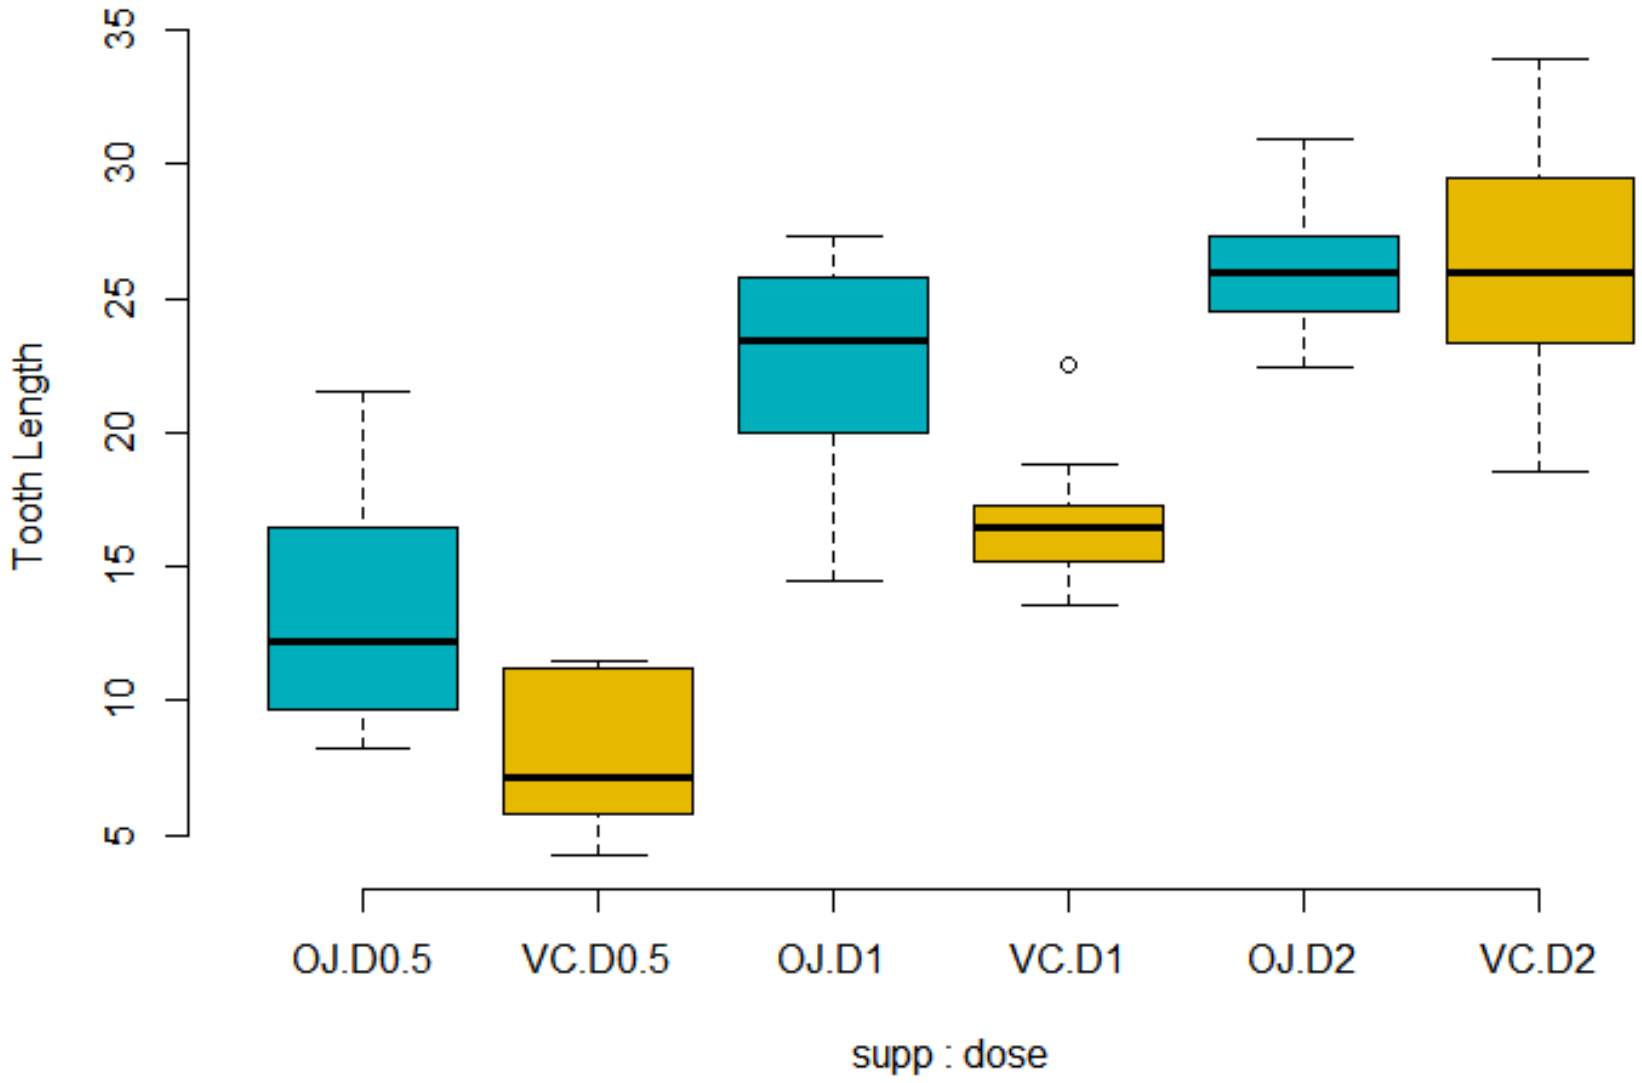
Tooth Length
5
10
15
20
25
30
35
OJ.D0.5
VC.D0.5
OJ.D1
VC.D1
OJ.D2
VC.D2
supp : dose

ANOVA DE DOIS FATORES

```
# Gráfico da interação de dois fatores
interaction.plot(x.factor = my_data$dose, trace.factor =
my_data$supp, response = my_data$len, fun = mean,
        type = "b", legend = TRUE,
        xlab = "Dose", ylab="Tooth Length",
        pch=c(1,19), col = c("#00AFBB", "#E7B800"))
```

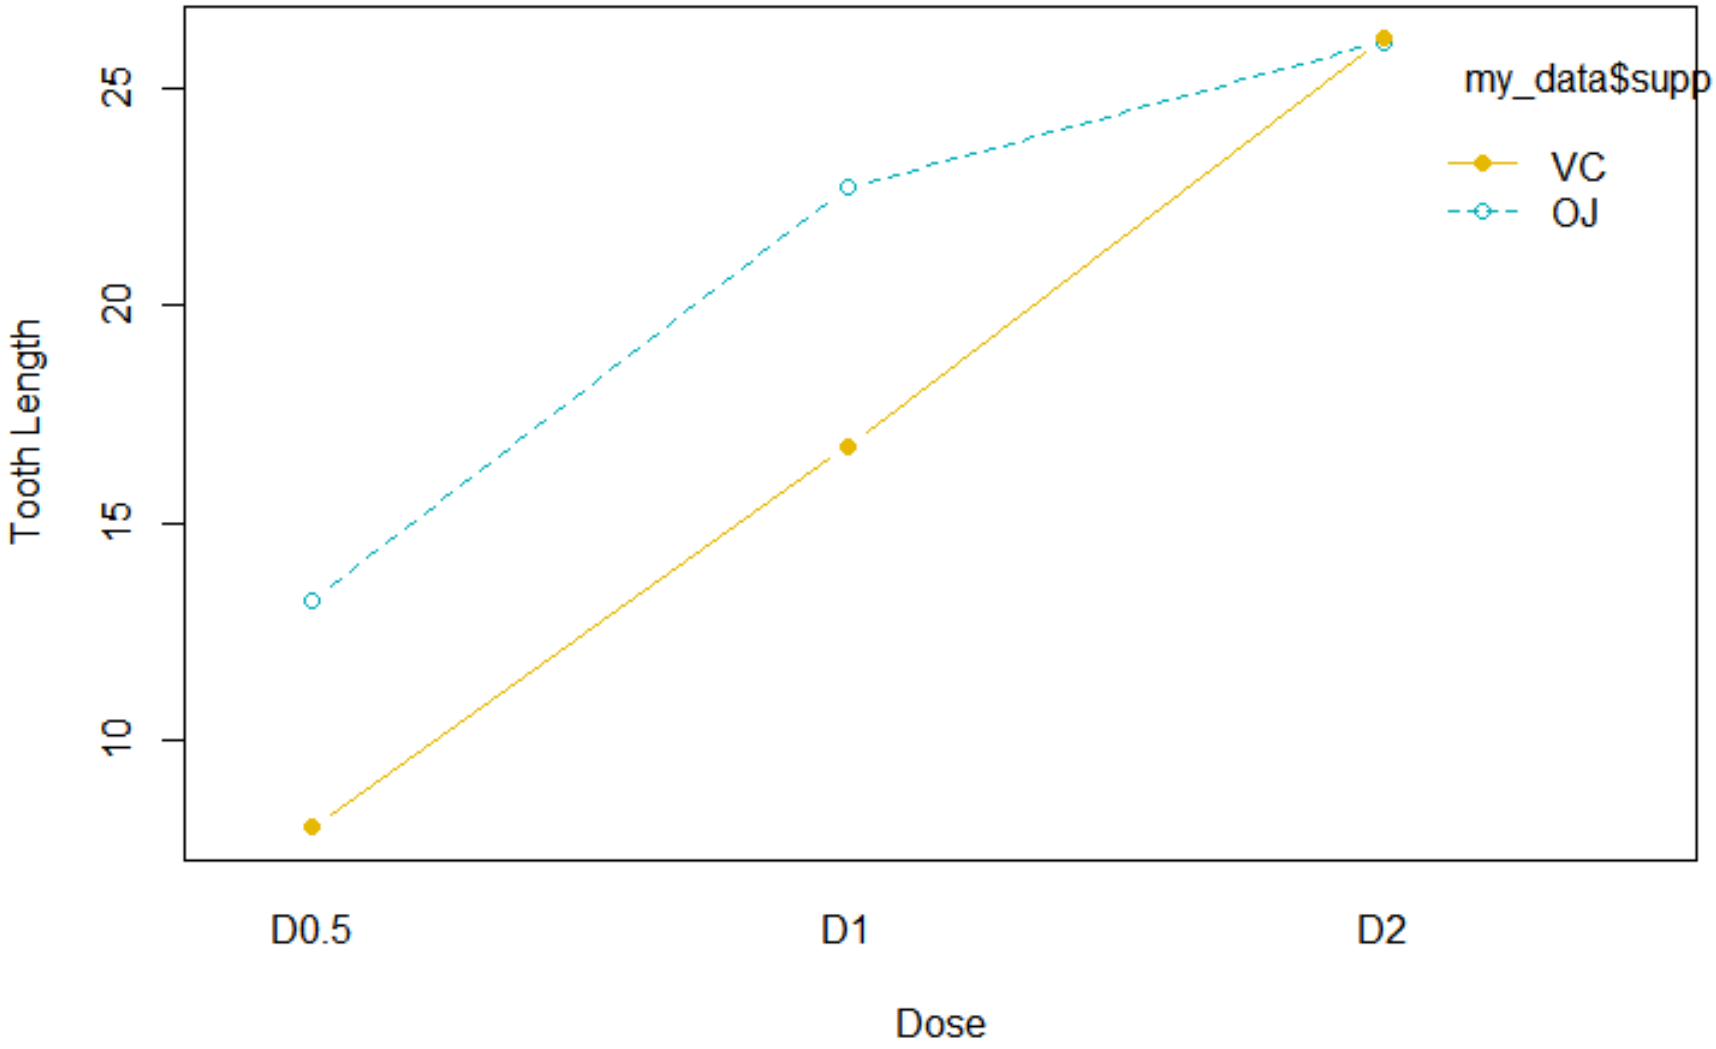
my_data$supp
VC
OJ
Tooth Length
10
15
20
25
D0.5
D1
D2
Dose

ANOVA DE DOIS FATORES

```
# ANOVA teste
res.aov2 <- aov(len ~ supp + dose, data = my_data)
summary(res.aov2)
            Df  Sum Sq  Mean Sq F value   Pr(>F)
supp         1   205.4    205.4   14.02 0.000429 ***
dose         2  2426.4   1213.2   82.81  < 2e-16 ***
Residuals   56   820.4     14.7
```

ANOVA DE DOIS FATORES

```
# ANOVA de dois fatores com termo de interação
# Estes códigos são equivalentes
res.aov3 <- aov(len ~ supp * dose, data = my_data)
res.aov3 <- aov(len ~ supp + dose + supp:dose, data = my_data)
summary(res.aov3)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
supp	1	205.4	205.4	15.572	0.000231 ***
dose	2	2426.4	1213.2	92.000	< 2e-16 ***
supp:dose	2	108.3	54.2	4.107	0.021860 *
Residuals	54	712.1	13.2		

ANOVA DE DOIS FATORES

```
library("dplyr")
group_by(my_data, supp, dose) %>%
+   summarise(
+     count = n(),
+     mean = mean(len, na.rm = TRUE),
+     sd = sd(len, na.rm = TRUE)
+   )
`summarise()` has grouped output by 'supp'.
You can override using the `.groups` argument.
```

ANOVA DE DOIS FATORES

```
# A tibble: 6 x 5
# Groups:   supp [2]
  supp  dose  count  mean    sd
  <fct> <fct> <int> <dbl> <dbl>
1 OJ    D0.5     10      13.2   4.46
2 OJ    D1       10      22.7   3.91
3 OJ    D2       10      26.1   2.66
4 VC    D0.5     10       7.98  2.75
5 VC    D1       10      16.8    2.52
6 VC    D2       10      26.1   4.80
```

ANOVA DE DOIS FATORES

Tukey HSD (Tukey Honest Significant Differences): TukeyHSD() para realizar múltiplas comparações de pares entre as médias dos grupos.

```
TukeyHSD(res.aov3, which = "dose")

  Tukey multiple comparisons of means

    95% family-wise confidence level

Fit: aov(formula = len ~ supp + dose + supp:dose, data = my_data)

$dose

              diff       lwr          upr          p adj

D1-D0.5   9.130  6.362488   11.897512    0.0e+00

D2-D0.5 15.495 12.727488   18.262512   0.0e+00

D2-D1      6.365  3.597488    9.132512    2.7e-06
```

ANOVA DE DOIS FATORES

```
# 1. Homogeneidade das variâncias
plot(res.aov3, 1)
```

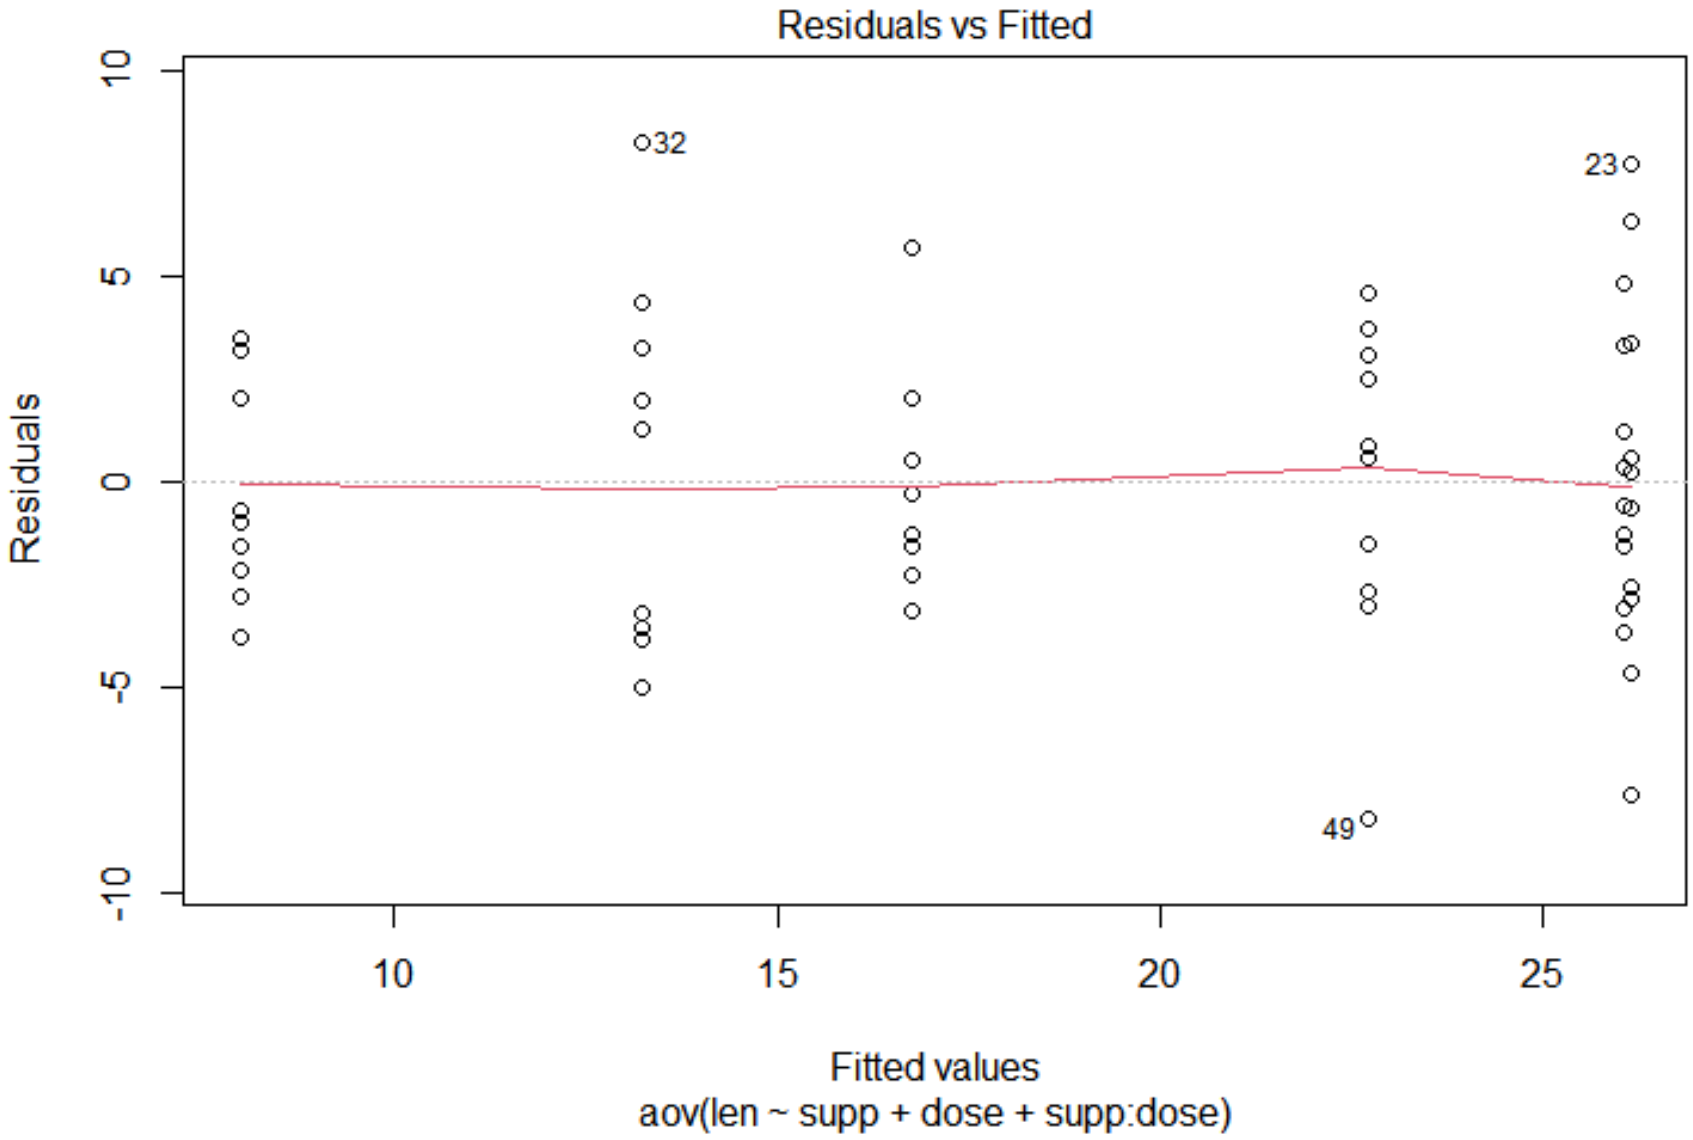
Residuals vs Fitted
Residuals
Fitted values
aov(len ~ supp + dose + supp:dose)
10
5
0
-5
-10
10
15
20
25
32
23
49

ANOVA DE DOIS FATORES

```
# 1. Homogeneidade das variâncias
library(car)
leveneTest(len ~ supp*dose, data = my_data)
Levene's Test for Homogeneity of Variance (center = median)
        Df    F value   Pr(>F)
group    5    1.7086    0.1484
        54
```

ANOVA DE DOIS FATORES

```
# 2. Normalidade
plot(res.aov3, 2)
```

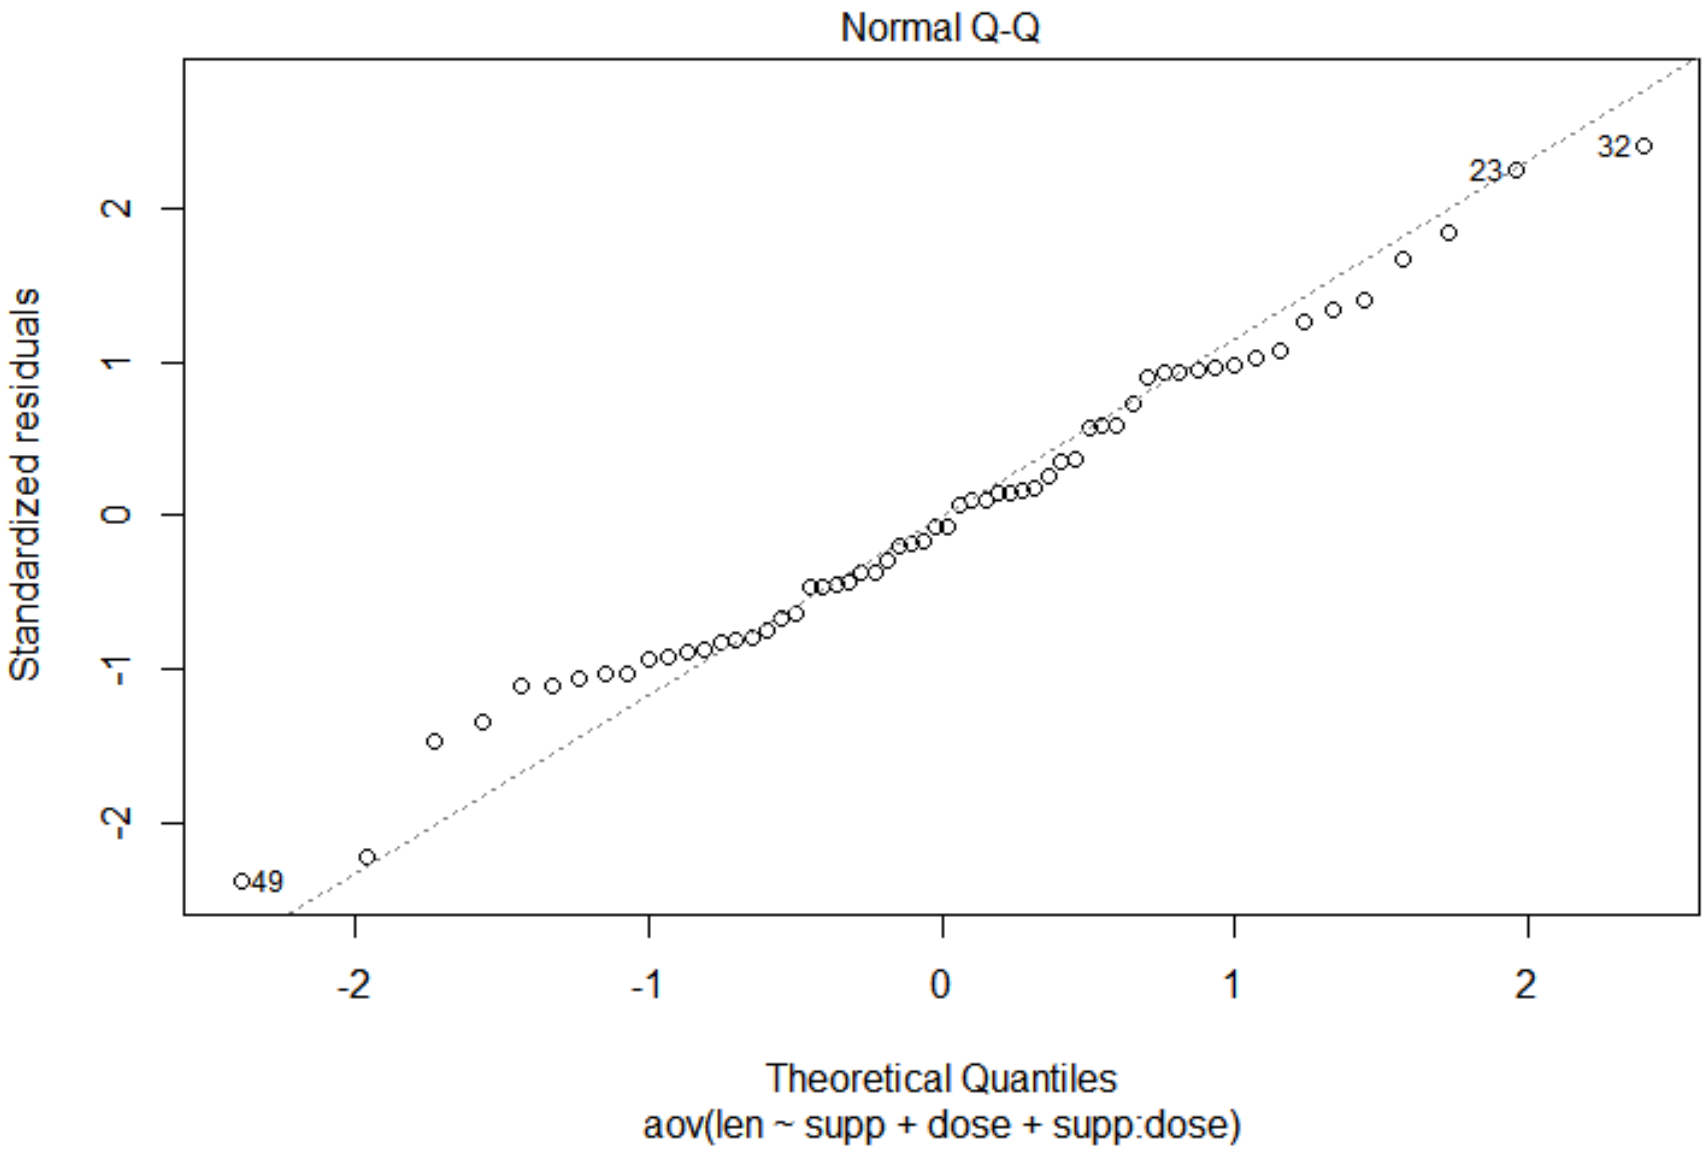
Normal Q-Q
Standardized residuals
Theoretical Quantiles
aov(len ~ supp + dose + supp:dose)
49
23
32
-2
-1
0
1
2

ANOVA DE DOIS FATORES

```
# 2. Normalidade
# Extraía os resíduos do modelo
aov_residuals <- residuals(object = res.aov3)
# Run Shapiro-Wilk test
shapiro.test(x = aov_residuals )
        Shapiro-Wilk normality test
data:  aov_residuals
W = 0.98499, p-value = 0.6694
```

ANOVA DE DOIS FATORES

Utilize o teste ANOVA de dois fatores no R para planejamentos desbalanceados da seguinte forma:

Existem três maneiras fundamentalmente diferentes de executar uma ANOVA em um planejamento desbalanceado.

Eles são conhecidos como somas dos quadrados Tipo-I, Tipo-II e Tipo-III.

Para manter as coisas simples, note que o método recomendado é a somas dos quadrados do Tipo-III.

ANOVA DE DOIS FATORES

```
library(car)
my_anova <- aov(len ~ supp * dose, data = my_data)
Anova(my_anova, type = "III")
Anova Table (Type III tests)
Response: len
```

	Sum Sq	Df	F value	Pr(>F)
(Intercept)	1750.33	1	132.730	3.603e-16 ***
supp	137.81	1	10.450	0.002092 **
dose	885.26	2	33.565	3.363e-10 ***
supp:dose	108.32	2	4.107	0.021860 *
Residuals	712.11	54		