# Planejamento e Otimização de Experimentos

## Planejamentos de Segunda Ordem

# Planejamento e Otimização de Experimentos (DoE)

## Planejamentos de Segunda Ordem

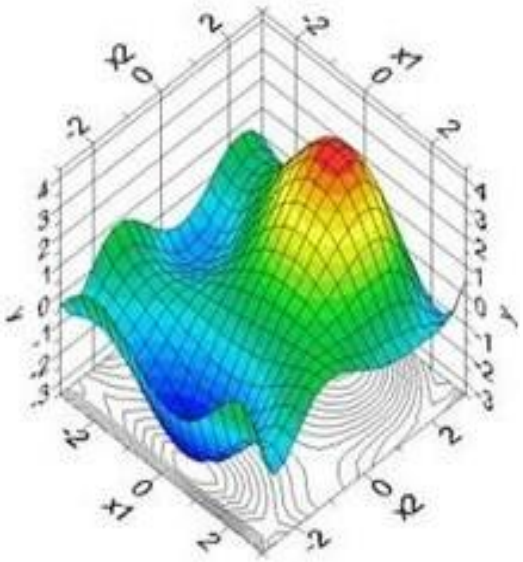

# Planejamentos de Segunda Ordem

- Modelo de regressão com dois regressores (p = 2)
- Restrições em relação ao erro
  - Erro i.i.d (distribuição idêntica e independentes)
  - Var ($e_j$) = $\sigma^2$
- $y_j = \beta_0 + \beta_1 x_{1j} + \beta_2 x_{2j} + \beta_{11} x_{1j}^2 + \beta_{22} x_{2j}^2 + \beta_{12} x_{1j} x_{2j} + e_j$
- Para *p* fatores ou regressores, temos
- $y_j = \beta_0 + \sum_{i=1}^{p} \beta_i x_{ij} + \sum_{i=1}^{p} \beta_{ii} x_{ij}^2 + \sum_{i<l}^{p} \beta_{il} x_{ij} x_{lj} + e_j$
- Onde j = 1, ..., n

# Planejamentos de Segunda Ordem

- Se no modelo descrito for retirado o termo de interação: $\beta_{12}x_{1j}x_{2j}$
- $y_j = \beta_0 + \beta_1 x_{1j} + \beta_2 x_{2j} + \beta_{11} x_{1j}^2 + \beta_{22} x_{2j}^2 + \beta_{12} x_{1j} x_{2j} + e_j$
- O modelo é chamado de quadrático puro:
- $y_j = \beta_0 + \beta_1 x_{1j} + \beta_2 x_{2j} + \beta_{11} x_{1j}^2 + \beta_{22} x_{2j}^2 + e_j$
- Os parâmetros dos modelos são estimados usando-se o método dos quadrados mínimos.
- O termo segunda ordem significa que a análise do planejamento é baseada no modelo quadrático.

# Planejamento e Otimização de Experimentos (DoE)

Planejamento Composto Central
Planejamento Híbrido
Planejamentos Ótimos
Planejamento Box-Behnken (BBD)
Planejamento Doehlert

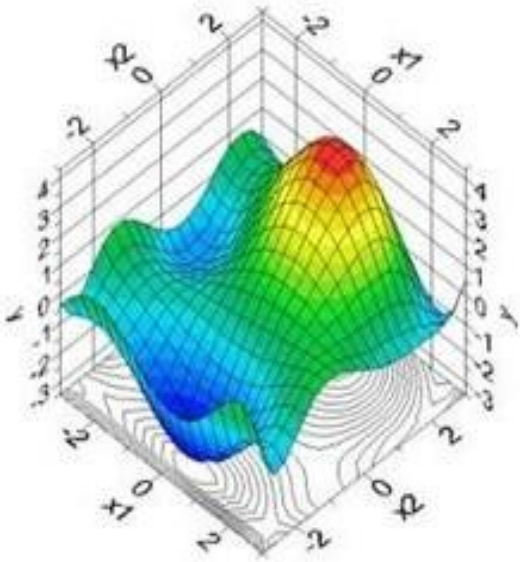

# Planejamento Composto Central (CCD)

- Introduzidos por Box & Wilson (1951).
- Objetivos:
  - Reduzir o número de pontos experimentais;
  - Minimizar o erro experimental.
- Adição de pontos axiais ao planejamento fatorial

# Planejamento Composto Central

- O planejamento composto central (CCD) consiste de três componentes:
  - **Planejamento básico 1** (cubo ou kernel): Planejamento fatorial completo com dois níveis para cada fator ou quando existir um grande número de fatores, um planejamento fatorial fracionário ($2^{k-p}$) com $n_k$ replicatas;
  - **Planejamento básico 2** (estrela): com os níveis $+\alpha$ e $-\alpha$ para os *p* fatores correspondentes e zero para os demais (número de replicatas = $n_s$, distância ao centro = $\alpha$);
  - **Planejamento básico 3** (centro): todos os fatores com nível igual a zero replicado $n_c$ vezes.
  - Total de ensaios = $2^{p-k}.n_k + 2p.n_s + n_c$.

# CCD com dois fatores (esquerda) e três fatores (direita)

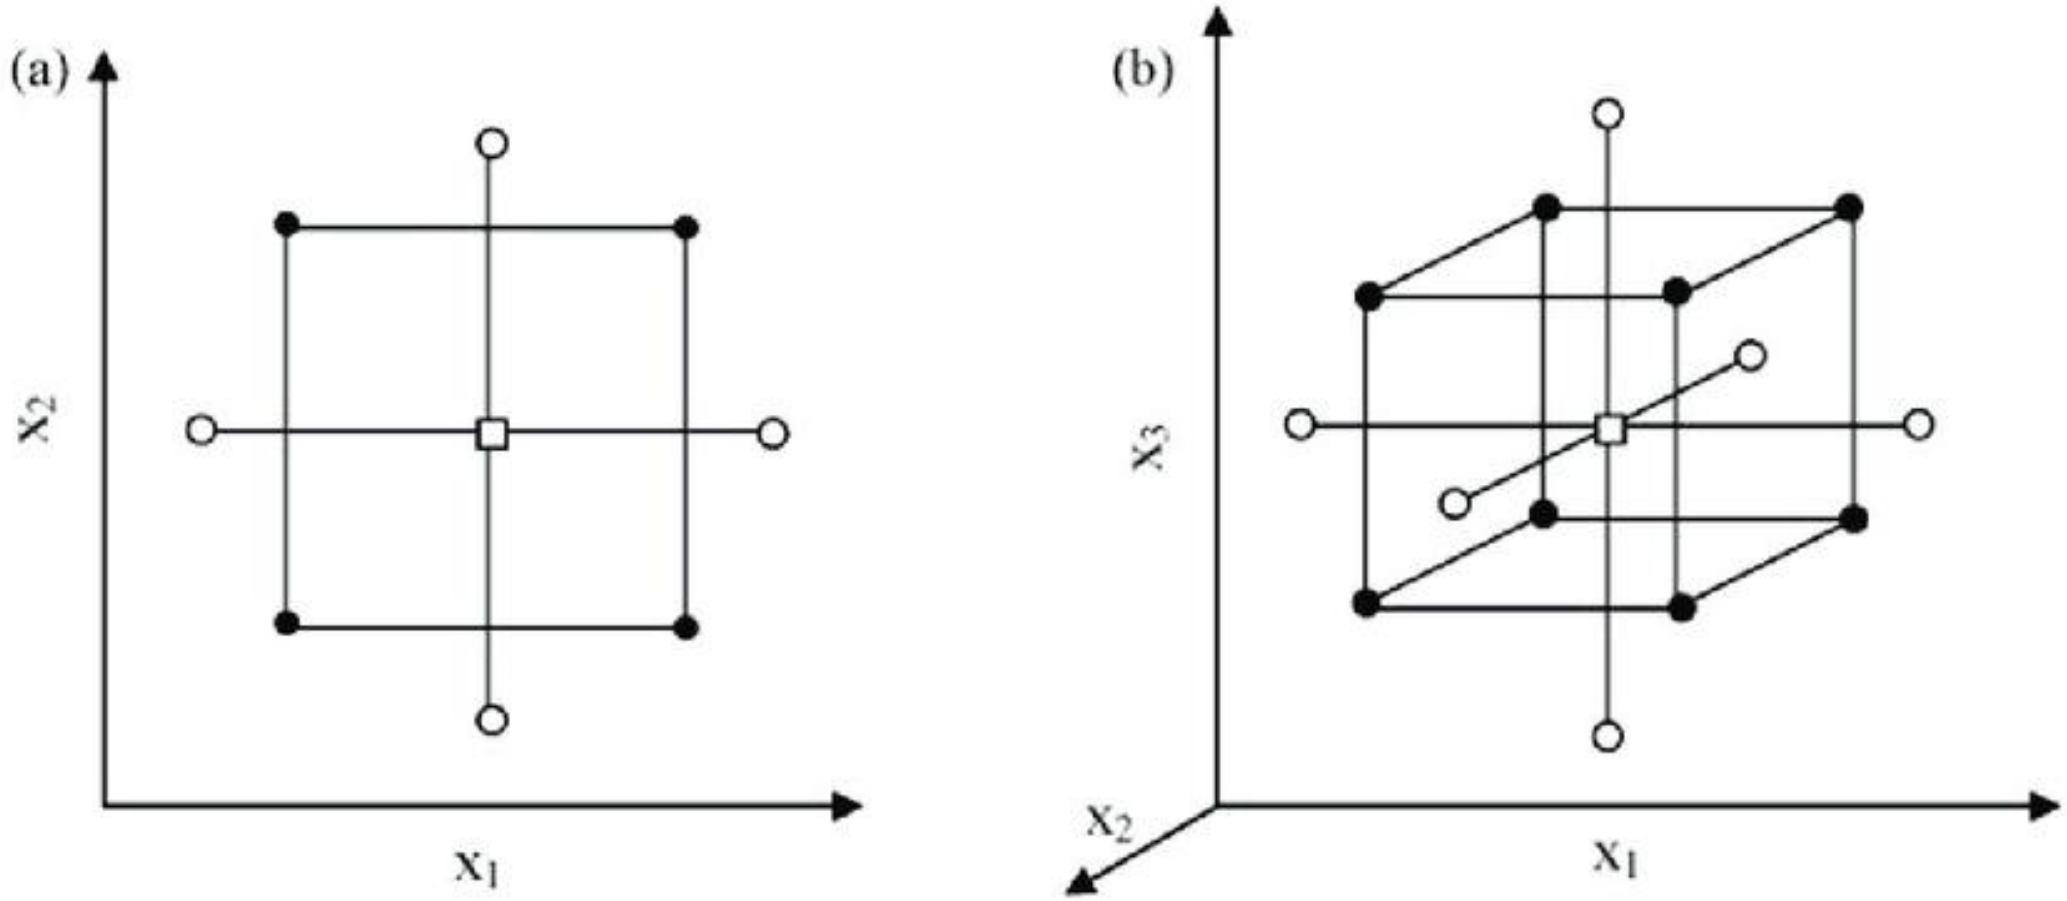

# Planejamento CCD para três fatores

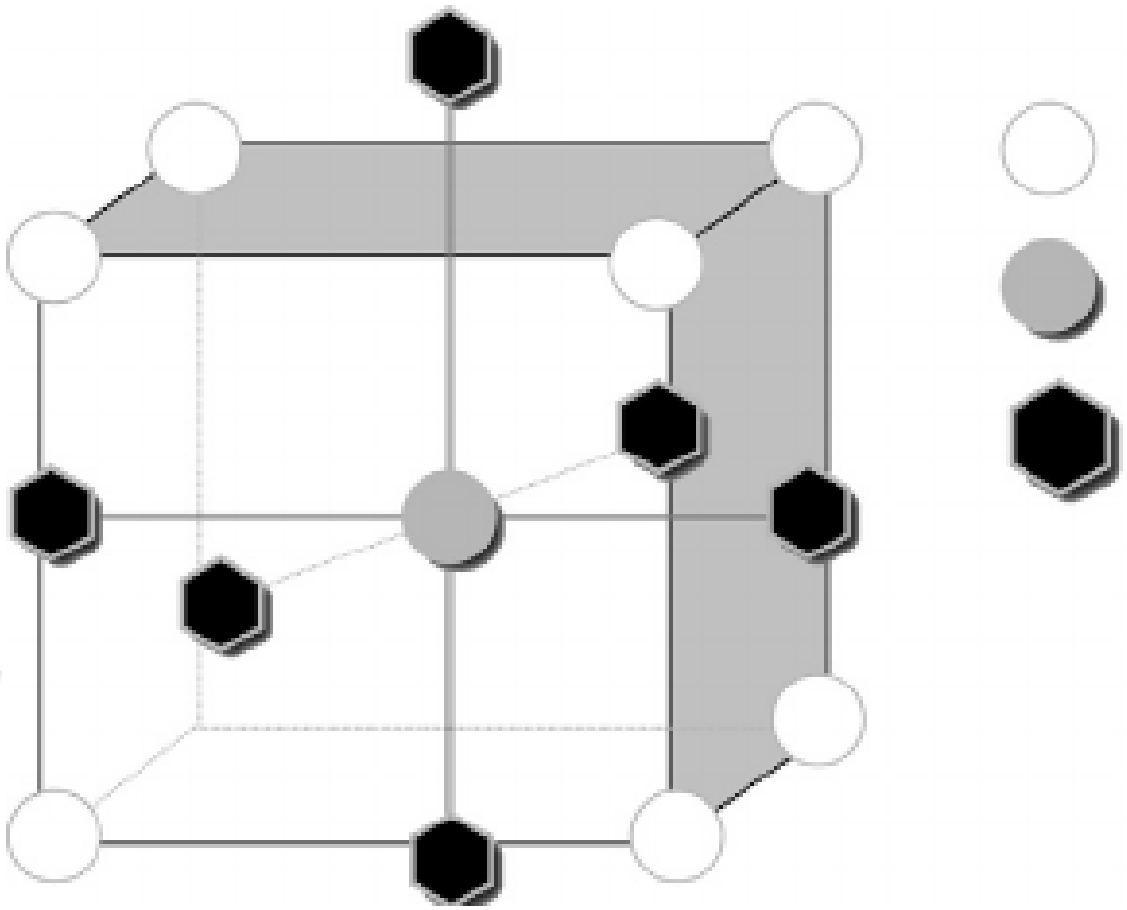

Cubo ou kernel

Centro

Estrela

# A variância dos valores preditos

- Com a inclusão de seis réplicas no ponto central, o planejamento tem precisão uniforme e a variância dos valores preditos será a mesma que na origem (0,0,0) e em qualquer ponto no raio igual a 1 nos níveis codificados dos fatores.
- # **Comandos no R**

```
library("rsm")
library("Vdgraph")
rotd<-ccd(3,n0=c(2,4),alpha="rotatable",randomize=FALSE)
rotdm<-rotd[,3:5]
Vdgraph(rotdm)
```

# Dispersão da Variância para a Precisão Uniforme de um CCD com três fatores

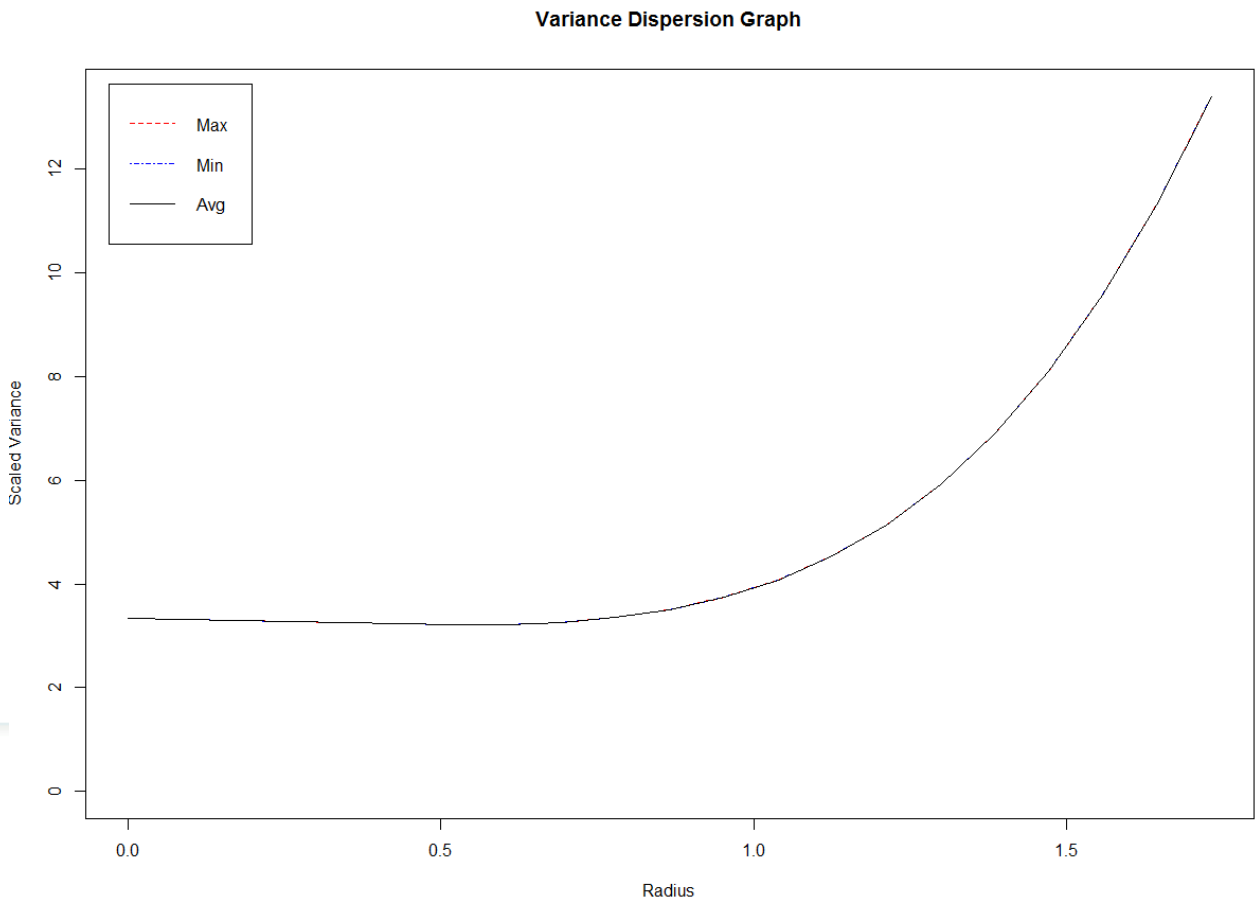

# Matriz dos coeficientes do planejamento composto central padrão com três fatores

| I | $x_1$ | $x_2$ | $x_3$ | $x_1x_2$ | $x_1x_3$ | $x_2x_3$ | $x_1^2$ | $x_2^2$ | $x_3^2$ | Componente | Número de replicatas |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | Cubo ou kernel | $n_k$ |
| 1 | 1 | 1 | -1 | 1 | -1 | -1 | 1 | 1 | 1 | | |
| 1 | 1 | -1 | 1 | -1 | 1 | -1 | 1 | 1 | 1 | | |
| 1 | 1 | -1 | -1 | -1 | -1 | 1 | 1 | 1 | 1 | | |
| 1 | -1 | 1 | 1 | -1 | -1 | 1 | 1 | 1 | 1 | | |
| 1 | -1 | 1 | -1 | -1 | 1 | -1 | 1 | 1 | 1 | | |
| 1 | -1 | -1 | 1 | 1 | -1 | -1 | 1 | 1 | 1 | | |
| 1 | -1 | -1 | -1 | 1 | 1 | 1 | 1 | 1 | 1 | | |

# Matriz dos coeficientes do planejamento composto central padrão com três fatores

| I | $x_1$ | $x_2$ | $x_3$ | $x_1x_2$ | $x_1x_3$ | $x_2x_3$ | $x_1^2$ | $x_2^2$ | $x_3^2$ | Componente | Número de replicatas |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | $-\alpha$ | 0 | 0 | 0 | 0 | 0 | $\alpha^2$ | 0 | 0 | estrela | $n_S$ |
| 1 | $\alpha$ | 0 | 0 | 0 | 0 | 0 | $\alpha^2$ | 0 | 0 | | |
| 1 | 0 | $-\alpha$ | 0 | 0 | 0 | 0 | 0 | $\alpha^2$ | 0 | | |
| 1 | 0 | $\alpha$ | 0 | 0 | 0 | 0 | 0 | $\alpha^2$ | 0 | | |
| 1 | 0 | 0 | $-\alpha$ | 0 | 0 | 0 | 0 | 0 | $\alpha^2$ | | |
| 1 | 0 | 0 | $\alpha$ | 0 | 0 | 0 | 0 | 0 | $\alpha^2$ | | |
| 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | centro | $n_C$ |

# Planejamento composto central

- Rotacional: $\alpha = \pm\sqrt[4]{2^k}$
- Esférico: $\alpha = \pm\sqrt{k}$

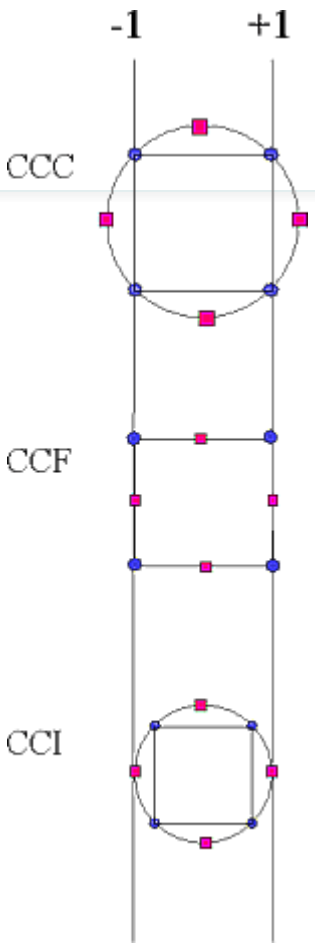


circunscrito

face centrada

inscrito

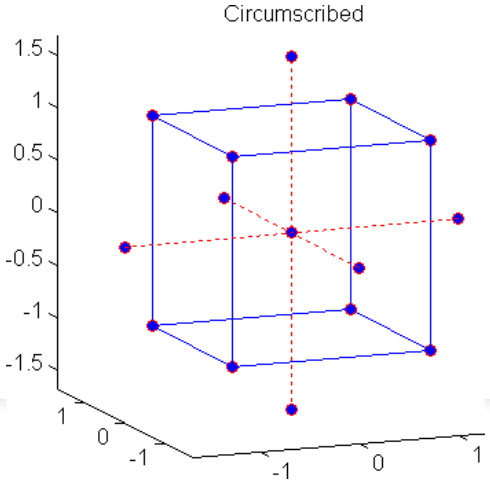


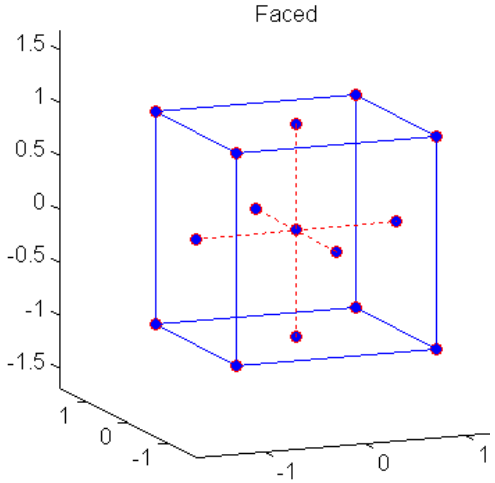


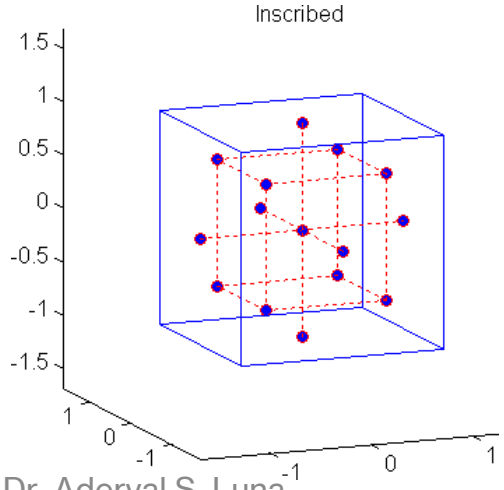

- **Outros planejamento**
  - *Planejamento Equiradial*

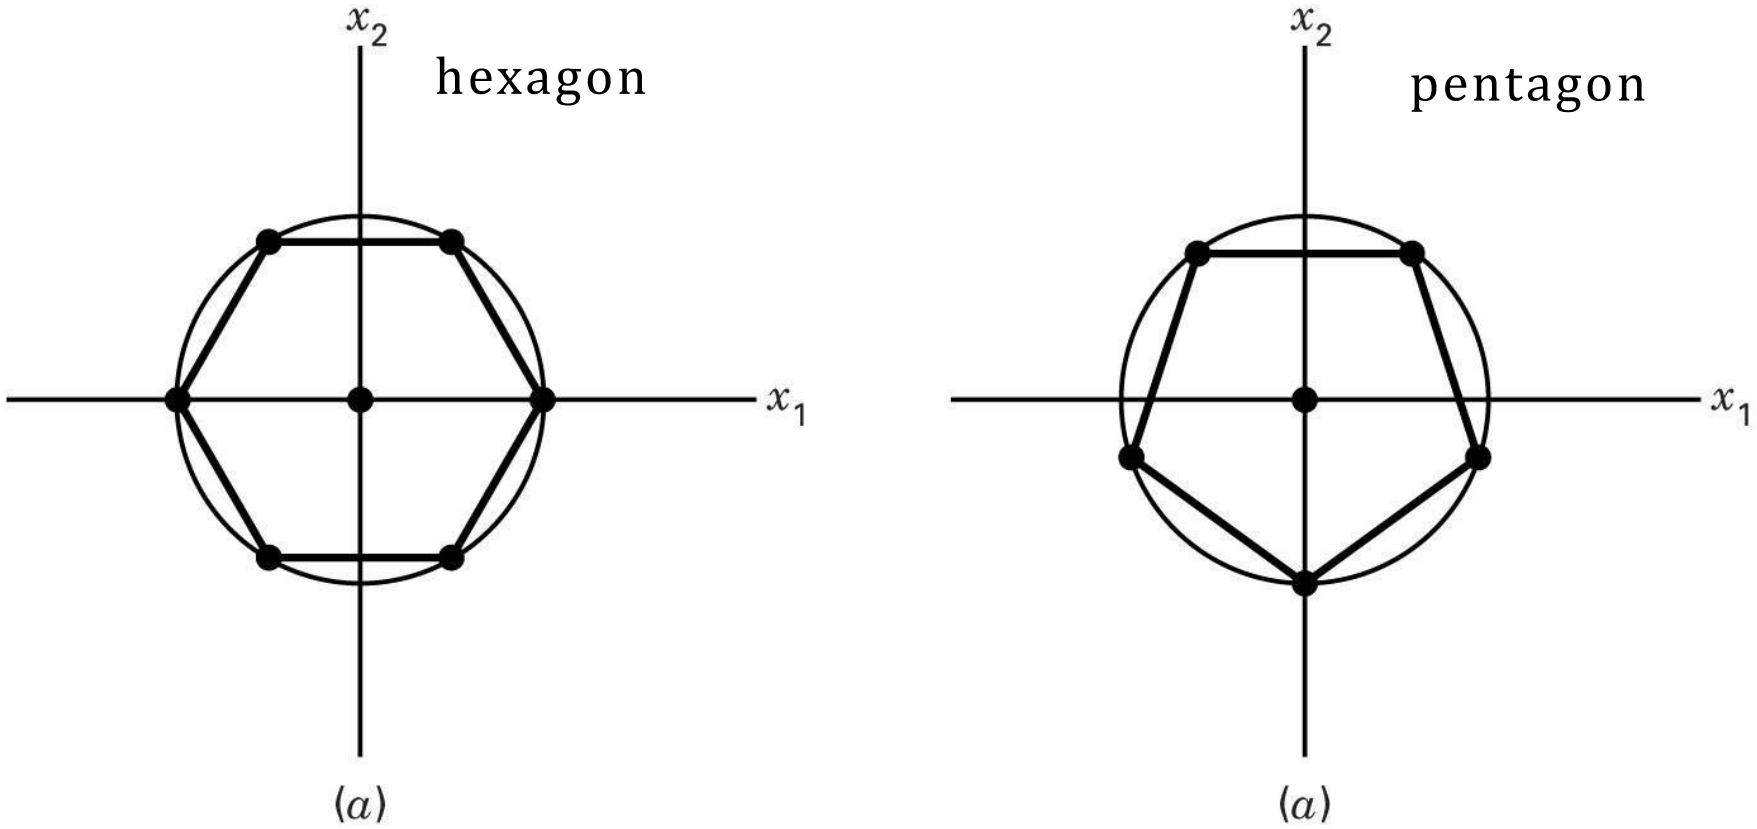


Figure 11.25
© John Wiley & Sons, Inc. All rights reserved.

# Planejamento composto central

- Planejamento rotacionável: o valor de $\alpha$ deve ser escolhido de forma que a variância do estimador E(y) dos pontos equidistantes ao ponto central seja constante.
- O valor de $\alpha$ para um planejamento rotacionável onde o cubo ou kernel tem uma resolução R > IV:
- $\alpha = \sqrt[4]{\frac{n_k}{n_s} 2^{p-k}} = \alpha_R$

# Planejamento composto central

- Planejamento ortogonal: As colunas da matriz **X** em E(**y**)=**XB** são ortogonais, se o cubo ou kernel tem uma resolução R > IV, o valor de $\alpha$ é:
- $\alpha = \frac{1}{\sqrt{2n_s}}\sqrt{\sqrt{n.n_k.2^{p-k}} - n_k.2^{k-1}} = \alpha_0$
- **Planejamento ortogonal e rotacionável:**
- $\alpha = \alpha_R$
- $n_c = 4\sqrt{n_k.n_s.2^{p-k}} + 2n_s(2-p)$

# Planejamento Rotacionável

- $V[\hat{y}(x)]$ é constante para todos os pontos de $\mathbf{x}$ que estão à uma mesma distância do centro do planejamento
- $\mathbf{V[\hat{y}(x)] = \sigma^2 x^t (X^t X)^{-1} x}$

- $\alpha = (n_f)^{1/4}$ , onde $n_f$ é o número de pontos usado na parte fatorial do planejamento.

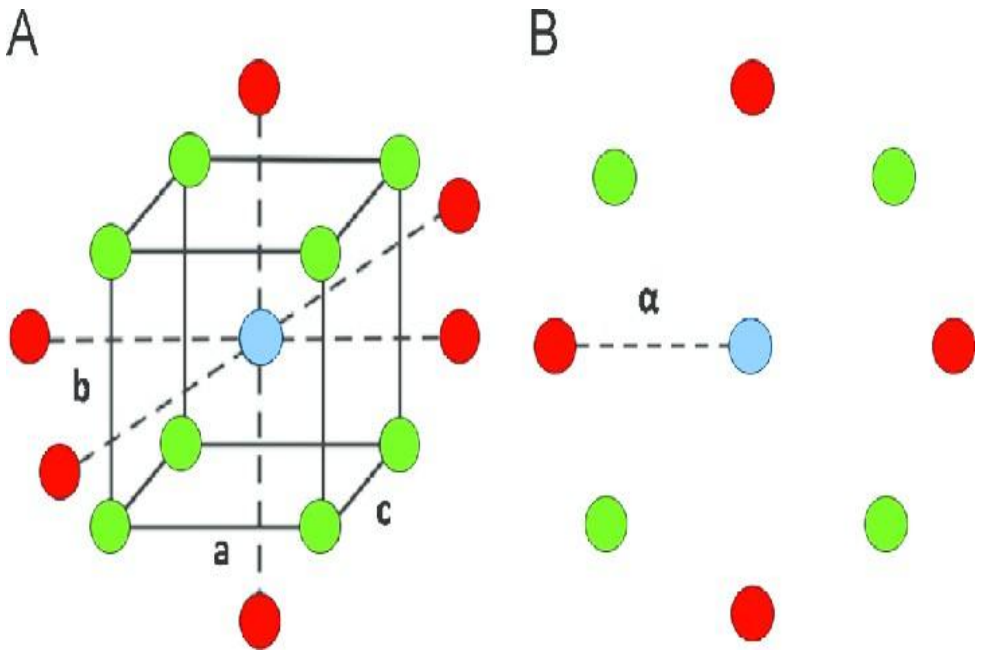

# Exemplo

- Foi investigado o tempo t (min) e a temperatura T ($^0$C) de um processo químico para maximizar a resposta ou saída do sistema, y (g).
- $x_1 = \frac{t-90}{10}$
- $x_2 = \frac{T-145}{5}$
- Planejamento básico 1 (cubo ou kernel): $2^2$
- Planejamento básico 2 (estrela): 4 pontos
- Planejamento básico (centro): 4 replicatas ($n_c = 4$)
- Total de ensaios = $2^2 + 4 + 4 = 12$

# Resolução do exemplo

- Planejamento básico 1 (cubo ou kernel): $2^2$ (uma réplica)
- Planejamento básico 2 (estrela): 4 pontos (uma réplica)
- Planejamento básico (centro): 4 replicatas ($n_c = 4$)
- Total de ensaios = $2^2 + 4 + 4 = 12$
- Este planejamento tem precisao uniforme?
- Para que seja obtido a precisao uniforme é preciso que o número de replicatas no centro seja igual a:
- $n_c = 4\sqrt{n_k . n_s . 2^{p-k}} + 2n_s(2 - p)$
- $n_c = 4.\sqrt{1.1.2^2} + 2.1.0 = 8$

# Parâmetros do planejamento de segunda ordem ortogonais e rotacionáveis com menor dimensão

| p | $2^p$ | p - k | $n_k$ | $n_s$ | $n_c$ | n | $\alpha$ |
|---|---|---|---|---|---|---|---|
| 2 | 4 | 2 | 1 | 1 | 8 | 16 | $\sqrt{2}$ |
| 3 | 8 | 3 | 1 | 2 | 12 | 32 | $\sqrt{2}$ |
| 4 | 16 | 4 | 1 | 1 | 12 | 36 | 2 |
| 5 | 32 | 4 | 1 | 1 | 10 | 36 | 2 |
| 6 | 64 | 5 | 1 | 2 | 16 | 72 | $\sqrt{8}$ |
| 7 | 128 | 6 | 1 | 1 | 22 | 100 | $\sqrt{8}$ |
| 8 | 256 | 6 | 1 | 1 | 20 | 100 | $\sqrt{8}$ |
| 9 | 512 | 7 | 1 | 2 | 36 | 200 | $\sqrt{8}$ |

# Planejamento composto central reduzido

- O planejamento composto central reduzido pode ser usado quando o custo de cada experimento é elevado e o pesquisador está disposto em estabelecer um compromisso entre as propriedades desejáveis de uma superfície de resposta.
- Hartley (1959) mostrou que quando as réplicas do ponto central e os pontos axiais são incluídos, as interações de dois fatores podem ser estimadas com um planejamento fatorial fracionário de resolução III.

## Comparação do CCD com o CCD reduzido (I = AB) para dois fatores

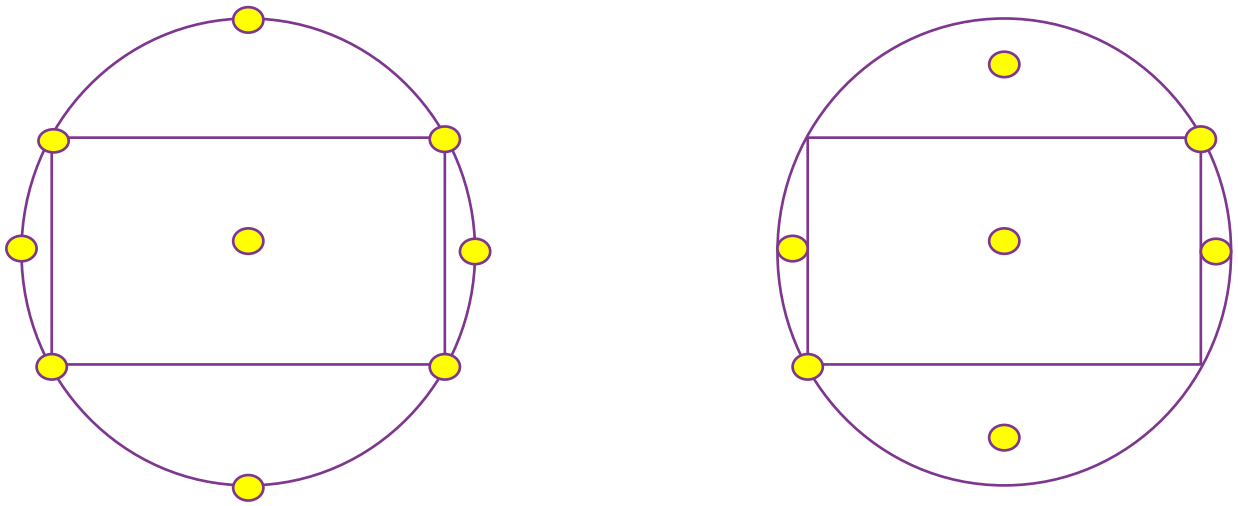

- CCD (13 ensaios com cinco replicatas no ponto central)
- CCD reduzido (7 ensaios)

# Dispersão da Variância para a Precisão Uniforme de um CCD reduzido com dois fatores

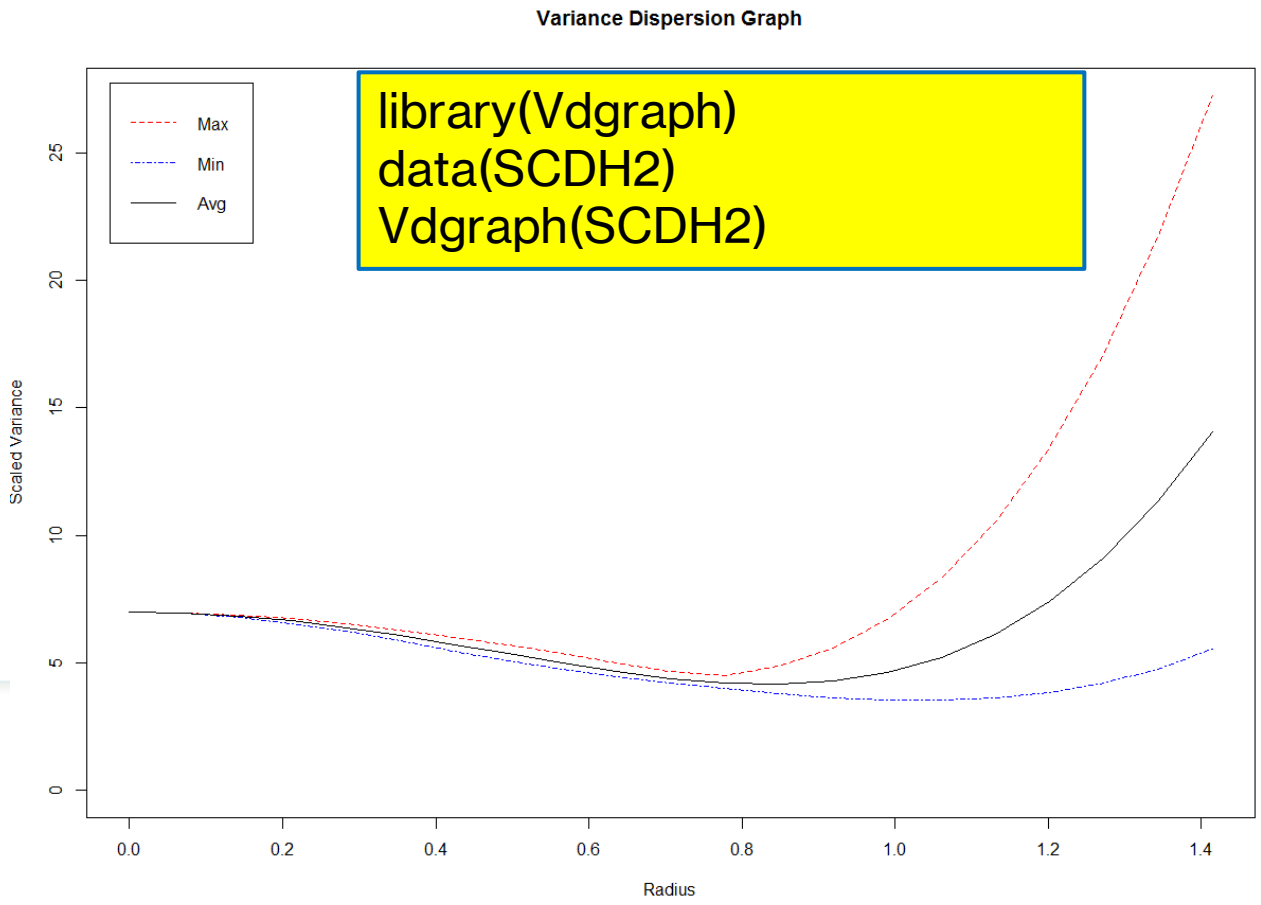

# Exemplo de Planejamento CCD

- Nos últimos anos tem aumentado o interesse no processamento de alimentos a alta pressão, e particularmente no processamento do leite visando à destruição de microrganismo. Neste exemplo estudou-se como a capacidade de retenção de água e a força do gel em um coalho de renina serão afetadas por alta pressão no tratamento do leite.
- Estas características do gel são importantes parâmetros no processamento do queijo, influenciando no rendimento, umidade e textura do produto.

# Exemplo

- Assim, foram avaliados três fatores importantes no processamento do leite: pressão (200 a 400 mPa), temperatura (3 a 21$^0$C) e o tempo (10 a 110 minutos). A tabela abaixo indica os valores naturais e codificados dos parâmetros:

| Fatores | | -1,68 | -1 | 0 | +1 | +1,68 |
|---|---|---|---|---|---|---|
| Pressão (mPa) | X1 | 200 | 240,55 | 300 | 359,45 | 400 |
| Temperatura ($^0$C) | X2 | 3 | 6,65 | 12 | 17,35 | 21 |
| Tempo (min) | x3 | 0 | 30,27 | 60 | 89,73 | 110 |

# Variável de resposta

## y1 = capacidade de retenção de água; y2 = força do gel

| Ensaio | x1 | x2 | x3 | y1 | y2 | Ensaio | x1 | x2 | x3 | y1 | y2 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | -1 | -1 | -1 | 45,9 | 0,55 | 11 | -1,68 | 0 | 0 | 49,9 | 0,44 |
| 2 | +1 | -1 | -1 | 50,8 | 0,41 | 12 | +1,68 | 0 | 0 | 64,7 | 0,34 |
| 3 | -1 | +1 | -1 | 54,8 | 0,50 | 13 | 0 | -1,68 | 0 | 45,2 | 0,49 |
| 4 | +1 | +1 | -1 | 61,3 | 0,40 | 14 | 0 | +1,68 | 0 | 66,5 | 0,40 |
| 5 | -1 | -1 | +1 | 49,4 | 0,49 | 15 | 0 | 0 | -1,68 | 44,3 | 0,50 |
| 6 | +1 | -1 | +1 | 60,4 | 0,41 | 16 | 0 | 0 | +1,68 | 56,9 | 0,42 |
| 7 | -1 | +1 | +1 | 60,4 | 0,40 | 17 | 0 | 0 | 0 | 43,7 | 0,40 |
| 8 | +1 | +1 | +1 | 69,3 | 0,36 | 18 | 0 | 0 | 0 | 44,8 | 0,42 |
| 9 | 0 | 0 | 0 | 44,8 | 0,42 | 19 | 0 | 0 | 0 | 44,3 | 0,41 |
| 10 | 0 | 0 | 0 | 44,4 | 0,41 | 20 | 0 | 0 | 0 | 43,6 | 0,42 |

# Resolução usando o rsm para y1

```
install.packages(rsm)
library(rsm)
# Criação do objeto ccd
model<-ccd(3, n0=c(2,4),alpha="rotatable",randomize=FALSE)
# Visualizar o objeto criado
model
```

| | run.order | std.order | x1.as.is | x2.as.is | x3.as.is | Block |
|---|---|---|---|---|---|---|
| 1 | 1 | 1 | -1.000000 | -1.000000 | -1.000000 | 1 |
| 2 | 2 | 2 | 1.000000 | -1.000000 | -1.000000 | 1 |
| 3 | 3 | 3 | -1.000000 | 1.000000 | -1.000000 | 1 |
| 4 | 4 | 4 | 1.000000 | 1.000000 | -1.000000 | 1 |
| 5 | 5 | 5 | -1.000000 | -1.000000 | 1.000000 | 1 |
| 6 | 6 | 6 | 1.000000 | -1.000000 | 1.000000 | 1 |
| 7 | 7 | 7 | -1.000000 | 1.000000 | 1.000000 | 1 |
| 8 | 8 | 8 | 1.000000 | 1.000000 | 1.000000 | 1 |
| 9 | 9 | 9 | 0.000000 | 0.000000 | 0.000000 | 1 |
| 10 | 10 | 10 | 0.000000 | 0.000000 | 0.000000 | 1 |
| 11 | 1 | 1 | -1.681793 | 0.000000 | 0.000000 | 2 |
| 12 | 2 | 2 | 1.681793 | 0.000000 | 0.000000 | 2 |
| 13 | 3 | 3 | 0.000000 | -1.681793 | 0.000000 | 2 |
| 14 | 4 | 4 | 0.000000 | 1.681793 | 0.000000 | 2 |
| 15 | 5 | 5 | 0.000000 | 0.000000 | -1.681793 | 2 |
| 16 | 6 | 6 | 0.000000 | 0.000000 | 1.681793 | 2 |
| 17 | 7 | 7 | 0.000000 | 0.000000 | 0.000000 | 2 |
| 18 | 8 | 8 | 0.000000 | 0.000000 | 0.000000 | 2 |
| 19 | 9 | 9 | 0.000000 | 0.000000 | 0.000000 | 2 |
| 20 | 10 | 10 | 0.000000 | 0.000000 | 0.000000 | 2 |

# Continuação

```
# Extraindo as colunas 3, 4 e 5 do objeto model
model_ext<-model[,3:5]
# Visualizando o objeto extraído
model_ext
```

| | x1.as.is | x2.as.is | x3.as.is |
|---|---|---|---|
| 1 | -1.000000 | -1.000000 | -1.000000 |
| 2 | 1.000000 | -1.000000 | -1.000000 |
| 3 | -1.000000 | 1.000000 | -1.000000 |
| 4 | 1.000000 | 1.000000 | -1.000000 |
| 5 | -1.000000 | -1.000000 | 1.000000 |
| 6 | 1.000000 | -1.000000 | 1.000000 |
| 7 | -1.000000 | 1.000000 | 1.000000 |
| 8 | 1.000000 | 1.000000 | 1.000000 |
| 9 | 0.000000 | 0.000000 | 0.000000 |
| 10 | 0.000000 | 0.000000 | 0.000000 |
| 11 | -1.681793 | 0.000000 | 0.000000 |
| 12 | 1.681793 | 0.000000 | 0.000000 |
| 13 | 0.000000 | -1.681793 | 0.000000 |
| 14 | 0.000000 | 1.681793 | 0.000000 |
| 15 | 0.000000 | 0.000000 | -1.681793 |
| 16 | 0.000000 | 0.000000 | 1.681793 |
| 17 | 0.000000 | 0.000000 | 0.000000 |
| 18 | 0.000000 | 0.000000 | 0.000000 |
| 19 | 0.000000 | 0.000000 | 0.000000 |
| 20 | 0.000000 | 0.000000 | 0.000000 |

# Continuação

```
# Criação do vetor de dados para y1
y1<-c(45.9, 50.8, 54.8, 61.3, 49.4, 60.4, 60.4, 69.3, 44.8, 44.4, 49.9,
64.7, 45.2, 66.5, 44.3, 56.9, 43.7, 44.8, 44.3, 43.6)
# Verificar o comprimento do objeto
length(y1)
```

```
[1] 20
```

# Continuação

```
# Adicionar o vetor de dados de y1 no objeto criado model_ext
model_ext<-cbind(model_ext,y1)
# Visualizar o novo objeto
model_ext
```

| | x1 | x2 | x3 | y1 |
|---|---|---|---|---|
| 1 | -1.000000 | -1.000000 | -1.000000 | 45.9 |
| 2 | 1.000000 | -1.000000 | -1.000000 | 50.8 |
| 3 | -1.000000 | 1.000000 | -1.000000 | 54.8 |
| 4 | 1.000000 | 1.000000 | -1.000000 | 61.3 |
| 5 | -1.000000 | -1.000000 | 1.000000 | 49.4 |
| 6 | 1.000000 | -1.000000 | 1.000000 | 60.4 |
| 7 | -1.000000 | 1.000000 | 1.000000 | 60.4 |
| 8 | 1.000000 | 1.000000 | 1.000000 | 69.3 |
| 9 | 0.000000 | 0.000000 | 0.000000 | 44.8 |
| 10 | 0.000000 | 0.000000 | 0.000000 | 44.4 |
| 11 | -1.681793 | 0.000000 | 0.000000 | 49.9 |
| 12 | 1.681793 | 0.000000 | 0.000000 | 64.7 |
| 13 | 0.000000 | -1.681793 | 0.000000 | 45.2 |
| 14 | 0.000000 | 1.681793 | 0.000000 | 66.5 |
| 15 | 0.000000 | 0.000000 | -1.681793 | 44.3 |
| 16 | 0.000000 | 0.000000 | 1.681793 | 56.9 |
| 17 | 0.000000 | 0.000000 | 0.000000 | 43.7 |
| 18 | 0.000000 | 0.000000 | 0.000000 | 44.8 |
| 19 | 0.000000 | 0.000000 | 0.000000 | 44.3 |
| 20 | 0.000000 | 0.000000 | 0.000000 | 43.6 |

# Continuação

```
# Criação do modelo estatístico usando o pacote rsm
model_est<-rsm(y1~FO(x1,x2,x3),data=model_ext,subset=1:10)
summary(model_est)
```

```
Call:
rsm(formula = y1 ~ FO(x1, x2, x3), data = model_ext, subset = 1:10)

            Estimate Std. Error t value  Pr(>|t|)
(Intercept)  54.1500     1.9954 27.1378 1.654e-07 ***
x1            3.9125     2.2309  1.7538   0.13001
x2            4.9125     2.2309  2.2020   0.06991 .
x3            3.3375     2.2309  1.4960   0.18528
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.6288,    Adjusted R-squared:  0.4432
F-statistic: 3.388 on 3 and 6 DF,  p-value: 0.09495

Analysis of Variance Table

Response: y1
               Df Sum Sq Mean Sq  F value  Pr(>F)
FO(x1, x2, x3)  3 404.63 134.878   3.3876 0.09495
Residuals       6 238.89  39.815
Lack of fit     5 238.81  47.762 597.0281 0.03106
Pure error      1   0.08   0.080
```

# Continuação

```
# Criação do modelo estatístico com adição dos termos de interação
model_est_int<-rsm(y1~FO(x1,x2,x3)+TWI(x1,x2,x3),data=model_ext)
summary(model_est_int)
```

```
Call:
rsm(formula = y1 ~ FO(x1, x2, x3) + TWI(x1, x2, x3), data = model_ext)

            Estimate Std. Error t value  Pr(>|t|)
(Intercept)  52.2700     1.5478 33.7696 4.748e-14 ***
x1            4.1145     1.8731  2.1966   0.04679 *
x2            5.5007     1.8731  2.9366   0.01156 *
x3            3.5067     1.8731  1.8721   0.08386 .
x1:x2        -0.0625     2.4474 -0.0255   0.98001
x1:x3         1.0625     2.4474  0.4341   0.67130
x2:x3         0.0625     2.4474  0.0255   0.98001
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.5687,    Adjusted R-squared:  0.3697
F-statistic: 2.857 on 6 and 13 DF,  p-value: 0.05316

Analysis of Variance Table

Response: y1
                Df Sum Sq Mean Sq  F value    Pr(>F)
FO(x1, x2, x3)   3 812.36 270.785   5.6512   0.01056
TWI(x1, x2, x3)  3   9.09   3.031   0.0633   0.97832
Residuals       13 622.91  47.916
Lack of fit      8 621.56  77.695 287.0500 3.162e-06
Pure error       5   1.35   0.271
```

```
Stationary point of response surface:
        x1          x2          x3
  40.41913 -743.23250  -47.59199

Eigenanalysis:
eigen() decomposition
$values
[1]  0.531250000  0.003651374 -0.534901374

$vectors
            [,1]       [,2]       [,3]
x1  7.071068e-01 -0.0582236 -0.7047056
x2 -4.440892e-16  0.9966042 -0.0823406
x3  7.071068e-01  0.0582236  0.7047056
```

# Continuação

```
# Criando o modelo de segunda ordem
model_est_2nd_order<-
rsm(y1~FO(x1,x2,x3)+SO(x1,x2,x3),data=model_ext)
summary(model_est_2nd_order)
```

```
Call:
rsm(formula = y1 ~ FO(x1, x2, x3) + SO(x1, x2, x3), data = model_ext)

            Estimate Std. Error t value  Pr(>|t|)
(Intercept) 44.22378    0.52741 83.8500 1.423e-15 ***
x1           4.11446    0.34993 11.7580 3.537e-07 ***
x2           5.50070    0.34993 15.7195 2.227e-08 ***
x3           3.50671    0.34993 10.0212 1.559e-06 ***
x1:x2       -0.06250    0.45720 -0.1367   0.89398
x1:x3        1.06250    0.45720  2.3239   0.04249 *
x2:x3        0.06250    0.45720  0.1367   0.89398
x1^2         4.88829    0.34064 14.3501 5.347e-08 ***
x2^2         4.37564    0.34064 12.8452 1.537e-07 ***
x3^2         2.51949    0.34064  7.3962 2.325e-05 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.9884,    Adjusted R-squared:  0.978
F-statistic: 94.86 on 9 and 10 DF,  p-value: 1.719e-08
```

```
Analysis of Variance Table

Response: y1
                 Df Sum Sq Mean Sq  F value    Pr(>F)
FO(x1, x2, x3)    3 812.36 270.785 161.9263 8.961e-09
TWI(x1, x2, x3)   3   9.09   3.031   1.8127  0.208473
PQ(x1, x2, x3)    3 606.19 202.063 120.8313 3.732e-08
Residuals        10  16.72   1.672
Lack of fit       5  15.37   3.074  11.3567  0.009258
Pure error        5   1.35   0.271

Stationary point of response surface:
        x1         x2         x3
-0.3582786 -0.6267423 -0.6125980

Eigenanalysis:
eigen() decomposition
$values
[1] 5.002901 4.375420 2.405101

$vectors
          [,1]       [,2]        [,3]
x1  0.97725694 0.03351355 -0.20939370
x2 -0.03829579 0.99908911 -0.01882485
x3  0.20857208 0.02641561  0.97765020
```

# Continuação

```
# Ajustando o modelo de segunda ordem
model_est_2nd_order_1<-rsm(y1~FO(x1,x2,x3)+SO(x1,x2,x3)-TWI(x1,x2,x3),data=model_ext)
summary(model_est_2nd_order_1)
```

```
Call:
rsm(formula = y1 ~ FO(x1, x2, x3) + SO(x1, x2, x3) - TWI(x1,
    x2, x3), data = model_ext)

            Estimate Std. Error t value  Pr(>|t|)
(Intercept) 44.22378    0.57475 76.9450 < 2.2e-16 ***
x1           4.11446    0.38133 10.7897 7.398e-08 ***
x2           5.50069    0.38133 14.4250 2.234e-09 ***
x3           3.50671    0.38133  9.1960 4.715e-07 ***
x1^2         4.88829    0.37122 13.1684 6.805e-09 ***
x2^2         4.37564    0.37122 11.7873 2.589e-08 ***
x3^2         2.51949    0.37122  6.7871 1.287e-05 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.9821,    Adjusted R-squared:  0.9739
F-statistic: 119.1 on 6 and 13 DF,  p-value: 1.347e-10
```

```
Analysis of Variance Table

Response: y1
               Df Sum Sq Mean Sq F value    Pr(>F)
FO(x1, x2, x3)  3 812.36 270.785 136.355 4.493e-10
PQ(x1, x2, x3)  3 606.19 202.063 101.750 2.803e-09
Residuals      13  25.82   1.986
Lack of fit     8  24.46   3.058  11.298  0.008104
Pure error      5   1.35   0.271

Stationary point of response surface:
        x1         x2         x3
-0.4208479 -0.6285586 -0.6959170

Eigenanalysis:
eigen() decomposition
$values
[1] 4.888294 4.375642 2.519487

$vectors
   [,1] [,2] [,3]
x1    1    0    0
x2    0    1    0
x3    0    0    1
```

# Continuação

```
# Valores preditos pelo modelo
pred<-predict(model_est_2nd_order_1)
# Modelo estatístico usando o pacote olsrr
install.packages(olsrr)
library(olsrr)
model_lm<-ols_regress(pred~model_ext$y1,data=model_ext)
model_lm
```

Model Summary

| | | | |
|---|---|---|---|
| R | 0.991 | RMSE | 1.187 |
| R-Squared | 0.982 | Coef. Var | 2.271 |
| Adj. R-Squared | 0.981 | MSE | 1.409 |
| Pred R-Squared | 0.979 | MAE | 0.847 |

RMSE: Root Mean Square Error
MSE: Mean Square Error
MAE: Mean Absolute Error

ANOVA

| | Sum of Squares | DF | Mean Square | F | Sig. |
|---|---|---|---|---|---|
| Regression | 1393.190 | 1 | 1393.190 | 989.05 | 0.0000 |
| Residual | 25.355 | 18 | 1.409 | | |
| Total | 1418.545 | 19 | | | |

ANOVA

| | Sum of Squares | DF | Mean Square | F | Sig. |
|---|---|---|---|---|---|
| Regression | 1393.190 | 1 | 1393.190 | 989.05 | 0.0000 |
| Residual | 25.355 | 18 | 1.409 | | |
| Total | 1418.545 | 19 | | | |

Parameter Estimates

| model | Beta | Std. Error | Std. Beta | t | Sig | lower | upper |
|---|---|---|---|---|---|---|---|
| (Intercept) | 0.934 | 1.654 | | 0.565 | 0.579 | -2.540 | 4.409 |
| model_ext$y1 | 0.982 | 0.031 | 0.991 | 31.449 | 0.000 | 0.917 | 1.048 |

# Continuação

```
# Gráfico Valores preditos versus Valores observados
par(mfrow=c(1,1))
plot(model_ext$y1, pred)
model_lm<-lm(pred~model_ext$y1)
# Inserção da reta de regressão
abline(model_lm)
```

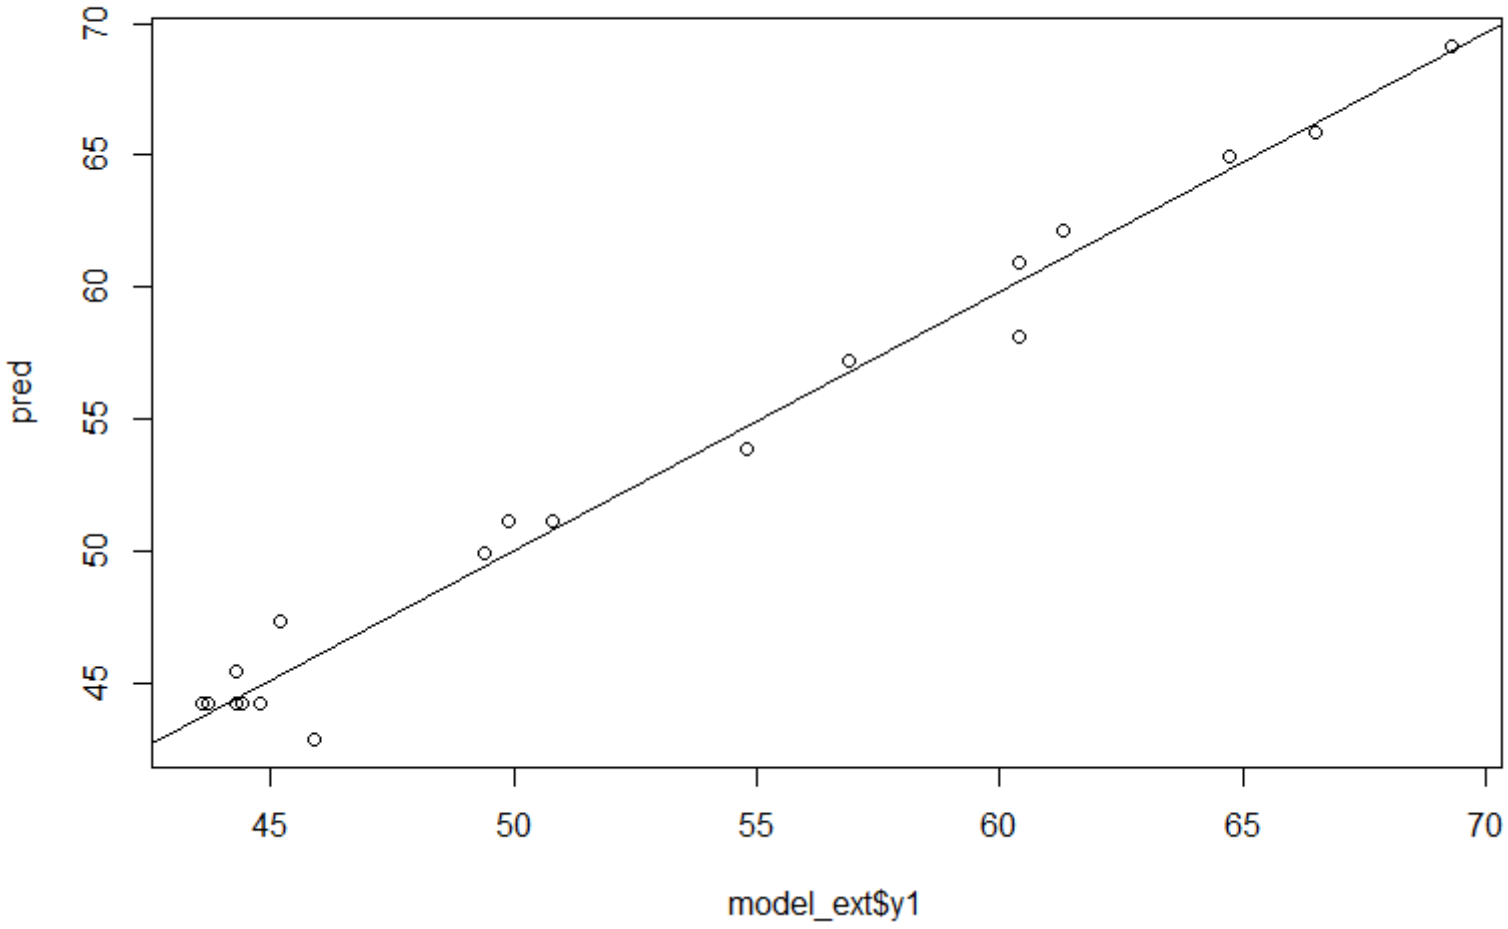
pred
70
65
60
55
50
45
45
50
55
60
65
70
model_ext$y1

# Continuação

```
# Valores dos resíduos do modelo
rs<-rstudent(model_lm)
plot(model_ext$y1,rs)
abline(h=0, col="red")
```

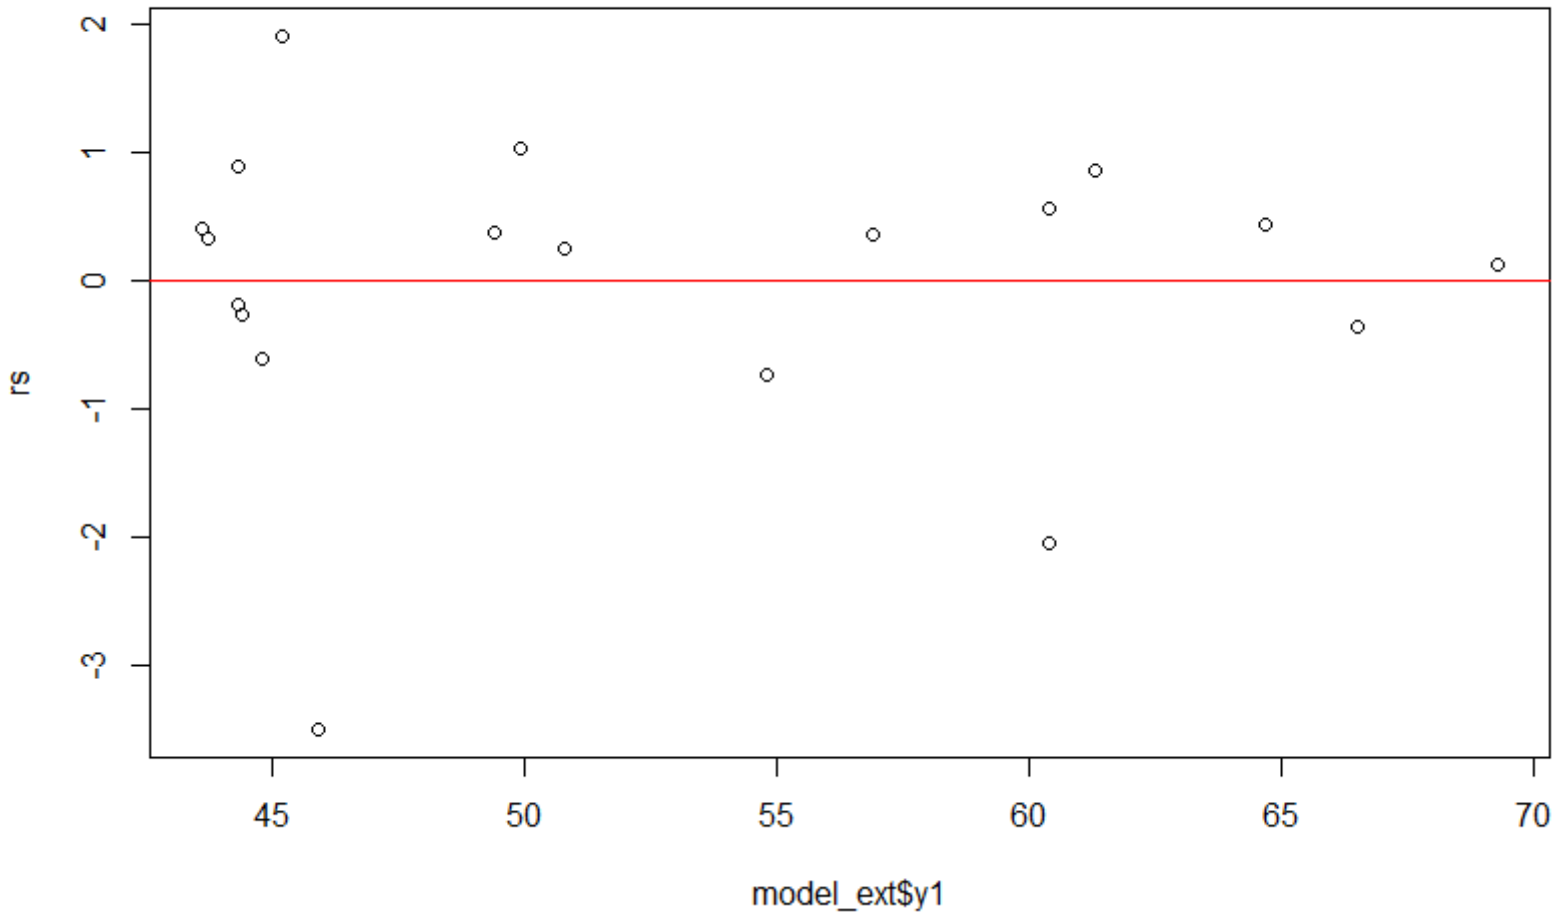
rs
2
1
0
-1
-2
-3
45
50
55
60
65
70
model_ext$y1

# Continuação

```
# Valores de leverage ou influência
hat_values<-hatvalues(model_lm)
h_crit<-3*2/length(y1)
h_crit
plot(hat_values,rs, xlim=c(0,1),ylim=c(-4,4))
abline(v=h_crit, col="red")
abline(h=-2, col="red")
abline(h=2, col="red")
```

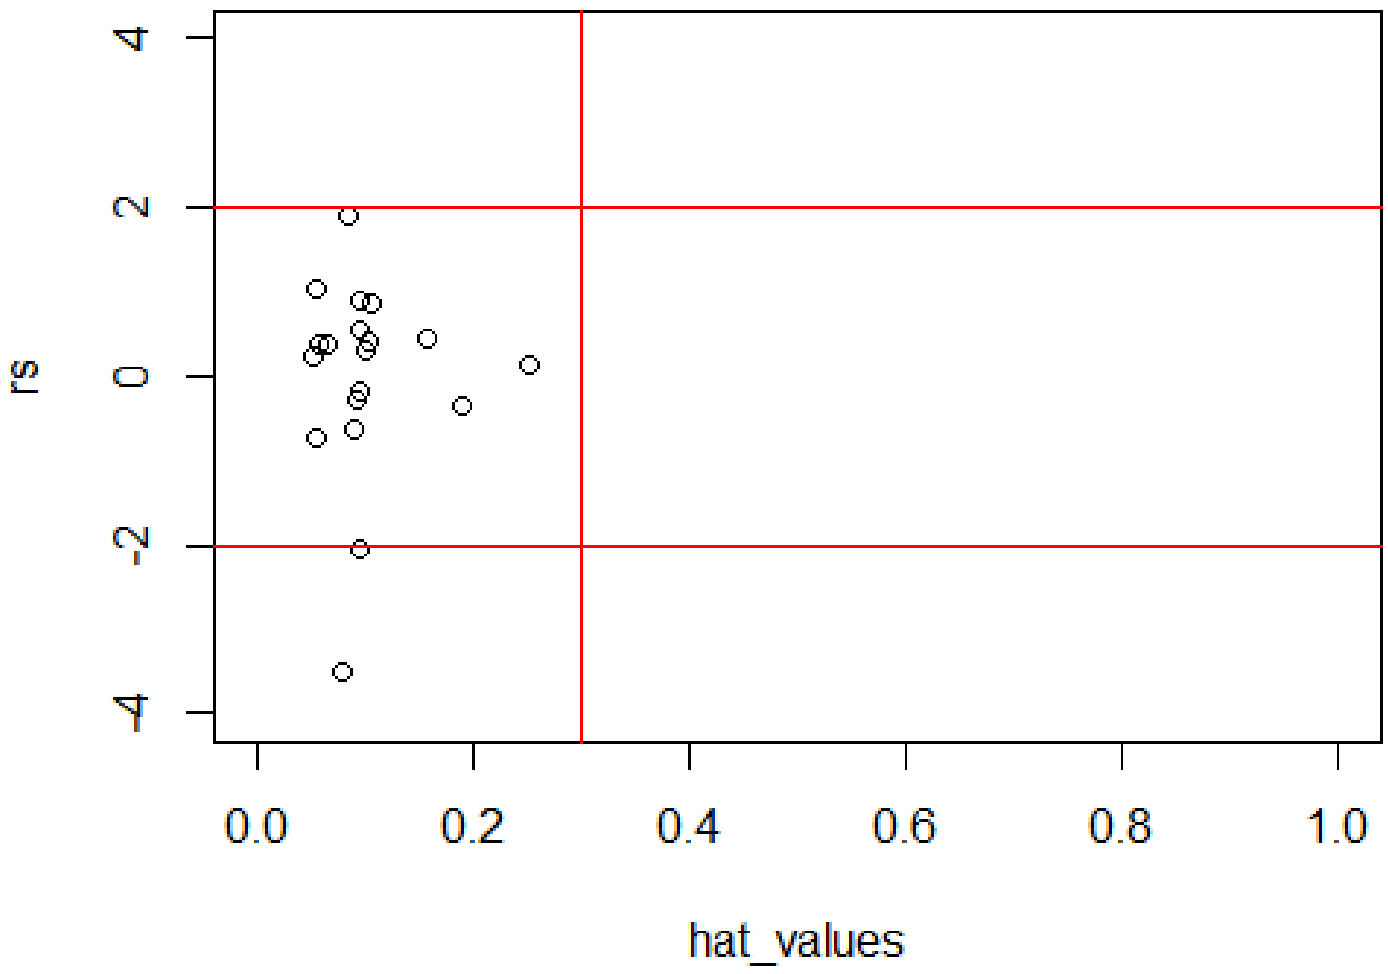
rs
4
2
0
-2
-4
0.0
0.2
0.4
0.6
0.8
1.0
hat_values

# Continuação

```
# Avaliação dos resíduos
par(mfrow=c(1,3))
hist(rs); boxplot(rs);qqnorm(rs);qqline(rs)
```

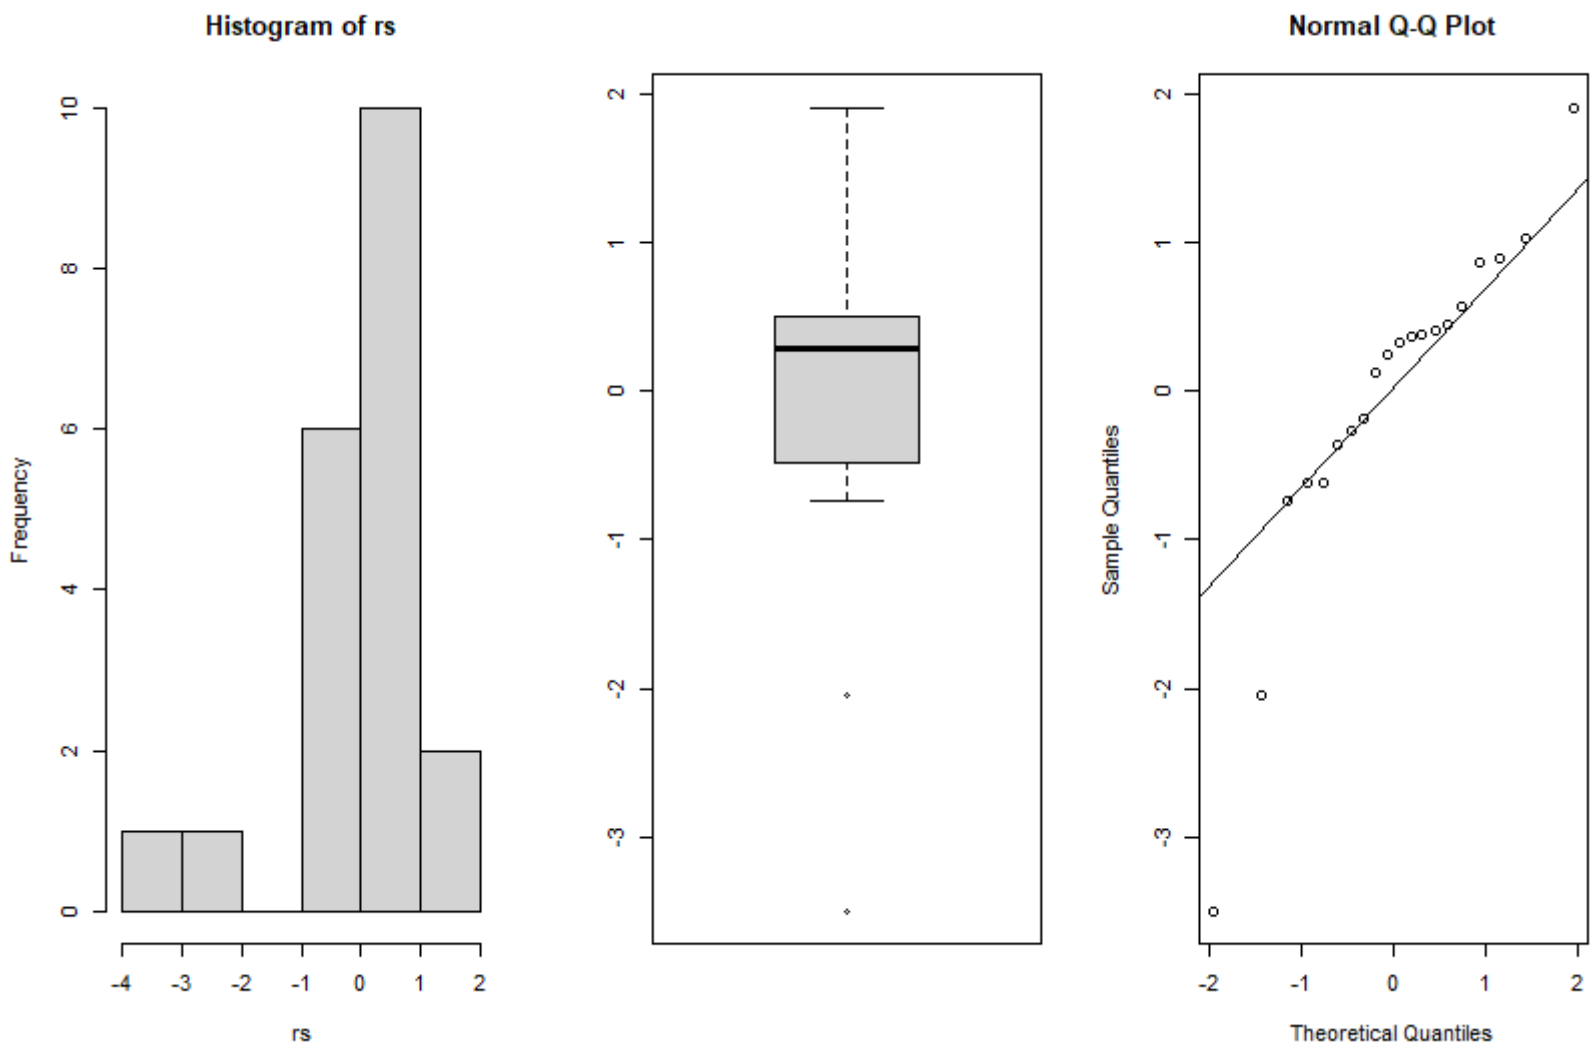
Histogram of rs
Frequency
0
2
4
6
8
10
-4
-3
-2
-1
0
1
2
rs
2
1
0
-1
-2
-3
Normal Q-Q Plot
Sample Quantiles
Theoretical Quantiles

# Continuação

# Teste de normalidade dos resíduos

shapiro.test(rs)

```
        Shapiro-Wilk normality test

data:  rs
W = 0.8729, p-value = 0.01322
```

# Continuação

# Teste de homogeneidade da variância
ols_test_breusch_pagan(model_lm)

```
Breusch Pagan Test for Heteroskedasticity
-----------------------------------------
Ho: the variance is constant
Ha: the variance is not constant

             Data
--------------------------------
Response : pred
Variables: fitted values of pred

       Test Summary
----------------------------
DF            =    1
Chi2          =    0.7280793
Prob > Chi2   =    0.3935065
>
```

# Continuação

```
# Teste de autocorrelação dos resíduos
install.packages(car)
library(car)
durbinWatsonTest(model_lm)
```

```
lag Autocorrelation D-W Statistic p-value
  1       -0.129397      1.864103   0.776
Alternative hypothesis: rho != 0
```

# Planejamento e Otimização de Experimentos (DoE)

~~Planejamento Composto Central~~

Planejamento Híbrido

Planejamentos Ótimos

Planejamento Box-Behnken (BBD)

Planejamento Doehlert

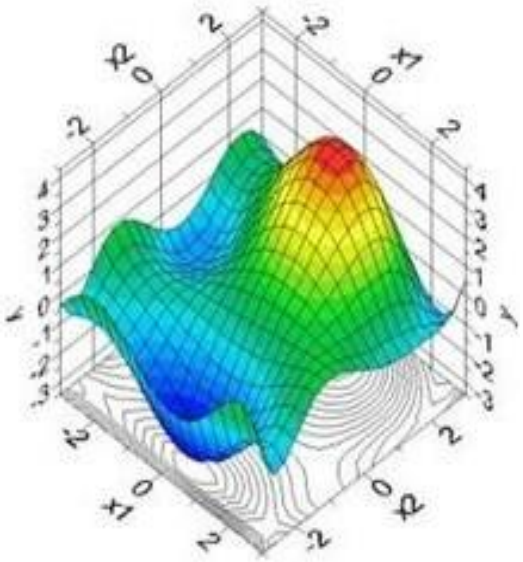

# Planejamento Híbrido

- Roquemore (1970) desenvolveu planejamentos híbridos que requerem mais alguns ensaios do que no planejamento CCD reduzido.
- Estes planejamentos são construídos fazendo-se um planejamento composto central com *k-1* fatores e adicionando-se o *k-ésimo* fator de forma que $\mathbf{X}^t\mathbf{X}$ tenha certas propriedades e o planejamento seja praticamente rotacionável.

- <u>Modelo fora do padrão</u>

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2 + \beta_{112} x_1^2 x_2 + \beta_{1112} x_3^2 x_2$$

- <u>Requisitos de tamanho de amostra incomum</u>
  - O número de ensaios do planejamento pode ser extremamente caro ou demorado
    - *Planejamento composto reduzido*
      - Planejamento fatorial fracionário de resolução III
    - *Planejamento híbrido*

      Níveis irregulares

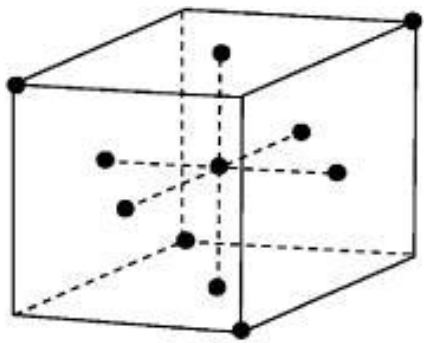

(*b*) Small Composite Design

■ **TABLE 11.10**

**A Hybrid Design for $k = 3$ Factors**

| Standard Order | $x_1$ | $x_2$ | $x_3$ |
|---|---|---|---|
| 1 | 0.00 | 0.00 | 1.41 |
| 2 | 0.00 | 0.00 | −1.41 |
| 3 | −1.00 | −1.00 | 0.71 |
| 4 | 1.00 | −1.00 | 0.71 |
| 5 | −1.00 | 1.00 | 0.71 |
| 6 | 1.00 | 1.00 | 0.71 |
| 7 | 1.41 | 0.00 | −0.71 |
| 8 | −1.41 | 0.00 | −0.71 |
| 9 | 0.00 | 1.41 | −0.71 |
| 10 | 0.00 | −1.41 | −0.71 |
| 11 | 0.00 | 0.00 | 0.00 |

Table 11.10
© John Wiley & Sons, Inc. All rights reserved.

# Planejamento Hartley

Quando não se pode fazer um grande número de ensaios ou experimentos, recomenda-se usar o planejamento de Hartley.

| p | n | $n_k$ | $n_s$ | $n_z$ | $\alpha$, se o cubo for $[-1; +1]^p$ |
|---|---|---|---|---|---|
| 3 | 11 | 1 | 1 | 1 | 1,1474 |
| 4 | 17 | 1 | 1 | 1 | 1,3531 |
| | 20 | 1 | 1 | 4 | 1,5246 |

Hartley, H. O. (1959). Smallest composite designs for quadratic response surfaces. *Biometrics 15*, 611 – 624.

# Dispersão da variância de um planejamento híbrido com três fatores e 10 ensaios

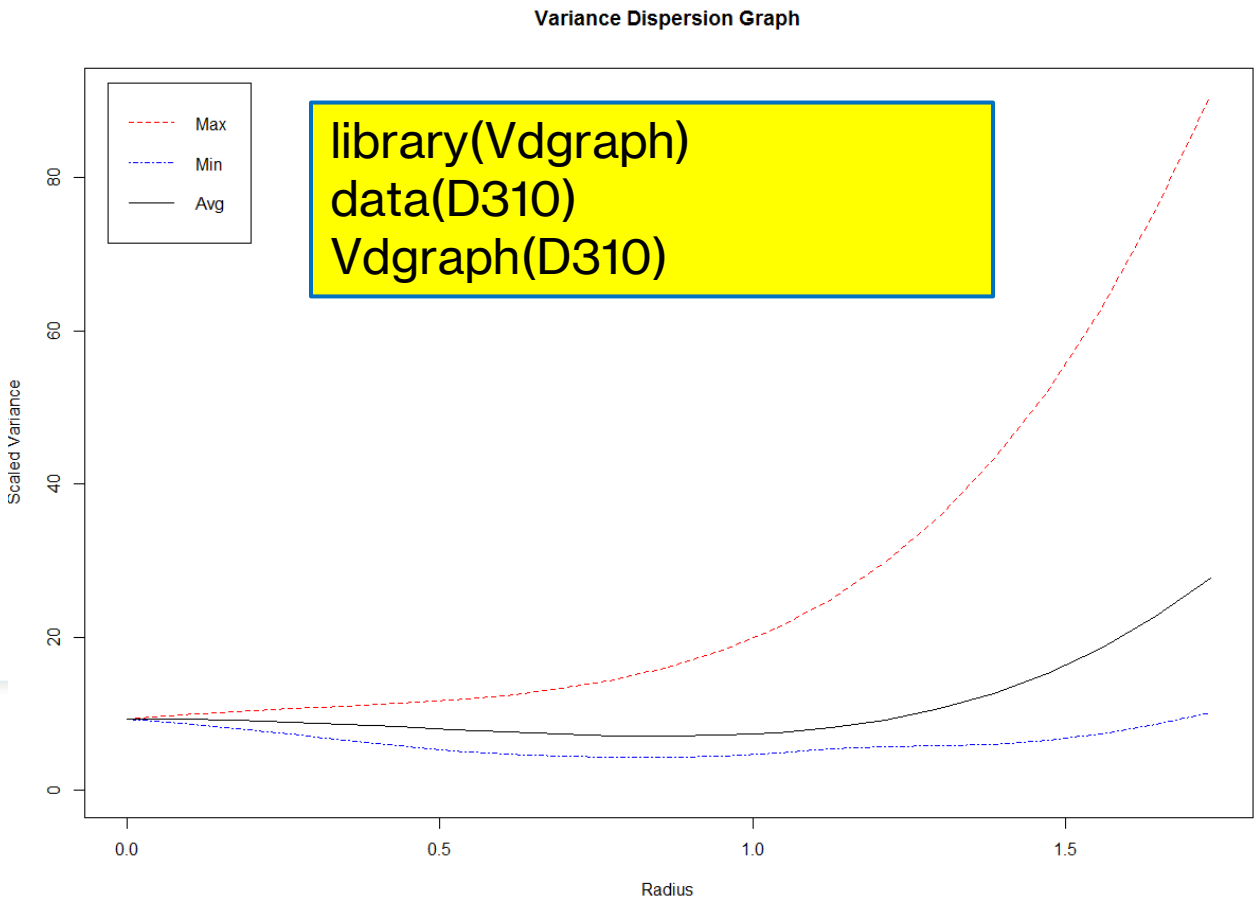


```
library(Vdgraph)
data(D310)
Vdgraph(D310)
```

# Planejamento e Otimização de Experimentos (DoE)

~~Planejamento Composto Central~~

~~Planejamento Híbrido~~

Planejamentos Ótimos

Planejamento Box-Behnken (BBD)

Planejamento Doehlert

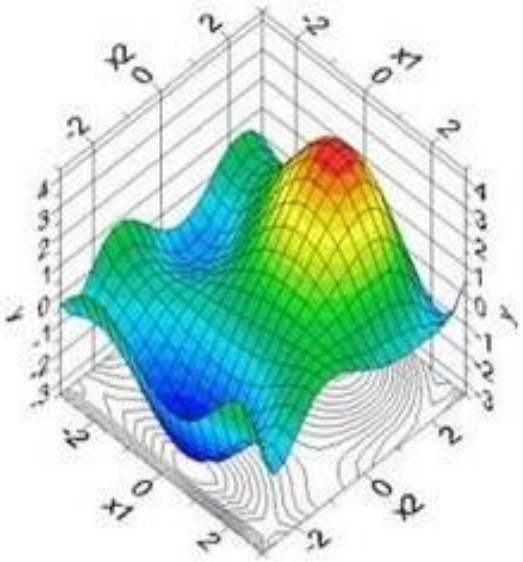

# Planejamentos Ótimos

- <u>Região experimental irregular (não é um cubo ou uma esfera)</u>

  *Restrições* nos fatores do planejamento

  $x_1 + x_2 \geq ou \leq condition$

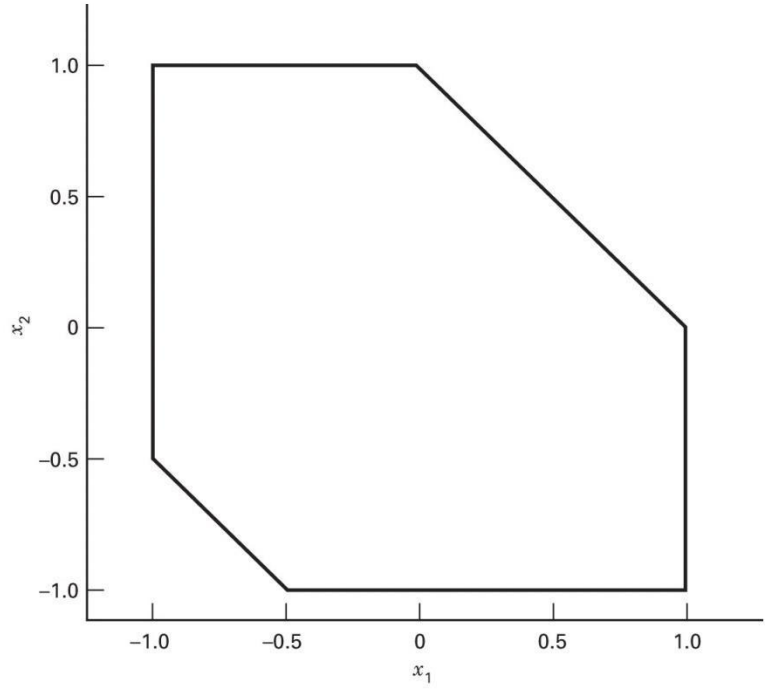


Figure 11.28
© John Wiley & Sons, Inc. All rights reserved.

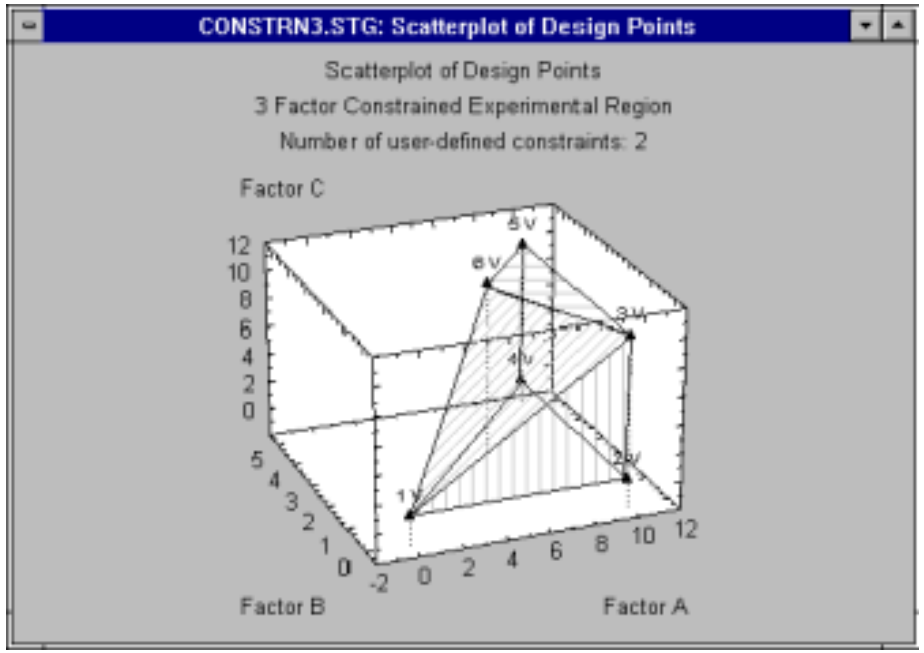

# Planejamentos Ótimos

- Vários planejamentos ótimos estão associados aos critérios de estimação.
- Os valores de $x_i$ são escolhidos de tal forma que a variância seja minimizada dentre todos os valores possíveis dos valores de $x_i$.
- Lembre a definição da região experimental: $[x_l,x_u]= [a,b]$, onde $x_l = a$ (nível inferior) e $x_u = b$(nível superior).
- A **desvantagem** do planejamento ótimo é sua dependência com a **exatidão** do modelo escolhido.

# Planejamentos Ótimos

- Planejamento $C_i$ ótimo se minimiza a variância ($\boldsymbol{b}_i$);
- Planejamento D ótimo se minimiza o determinante D da matriz de covariância;
- Planejamento A ótimo se minimiza o traço da matriz de covariância;
- Planejamento G ótimo se minimiza o máximo $[x_l, x_u]$ da faixa esperada do intervalo de confiança para E($\boldsymbol{y}$).

# Planejamento de segunda ordem D-ótimo e G-ótimo de menor dimensão

| p | k | n | $n_C$ | $n_K$ | $n_S$ | $\alpha = \sqrt{p}$ |
|---|---|---|---|---|---|---|
| 2 | 0 | 48 | 8 | 5 | 5 | 1,414 |
| 3 | 0 | 400 | 40 | 27 | 24 | 1,732 |
| 4 | 0 | 180 | 12 | 7 | 7 | 2,000 |
| 5 | 1 | 588 | 28 | 25 | 16 | 2,236 |
| 6 | 1 | 3584 | 128 | 81 | 72 | 2,449 |
| 7 | 1 | 20736 | 576 | 245 | 320 | 2,646 |
| 8 | 2 | 900 | 20 | 11 | 11 | 2,828 |
| 9 | 2 | 38720 | 704 | 243 | 384 | 3,000 |

# Planejamento D-ótimo

- As propriedades da matriz **X** são transmitidas para critérios diferentes na qualidade dos parâmetros do modelo estimados.
- Um critério é que a região de confiança conjunta deve ser a menor possível.
- Isto é obtido se o determinante da matriz de dispersão, $\left|\boldsymbol{X^t X^{-1}}\right|$, for o menor possível.
- $\left|\boldsymbol{X^t X^{-1}}\right| = {}^{\mathbf{1}}/_{|\boldsymbol{X^t X}|}$
- Isto equivale a dizer que o determinante $|\boldsymbol{X^t X}|$deve ser o maior possível.

# Planejamento D-ótimo

- Portanto, é possível selecionar uma série de experimentos de forma que $|\boldsymbol{X}^t\boldsymbol{X}|$ atinja um máximo.
- O critério de D-otimalidade deve ser usado para selecionar os experimentos.
- Quando o planejamento D-ótimo é adequado?
  - O experimento tem restrições.
  - Um número mínimo de experimentos deve ser usado.
  - Seleção de experimentos complementares para melhorar o modelo.

# Planejamento D-ótimo

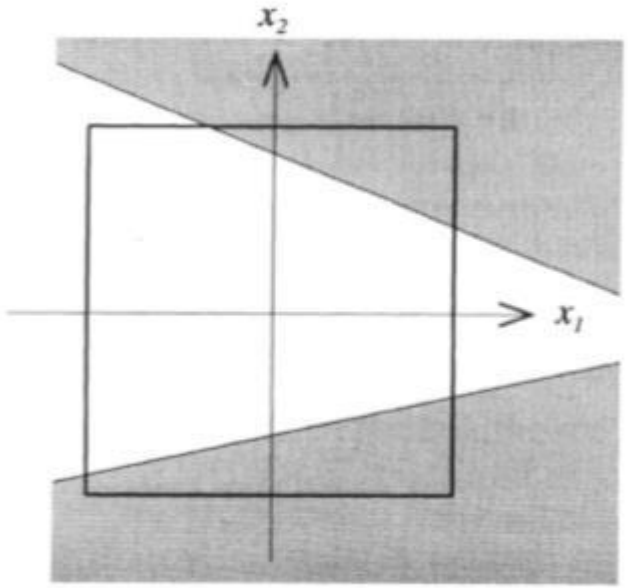


O domínio experimental é reduzido devido a restrições.

# Planejamento D-ótimo

- Considere um planejamento onde são avaliados seis fatores com dois níveis.
- Caso a opção seja de um planejamento fatorial completo, deve-se realizar um total de $2^6$= 64 ensaios.
- No problema em questão, procura-se obter um planejamento capaz de avaliar um modelo do tipo:
- $y = \beta_0 + \sum \beta_i x_i + \beta_{12} x_1 x_2 + \beta_{34} x_3 x_4 + \beta_{56} x_5 x_6 + e$
- O modelo tem dez parâmetros. Portanto, para estimar estes parâmetros, é suficiente um planejamento com 12 ensaios.

# Planejamento D-ótimo

- Qual o número de possíveis planejamentos D-ótimo que podemos selecionar?
- $N = \frac{64!}{(52!12!)} \approx 3{,}28 \cdot 10^{12}$
- Como resolver esta escolha?
  - Seleção aleatória de 12 ensaios.
  - Obter um sub-conjunto de 12 ensaios que forneça uma boa estimativa dos parâmetros do modelo onde o critério de D-otimalidade seja obedecido.

# Planejamento D-ótimo

- Seleção arbitraria inicial de 12 ensaios.
- Algoritmo de Mitchell (T. J. Mitchell, Technometrics, 16 (1974) 203).
- Através de processo iterativo, o conjunto inicial é modificado por adição ou remoção de experimentos de forma que o determinante de $|\boldsymbol{X}^t\boldsymbol{X}|$ seja maximizado.

# Planejamento D, A, G, e IV ótimos

- Descrição: Planejamentos gerados por algoritmo genético.

  library(VdgRsm)

- Borkowski2003(criterion, k, N)
- Arguments
- Critério: "D", "A", "G", e "IV".
- k = Número de fatores, k = 2 e 3
- N = Número de ensaios no planejamento
- Borkowski, J. J. (2003). Using a Genetic Algorithm to Generate Small Exact Response Surface Designs. Journal of Probability and Statistical Science, 1(1):65-88.

# Exemplo de Planejamento Ótimo

- Ao projetar um experimento, nem sempre é possível gerar um planejamento regular e equilibrado, como um planejamento fatorial completo ou fracionário.
- Geralmente há restrições do número total de experimentos que podem ser realizados ou restrições nas configurações dos fatores individualmente ou em combinação entre si.
- Nesses cenários, os planejamentos gerados por computador, ou os planejamentos ótimos de um determinado tamanho, podem ser identificados a partir de uma lista de combinações de fatores candidatos.

# Exemplo de Planejamento Ótimo

- A biblioteca AlgDesign no R possui facilidades para buscas ótimas de projetos com base no algoritmo de otimização de Federov.
- Um critério de otimalidade deve ser selecionado pelo investigador, atualmente D, A ou I, e esse critério é minimizado pela busca de um subconjunto ótimo de um determinado tamanho na lista de projetos candidatos.

# Exemplo de Planejamento Ótimo

- Dado o número total de execuções de tratamento para um experimento e um modelo especificado, o algoritmo de computador escolhe o conjunto ideal de execuções de projeto a partir de um conjunto candidato de execuções de tratamento de projeto possíveis.
- Esse conjunto candidato de execuções de tratamento geralmente consiste em todas as combinações possíveis de vários níveis de fatores que se deseja usar no experimento.
- A primeira etapa, como sempre, é disponibilizar o pacote para uso:

# Exemplo de Planejamento Ótimo

- Para fins ilustrativos, considere um experimento de quatro fatores, onde os fatores têm 4, 3, 2 e 2 níveis cada, respectivamente.
- Usando a função expand.grid, podemos criar um quadro de dados de todas as combinações possíveis das configurações dos fatores.

# Exemplo de Planejamento Ótimo

- Códigos do R

```
install.packages(AlgDesign)
library(AlgDesign)
cand.list = expand.grid(Factor1 = c("A", "B", "C", "D"), Factor2 = c("I", "II", "III"),
Factor3 = c("Low", "High"), Factor4 = c("Yes", "No"))
```

# Continuação

- A semente de número aleatório é definida para que o algoritmo possa ser executado.

```
# Código do R

set.seed(69)
```

# Continuação

- A função optFederov calcula um planejamento algorítmico exato ou aproximado para um dos três critérios, usando o algoritmo de troca de Federov.
- O primeiro argumento para a função é uma fórmula para o modelo pretendido para os dados e o argumento de dados especifica a lista de pontos candidatos.
- Código do R para 13 ensaios

```
optFederov( ~ ., data = cand.list, nTrials = 13)
```

# Continuação

- Neste exemplo, todos os fatores da lista de candidatos aparecem no modelo com um termo linear.
- Termos quadráticos ou cúbicos podem ser incluídos nesta fórmula.
- O argumento nTrials especifica o número de pontos do planejamento a serem selecionados na lista de candidatos.
- A saída desta função é:

```
$D
[1] 0.226687

$A
[1] 7.022811

$Ge
[1] 0.718

$Dea
[1] 0.676

$design
   Factor1 Factor2 Factor3 Factor4
4        D       I     Low     Yes
7        C      II     Low     Yes
9        A     III     Low     Yes
14       B       I    High     Yes
20       D      II    High     Yes
22       B     III    High     Yes
25       A       I     Low      No
27       C       I     Low      No
30       B      II     Low      No
36       D     III     Low      No
40       D       I    High      No
41       A      II    High      No
47       C     III    High      No

$rows
 [1]  4  7  9 14 20 22 25 27 30 36 40 41 47
```

# Continuação

- Isso fornece detalhes dos valores dos critérios de otimização para os pontos de projeto selecionados na lista de candidatos, os números de linha e os níveis dos fatores para os pontos de projeto escolhidos.

# Planejamento e Otimização de Experimentos (DoE)

~~Planejamento Composto Central~~
~~Planejamento Híbrido~~
~~Planejamentos Ótimos~~
Planejamento Box-Behnken (BBD)
Planejamento Doehlert

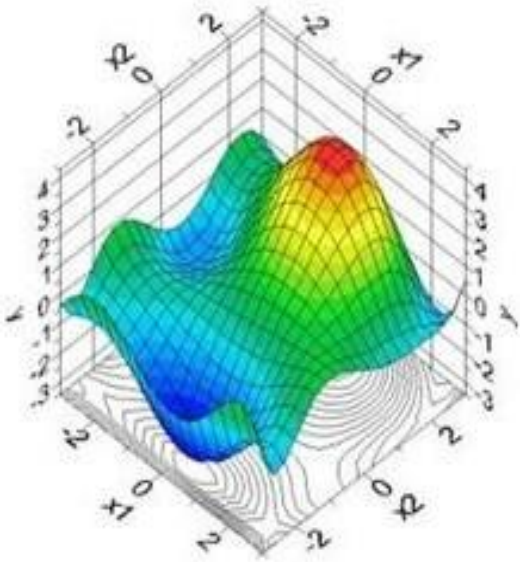

# Planejamento Box-Behnken

- O planejamento Box-Behnken é um planejamento quadrático independente, pois não contém um planejamento fatorial ou fracionário incorporado.
- Neste planejamento, as combinações de tratamento estão nos pontos médios das bordas do espaço do processo e no centro.
- Esses planejamentos são rotacionáveis (ou quase rotacionáveis) e exigem 3 níveis de cada fator.
- Os planejamentos têm capacidade limitada para a blocagem ortogonal em comparação com os planejamentos compostos centrais (CCD).

## – *Planejamento Box-Behnken*

- Planejamento esférico
- Raio = $\sqrt{2}$
- Muito eficiente em termos do número de ensaios necessários
- Não contém nenhum ponto nos vértices
  - Isso pode ser vantajoso quando os pontos nos vértices são proibitivamente caros ou impossíveis de testar

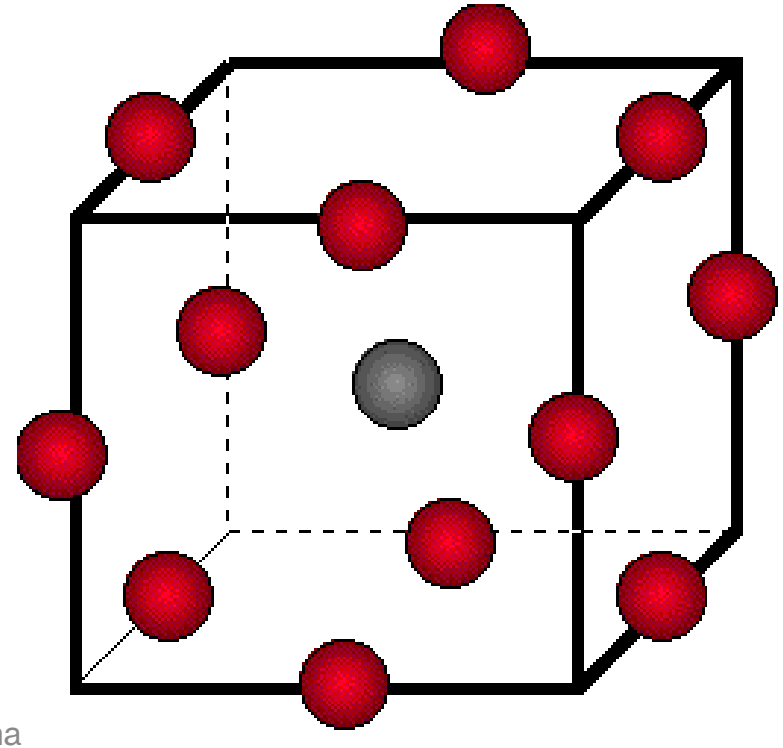

# Planejamento Box-Behnken para três fatores

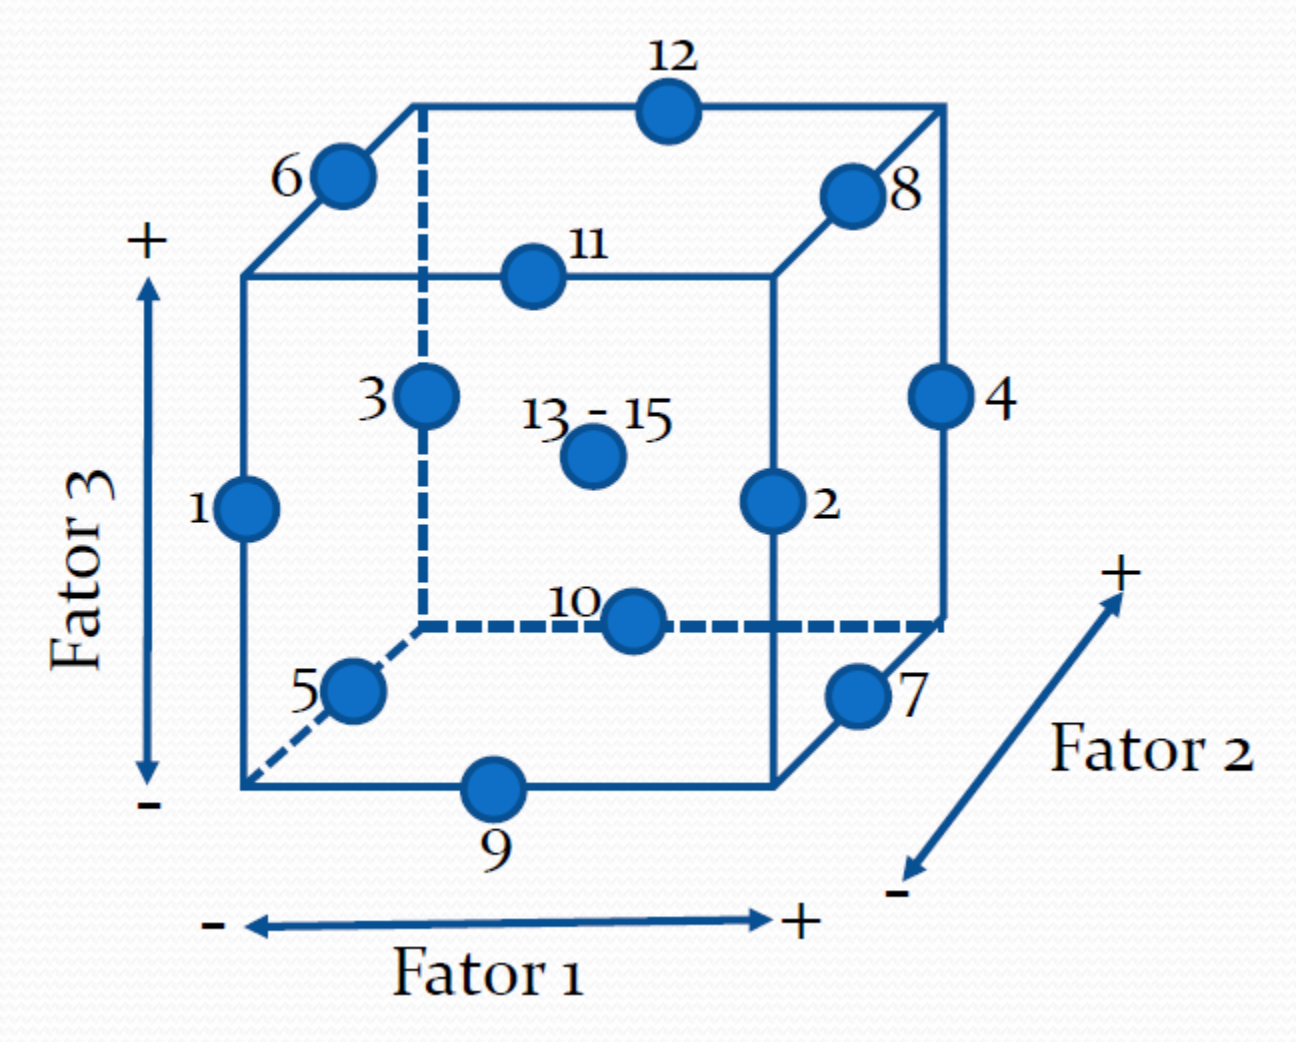

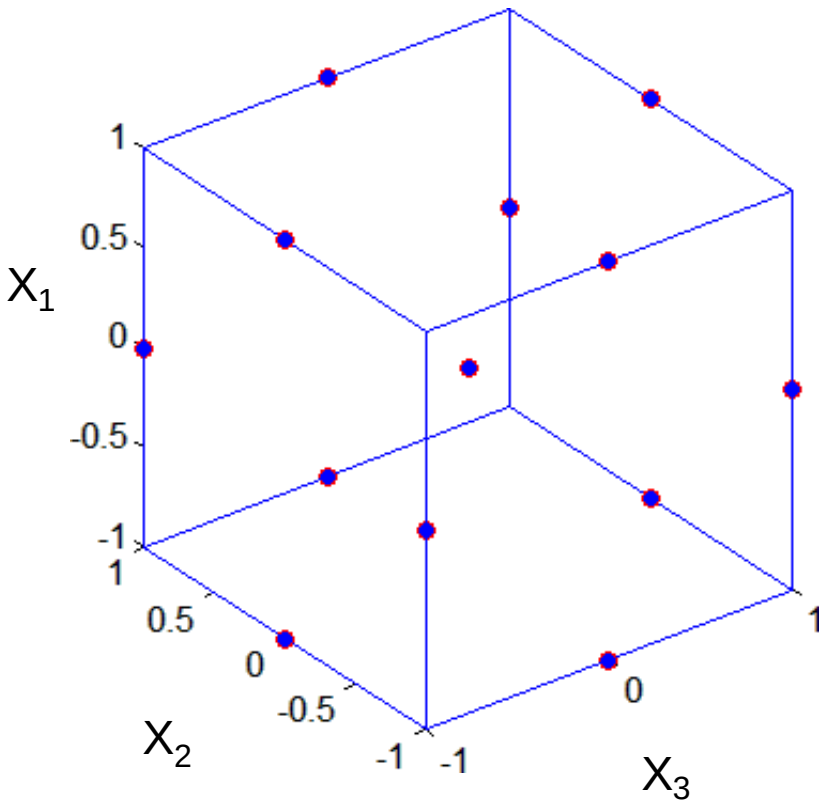


| $X_1$ | $X_2$ | $X_3$ |
|---|---|---|
| -1 | -1 | 0 |
| 1 | -1 | 0 |
| -1 | 1 | 0 |
| 1 | 1 | 0 |
| -1 | 0 | -1 |
| 1 | 0 | -1 |
| -1 | 0 | 1 |
| 1 | 0 | 1 |
| 0 | -1 | -1 |
| 0 | -1 | 1 |
| 0 | 1 | -1 |
| 0 | 1 | 1 |
| 0 | 0 | 0 |
| 0 | 0 | 0 |
| 0 | 0 | 0 |

# Planejamento Box-Behnken

- Enquanto que o planejamento CCD exige cinco níveis (-a -1, 0, +1, +a) para cada fator, o planejamento BB utiliza três níveis e permite a estimação de um modelo quadrático.
- Vantagens do planejamento BB quando comparado com o CCD:
  - Requer apenas três níveis para todos os fatores
  - O número de ensaios é menor do que no CCD. Por exemplo, um planejamento CCD para três fatores requer 20 ensaios que no BB somente 15 ensaios são necessários.

# Planejamento Box-Behnken

- Desvantagens do planejamento BB quando comparado com o CCD:
  - O planejamento BB não pode ser construído em dois estágios tal como ocorre no planejamento CCD.
  - O planejamento BB deve ser usado somente quando o pesquisador tem a segurança de que o modelo linear é inadequado.

# Comandos no R

- # Habilitar o pacote rsm

```
library(rsm)
# Criar o planejamento BB com três fatores
bbd3 <- bbd(3,randomize=FALSE,n0=3)
# Habilitar o pacote Vdgrph
library(Vdgraph)
# Construir o gráfico
Vdgraph(bbd3[ , 3:5])
```

# Dispersão da Variância para o planejamento BB com três fatores

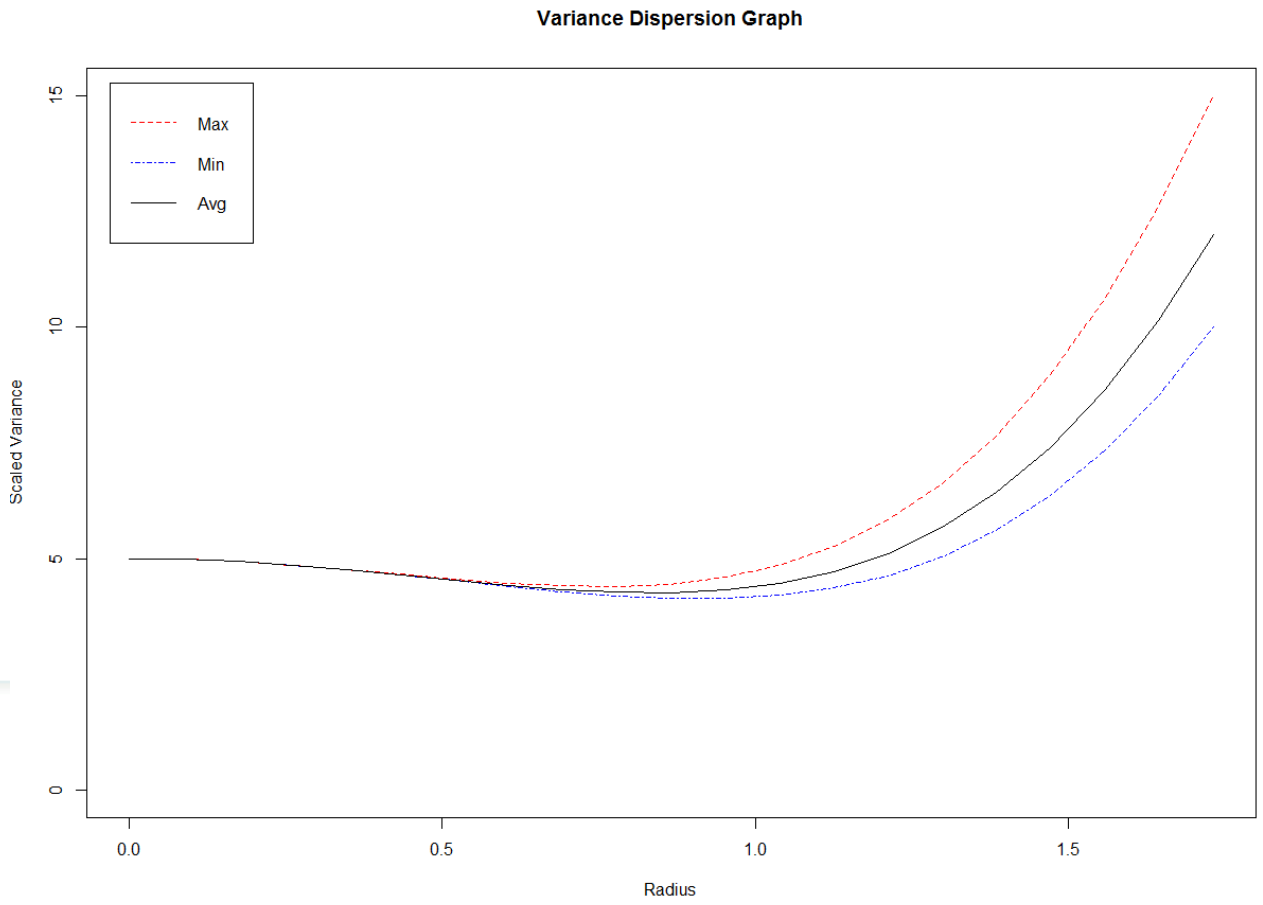

# Conclusões

- Como as linhas de mínimo, máximo da variância média padronizada do planejamento BB não se sobrepõem, este planejamento não é rotacionável.
- No entanto, como as linhas estão próximas dentro da região experimental com raio próximo de 1, assume-se que para fins práticos o planejamento tem precisão uniforme.
- Isto é verdadeiro para o planejamento BB com k = 3 – 6.

# Exemplo: Produção de um iogurte leve

- Em laboratório, uma pesquisadora é responsável pelo estudo dos fatores que podem diminuir a quantidade da acidez dos iogurtes.
- A acidez é produzida pelas bactérias do ácido láctico que convertem a lactose em ácido láctico. A elevada concentração deste ácido dá o sabor do iogurte especial da Bulgária.
- O objetivo deste estudo foi reduzir o gosto ácido desses leites fermentados. Para isso, na preparação de um leite estabilizado, adiciona-se um estabilizante natural para atenuar a variação de acidez do produto final, apesar da presença de fermentos lácticos.

# Exemplo: Produção de um iogurte leve

- A primeira etapa do método é a diluição do leite bruto com água.
- A segunda etapa do processo é uma pré-concentração que elimina parte da lactose e água. Diminuindo a quantidade de lactose, as bactérias irão produzir uma menor quantidade de ácido láctico.
- Os dois primeiros passos foram modificações no leite, antes de ser estabilizado. Injeta-se um estabilizante. Esta injeção não afeta o volume de leite processado. No final do processo, obtém-se um leite estabilizado e pronto para consumo.

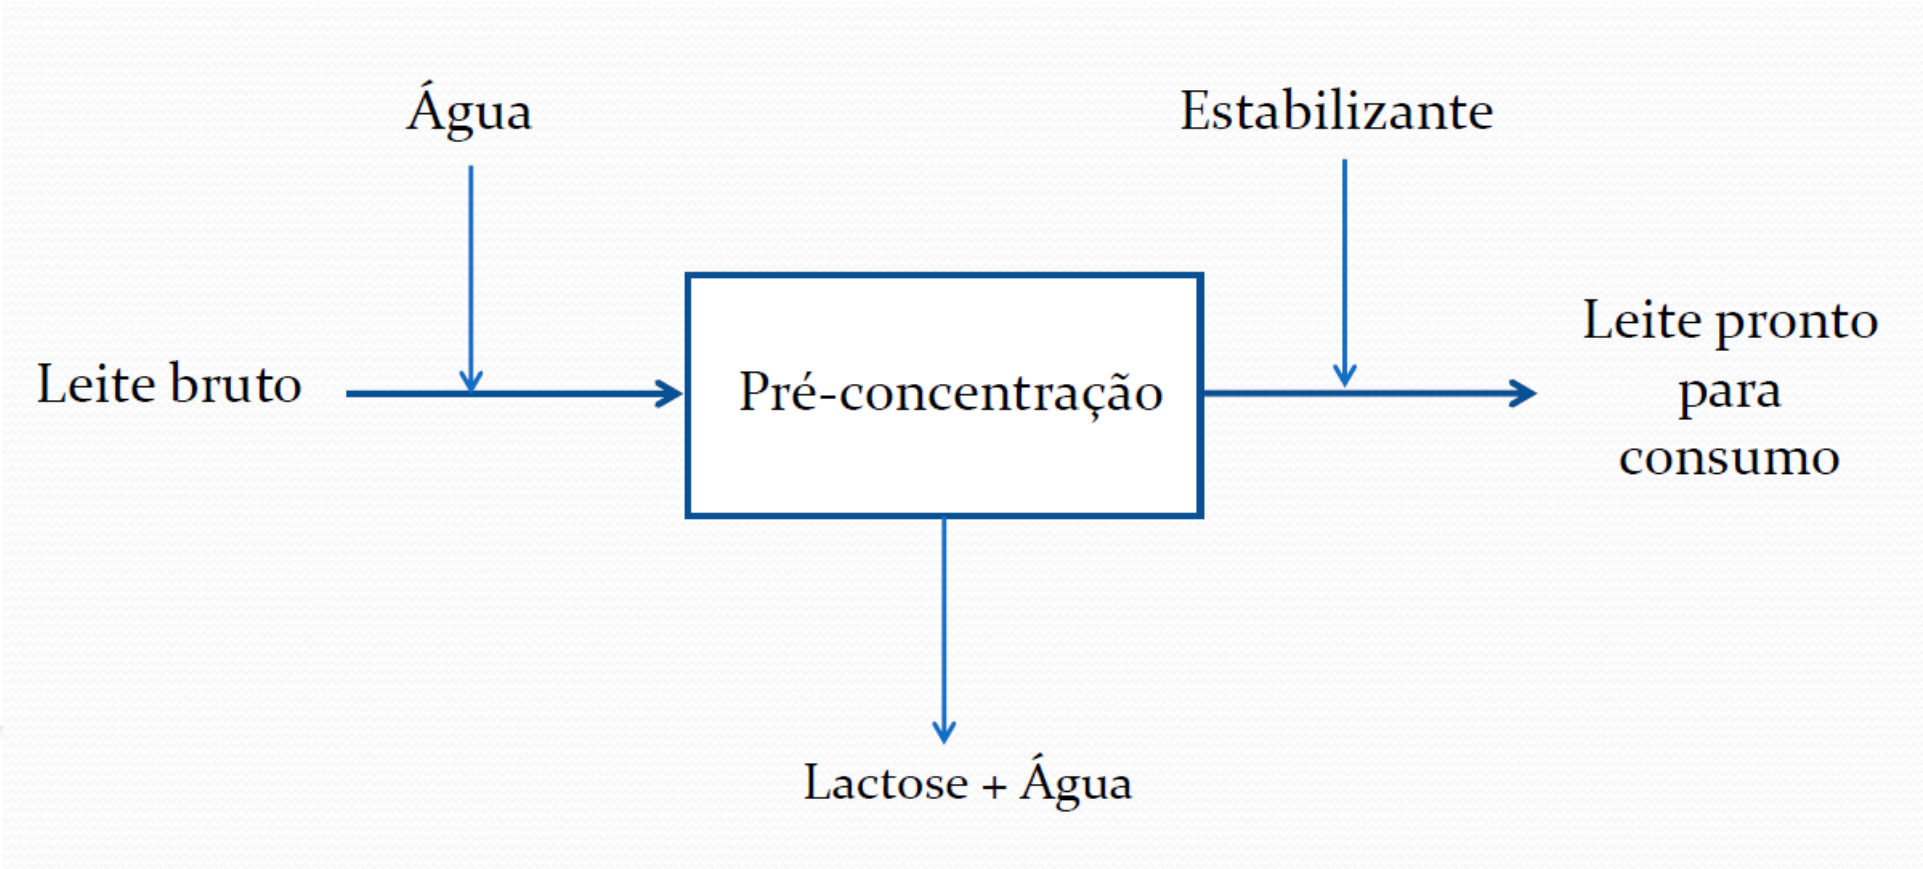
Água
Estabilizante
Leite bruto
Pré-concentração
Leite pronto para consumo
Lactose + Água

# Exemplo: Produção de um iogurte leve

- Três fatores foram investigados:
- Fator 1: taxa de diluição
- (volume de água adicionada/volume do leite bruto)
- Fator 2: pH na injeção do estabilizante.
- Ajusta-se a quantidade necessária de estabilizante para se obter o pH no instante de injeção.
- Fator 3: fator de pré-concentração do leite

  (volume do leite bruto/volume do leite estabilizado)

# Exemplo: Produção de um iogurte leve

- **Domínio experimental**

| Fator | Nível -1 | Nível +1 |
|---|---|---|
| 1: Diluição | 0,5 | 2 |
| 2: pH | 6 | 5 |
| 3: Taxa de pré-concentração | 1,5 | 2,5 |

# Matriz do Planejamento BB

| Ensaio | Diluição | pH | Concentração | Resposta |
|---|---|---|---|---|
| 1 | - 1 | - 1 | 0 | 51,3 |
| 2 | - 1 | - 1 | + 1 | 42,2 |
| 3 | - 1 | + 1 | 0 | 42,6 |
| 4 | + 1 | + 1 | 0 | 50,4 |
| 5 | - 1 | 0 | 1 | 40,7 |
| 6 | - 1 | 0 | +1 | 41,5 |
| 7 | + 1 | 0 | - 1 | 41,3 |
| 8 | + 1 | 0 | +1 | 40,8 |

# Matriz do Planejamento BB

| Ensaio | Diluição | pH | Concentração | Resposta |
|---|---|---|---|---|
| 9 | 0 | - 1 | - 1 | 39,5 |
| 10 | 0 | - 1 | + 1 | 35,2 |
| 11 | 0 | + 1 | - 1 | 35,3 |
| 12 | 0 | + 1 | + 1 | 39,8 |
| 13 | 0 | 0 | 0 | 50,8 |
| 14 | 0 | 0 | 0 | 50,1 |
| 15 | 0 | 0 | 0 | 49,4 |

# Resolução usando o R Studio

- **PacoteVdgRsm**
- Geração do PlanejamentoBox-Behnken para k = 3 -7
- Comando no R
- gen.BBD(k, n.center= 1)
- Argumentos
- k = Número de fatores ou variáveis independentes
- n.center= Número de replicatas no ponto central

# Resolução usando o R Studio

- **Habilite o pacote VdgRsm**

```
# Geração do planejamento BB com três variáveis
gen.BBD(3)
```

# Resolução usando o R Studio

```
# Criação do data frame (objeto A)
A <- gen.BBD(3, n.center = 3)
y <- c(51.3, 42.2, 42.6, 50.4, 40.7, 41.5, 41.3, 40.8, 39.5, 35.2, 35.3, 39.8,
       50.8, 50.1, 49.4)
A <- cbind(A, y)
A
```

| | x1 | x2 | x3 | y |
|---|---|---|---|---|
| 1 | -1 | -1 | 0 | 51.3 |
| 2 | -1 | 1 | 0 | 42.2 |
| 3 | 1 | -1 | 0 | 42.6 |
| 4 | 1 | 1 | 0 | 50.4 |
| 5 | -1 | 0 | -1 | 40.7 |
| 6 | -1 | 0 | 1 | 41.5 |
| 7 | 1 | 0 | -1 | 41.3 |
| 8 | 1 | 0 | 1 | 40.8 |
| 9 | 0 | -1 | -1 | 39.5 |
| 10 | 0 | -1 | 1 | 35.2 |
| 11 | 0 | 1 | -1 | 35.3 |
| 12 | 0 | 1 | 1 | 39.8 |
| 13 | 0 | 0 | 0 | 50.8 |
| 14 | 0 | 0 | 0 | 50.1 |
| 15 | 0 | 0 | 0 | 49.4 |

# Análise do modelo

```
# Criação do modelo de regressão:
lm.BB.1 <- lm(y ~ X1*X2*X3 - X1:X2:X3 + I(X1^2) + I(X2^2) + I(X3^2), data = A)
# Análise Estatística
summary(lm.BB.1)
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  50.1000     0.3014 166.232 1.49e-10 ***
x1           -0.0750     0.1846  -0.406 0.701279
x2           -0.1125     0.1846  -0.610 0.568789
x3            0.0625     0.1846   0.339 0.748637
I(x1^2)       0.0750     0.2717   0.276 0.793538
I(x2^2)      -3.5500     0.2717 -13.068 4.68e-05 ***
I(x3^2)      -9.1000     0.2717 -33.497 4.46e-07 ***
x1:x2         4.2250     0.2610  16.187 1.64e-05 ***
x1:x3        -0.3250     0.2610  -1.245 0.268241
x2:x3         2.2000     0.2610   8.429 0.000386 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.522 on 5 degrees of freedom
Multiple R-squared:  0.9968,    Adjusted R-squared:  0.9912
F-statistic: 175.7 on 9 and 5 DF,  p-value: 1.031e-05
```

# Refinamento do modelo BB

```
# Refinamento do modelo BB
lm.BB.2 <- lm(y ~ X1*X2*X3 - X1 - X2 - X3 - X1:X3 - X1:X2:X3 + I(X2^2) + I(X3^2), data = A)
summary(lm.BB.2)
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  50.1462     0.2139  234.40  < 2e-16 ***
I(X2^2)      -3.5558     0.2311  -15.39 2.73e-08 ***
I(X3^2)      -9.1058     0.2311  -39.41 2.65e-12 ***
X1:X2         4.2250     0.2227   18.97 3.59e-09 ***
X2:X3         2.2000     0.2227    9.88 1.78e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.4453 on 10 degrees of freedom
Multiple R-squared:  0.9954,    Adjusted R-squared:  0.9936
F-statistic: 542.3 on 4 and 10 DF,  p-value: 1.216e-11
```

# Análise da Variância

# ANOVA

anova(lm.BB.2)

```
Analysis of Variance Table

Response: y
          Df  Sum Sq Mean Sq  F value    Pr(>F)
I(X2^2)    1  31.513  31.513  158.896 1.837e-07 ***
I(X3^2)    1 307.970 307.970 1552.841 2.647e-12 ***
X1:X2      1  71.402  71.402  360.024 3.588e-09 ***
X2:X3      1  19.360  19.360   97.617 1.775e-06 ***
Residuals 10   1.983   0.198
```

# Análise dos resíduos

```
# Análise dos Resíduos
yp <- predict.lm(lm.BB.2)
res <- residuals(lm.BB.2)
par(mar = c(5.1, 4.5, 4.1, 4.1))
plot(yp, res, cex = 1.3, col = "blue", pch = 16, xlab ="Valores preditos", ylab
= "Resíduos", cex.lab = 1.3, cex.axis = 1.3)
abline(0, 0, col = "red", lty = "dashed", lwd = 2.0)
```

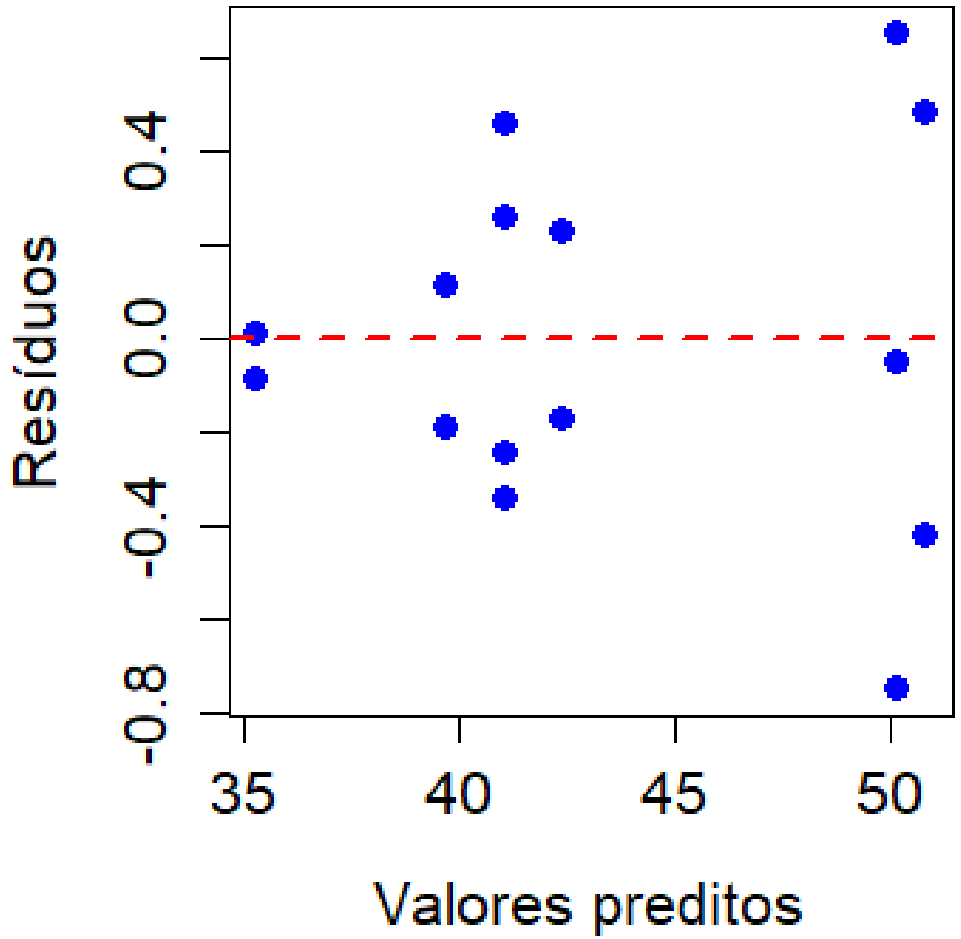


- Que conclusões podemos obter deste gráfico?
- Quais as próximas etapas que você julga serem necessárias nesta análise?

# Análise do modelo usando o pacote rsm

```
# Requisição do pacote:
library(rsm)
# Criação do modelo:
lm.BB.3 <- rsm(y ~ TWI(X1, X2) + TWI(X2, X3) + SO(X2,X3), data = A)
summary(lm.BB.3)
```

```
            Estimate Std. Error  t value  Pr(>|t|)
(Intercept) 50.14615    0.23106 217.0289 2.274e-16 ***
X1:X2        4.22500    0.24049  17.5681 1.126e-07 ***
X2:X3        2.20000    0.24049   9.1479 1.644e-05 ***
X2          -0.11250    0.17005  -0.6616    0.5268
X3           0.06250    0.17005   0.3675    0.7228
X2^2        -3.55577    0.24957 -14.2475 5.739e-07 ***
X3^2        -9.10577    0.24957 -36.4857 3.490e-10 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.9957,    Adjusted R-squared:  0.9925
F-statistic: 310.1 on 6 and 8 DF,  p-value: 5.008e-09
```

```
Analysis of Variance Table

Response: y
            Df Sum Sq Mean Sq  F value    Pr(>F)
TWI(X1, X2)  1  71.40  71.402 308.6392 1.126e-07
TWI(X2, X3)  1  19.36  19.360  83.6841 1.644e-05
FO(X2, X3)   2   0.13   0.066   0.2864    0.7584
PQ(X2, X3)   2 339.48 169.742 733.7134 8.643e-10
Residuals    8   1.85   0.231
Lack of fit  3   0.38   0.128   0.4353    0.7374
Pure error   5   1.47   0.293
```

```
Stationary point of response surface:
          x2           x3
-0.015330605  0.001579914

Eigenanalysis:
eigen() decomposition
$values
[1] -3.345702 -9.315836

$vectors
         [,1]       [,2]
x2 -0.9822493 -0.1875801
x3 -0.1875801  0.9822493
```

# Geração das curvas de nível

```
# Geração das curvas de nível

fit.model.BB <- rsm(y ~ TWI(X1,X3) + TWI(X1, X2) + TWI(X2, X3) + SO(X2,
X3), data = A)

# Curva de nível: X1 e X2

# Modificação da cor de fundo:

par(bg="black")

contour(fit.model.BB, ~X1 + X2, main = "Curvas de Nível", col =
rev(heat.colors(12)), lwd = 2, labcex = 1.5, lty = "solid", col.lab = "white",
col.axis = "white", col.main = "white") box(col = "white")
```

# Geração das curvas de nível

```
# Curva de nível: X1 e X3

par(bg="black")

contour(fit.model.BB, ~X1 + X3, main = "Curvas de Nível", col =
rev(heat.colors(12)), lwd = 2, labcex = 1.5, lty = "solid", col.lab = "white", col.axis =
"white", col.main = "white") box(col = "white")

# Curva de nível: X2 e X3

par(bg="black")

contour(fit.model.BB, ~X2 + X3, main = "Curvas de Nível", col =
rev(heat.colors(12)), lwd = 2, labcex = 1.5, lty = "solid", col.lab = "white", col.axis =
"white", col.main = "white") box(col = "white")
```

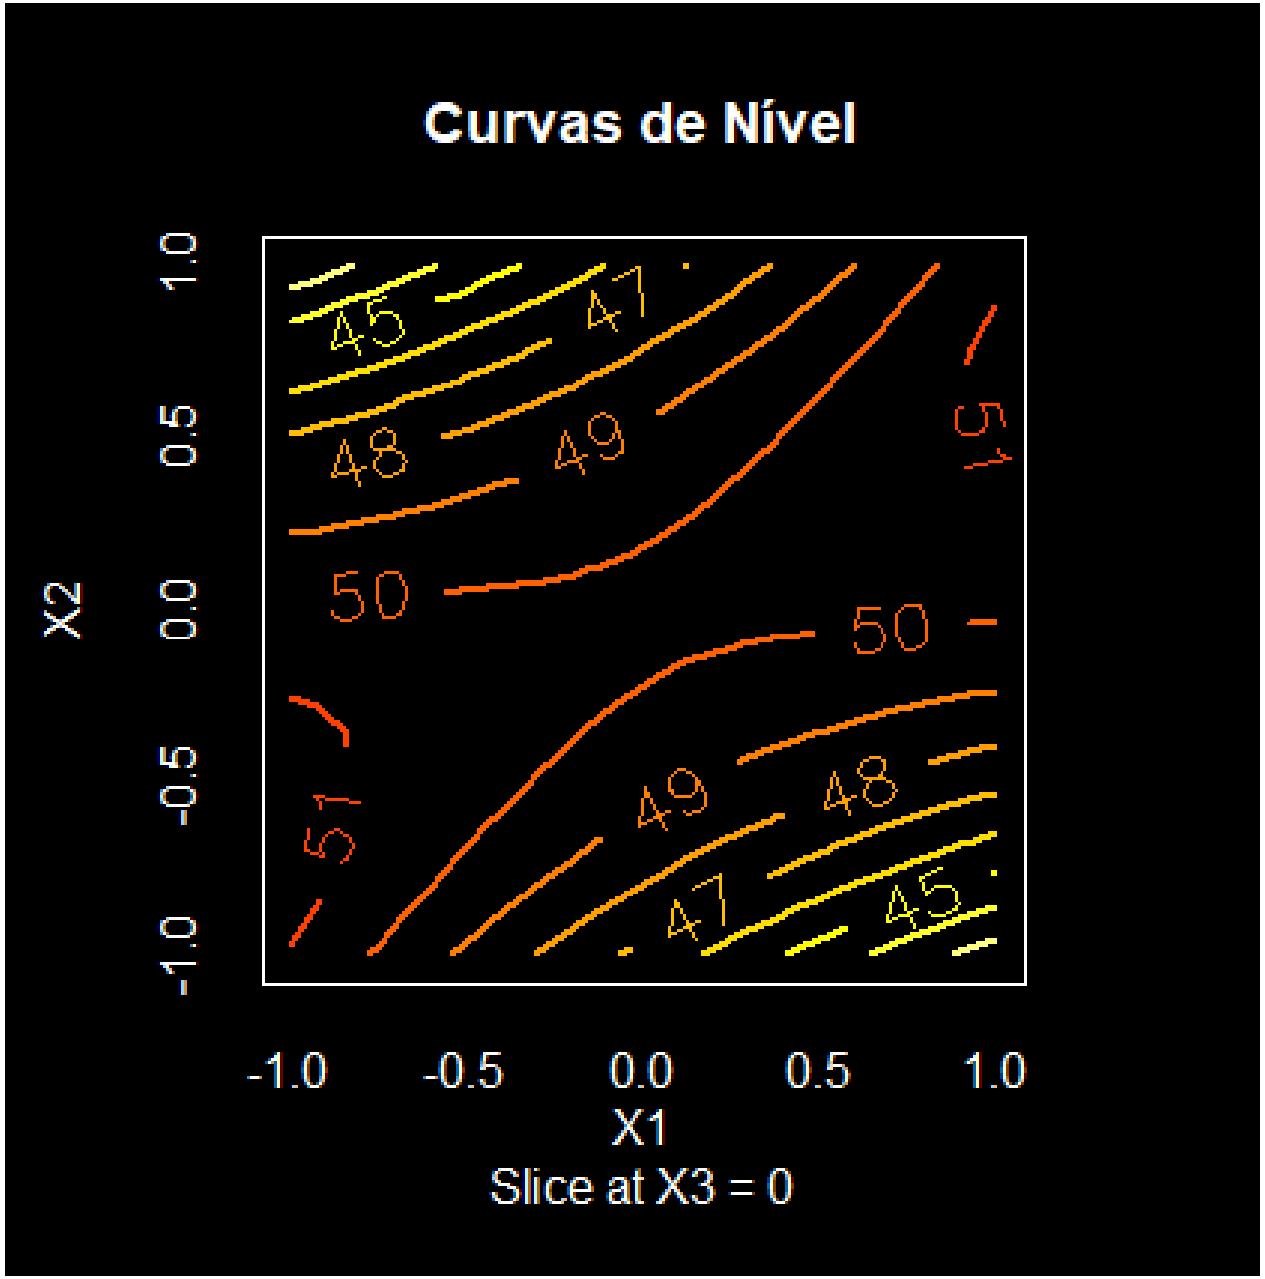
Curvas de Nível
X2
1.0
0.5
0.0
-0.5
-1.0
-1.0
-0.5
0.0
0.5
1.0
X1
Slice at X3 = 0
45
47
48
49
50
51

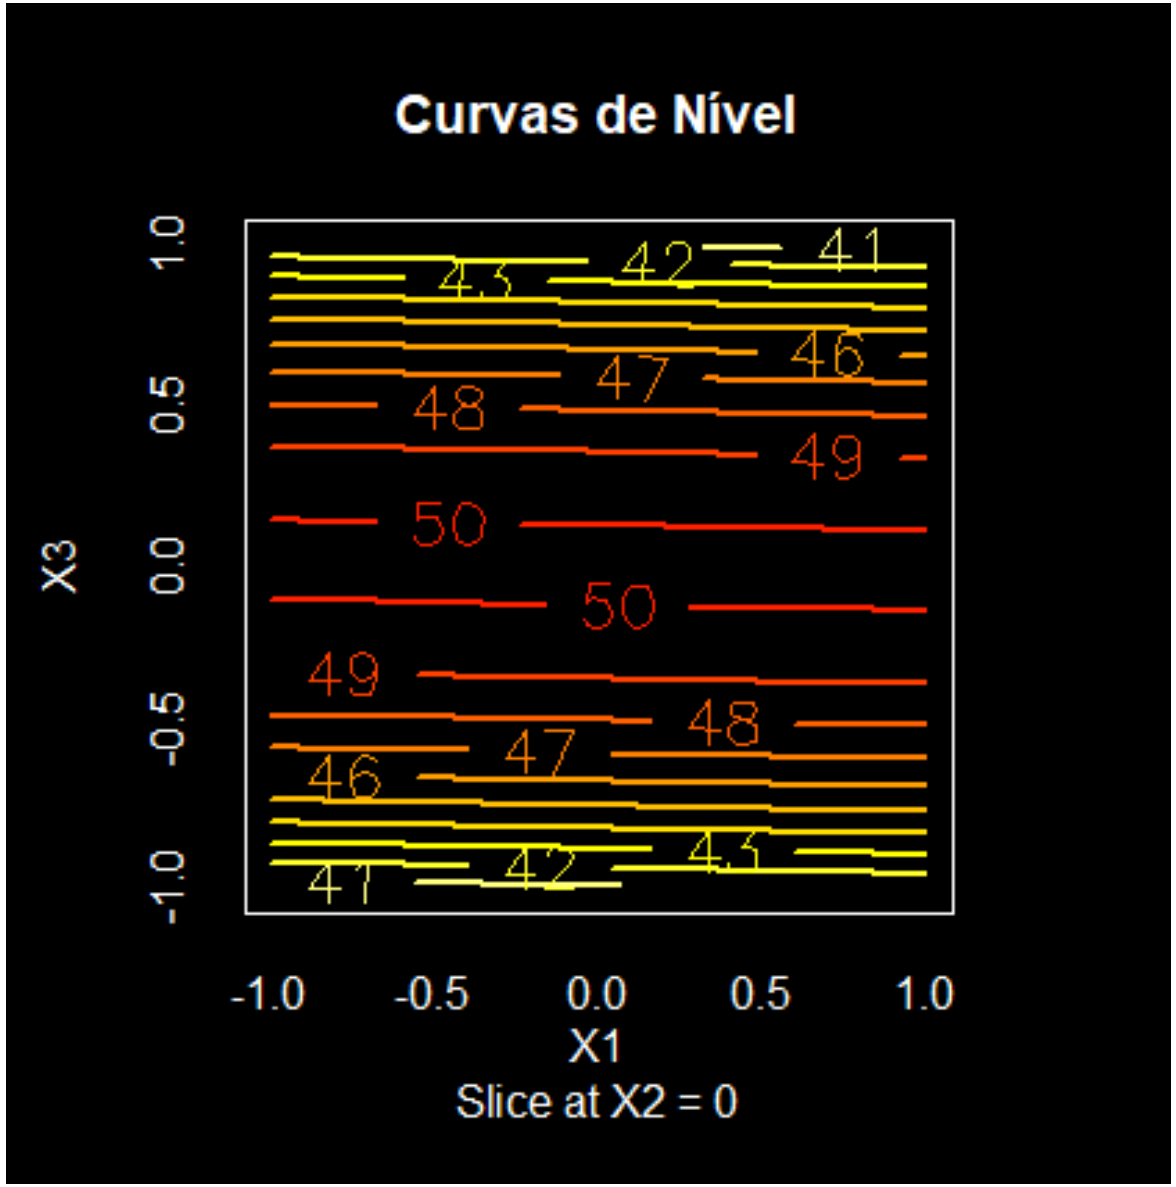
Curvas de Nível
X3
1.0
0.5
0.0
-0.5
-1.0
-1.0
-0.5
0.0
0.5
1.0
X1
Slice at X2 = 0
41
42
43
46
47
48
49
50
50
49
48
47
46
43
42
41

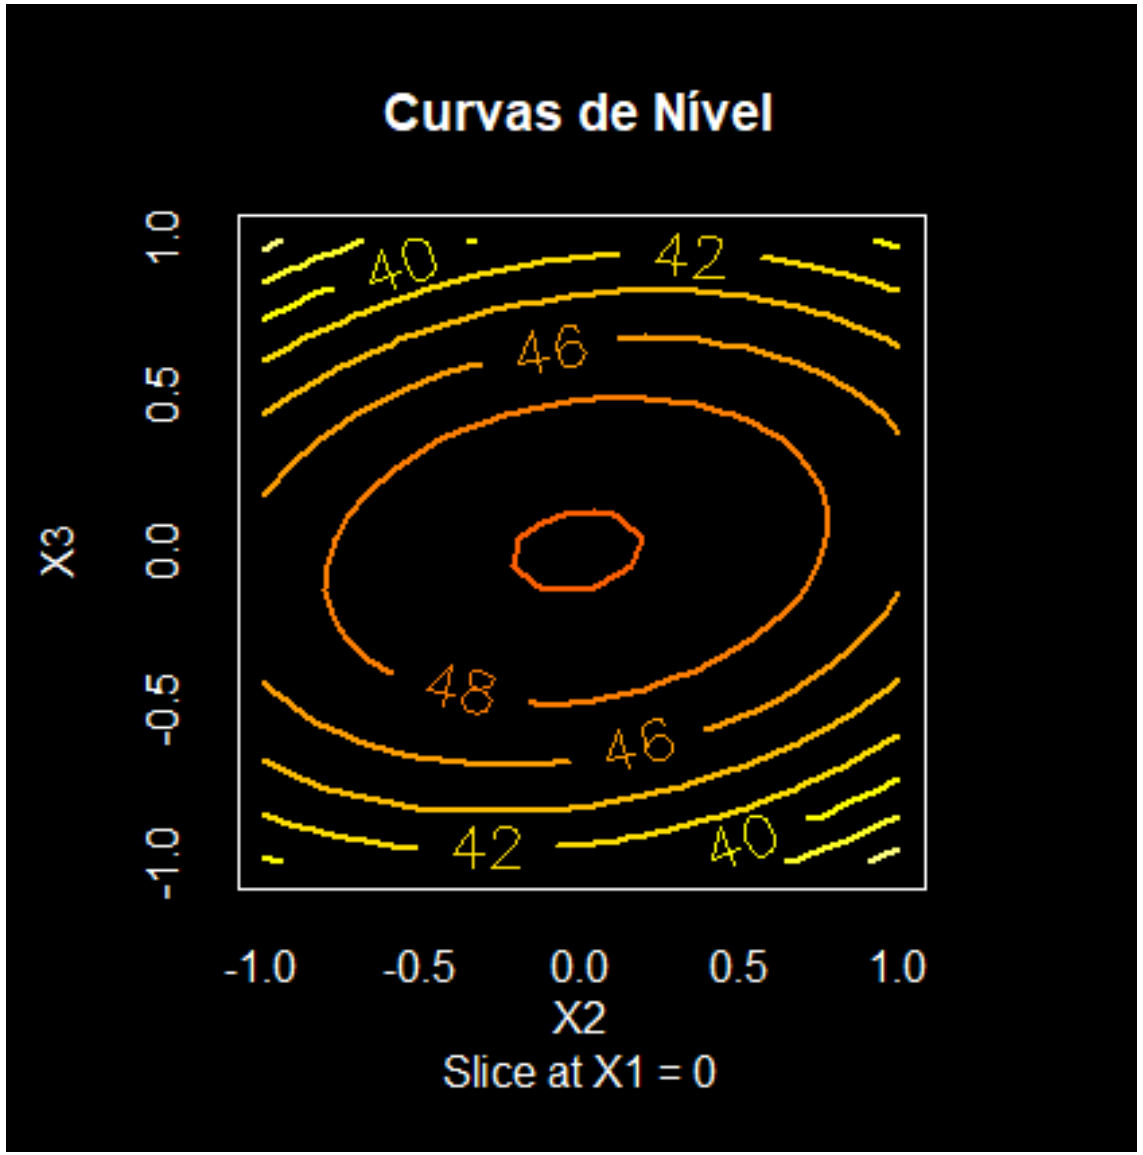
Curvas de Nível
40
42
46
48
46
42
40
1.0
0.5
0.0
-0.5
-1.0
X3
-1.0
-0.5
0.0
0.5
1.0
X2
Slice at X1 = 0

# Geração da superfície de resposta

```
# Geração da superfície de resposta: X1 e X2
persp(fit.model.BB, ~X1 + X2, main = "Superfície de Resposta", col = rainbow(40))
# Geração da superfície de resposta: X1 e X3
persp(fit.model.BB, ~X1 + X3, main = "Superfície de Resposta", col = rainbow(40))
# Geração da superfície de resposta: X2 e X3
persp(fit.model.BB, ~X2 + X3, main = "Superfície de Resposta", col = rainbow(40))
```

## Superfície de Resposta

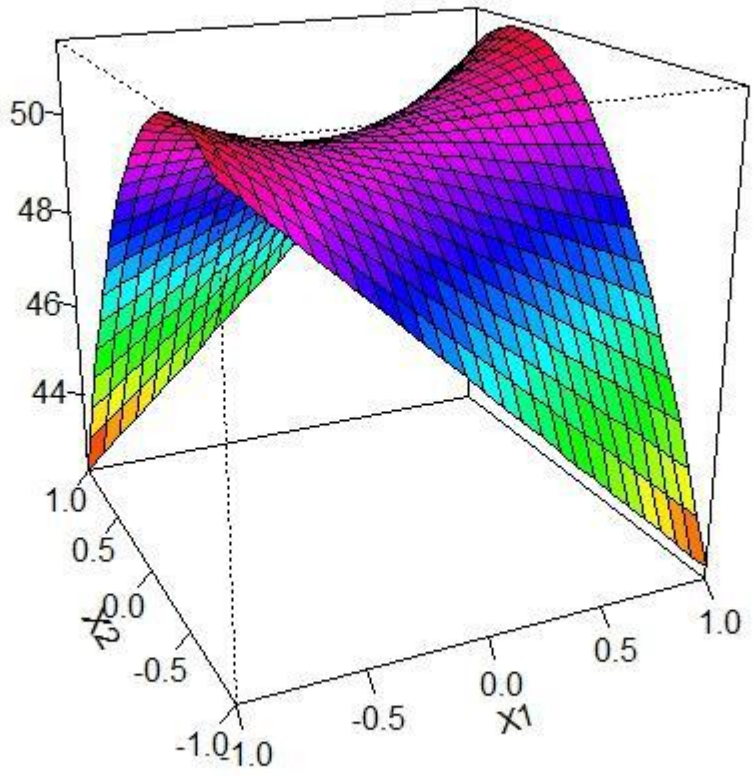


Slice at X3 = 0

## Superfície de Resposta

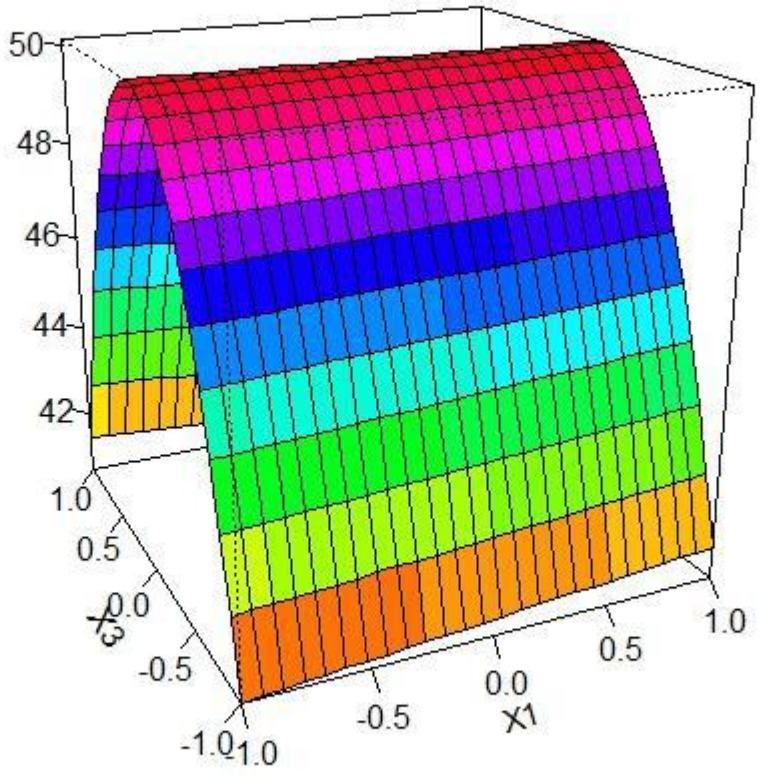


Slice at X2 = 0

## Superfície de Resposta

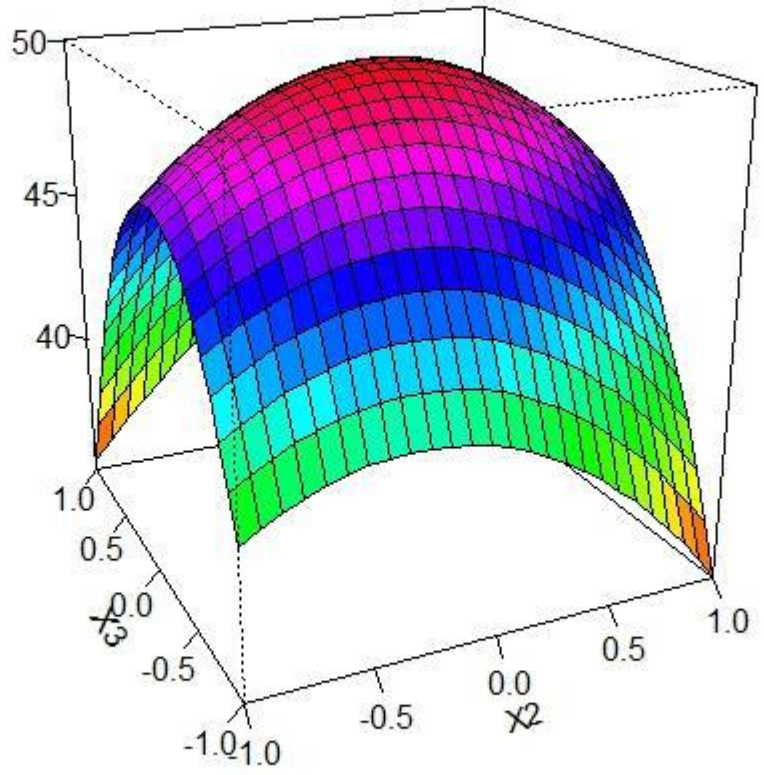


Slice at X1 = 0

# Planejamento Completo $3^k$: Exemplo

- Um experimento foi realizado para estudar o efeito de três tipos diferentes de garrafas de 32 onças (A) e três tipos diferentes de prateleiras (B) - prateleiras lisas permanentes, expositores de corredor final com prateleiras grelhadas e refrigeradores de bebidas - com estoque dez caixas de 12 garrafas nas prateleiras.
- Três trabalhadores (fator C) foram empregados neste experimento, e duas replicatas de um planejamento fatorial $3^3$ foram executadas.
- Os dados de tempo observados são mostrados na tabela a seguir.
- Analise os dados e tire conclusões.

| Trabalhador | Tipo de Garrafa | Replicata 1 | | | Replicata 2 | | |
|---|---|---|---|---|---|---|---|
| | | Permanente | Final do Corredor | Cooler | Permanente | Final do Corredor | Cooler |
| 1 | Plástico | 3,45 | 4,14 | 5,80 | 3,36 | 4,19 | 5,23 |
| | Vidro 28 mm | 4,07 | 4,38 | 5,48 | 3,52 | 4,26 | 4,85 |
| | Vidro 38 mm | 4,20 | 4,26 | 5,67 | 3,68 | 4,37 | 5,58 |
| 2 | Plástico | 4,80 | 5,22 | 6,21 | 4,40 | 4,70 | 5,88 |
| | Vidro 28 mm | 4,52 | 5,15 | 6,25 | 4,44 | 4,65 | 6,20 |
| | Vidro 38 mm | 4,96 | 5,17 | 6,03 | 4,39 | 4,75 | 6,38 |
| 3 | Plástico | 4,08 | 3,94 | 5,14 | 3,65 | 4,08 | 4,49 |
| | Vidro 28 mm | 4,30 | 4,53 | 4,99 | 4,04 | 4,08 | 4,59 |
| | Vidro 38 mm | 4,17 | 4,86 | 4,85 | 3,88 | 4,48 | 4,90 |

| Trabalhador | Tipo de Garrafa | Replicata 1 | | | Replicata 2 | | |
|---|---|---|---|---|---|---|---|
| | | -1 | 0 | +1 | -1 | 0 | +1 |
| -1 | -1 | 3,45 | 4,14 | 5,80 | 3,36 | 4,19 | 5,23 |
| | 0 | 4,07 | 4,38 | 5,48 | 3,52 | 4,26 | 4,85 |
| | +1 | 4,20 | 4,26 | 5,67 | 3,68 | 4,37 | 5,58 |
| 0 | -1 | 4,80 | 5,22 | 6,21 | 4,40 | 4,70 | 5,88 |
| | 0 | 4,52 | 5,15 | 6,25 | 4,44 | 4,65 | 6,20 |
| | +1 | 4,96 | 5,17 | 6,03 | 4,39 | 4,75 | 6,38 |
| +1 | -1 | 4,08 | 3,94 | 5,14 | 3,65 | 4,08 | 4,49 |
| | 0 | 4,30 | 4,53 | 4,99 | 4,04 | 4,08 | 4,59 |
| | +1 | 4,17 | 4,86 | 4,85 | 3,88 | 4,48 | 4,90 |

# Planejamento Fatorial $3^k$

```
# Requisição do pacote:
library(DoE.base)
# Criação do planejamento:
design <- fac.design(nlevels = 3, nfactors = 3, factor.names = list(x1 = c(-1, 0, 1),
+x2 = c(-1, 0, 1), x3 = c(-1, 0, 1)), replications = 2, randomize = FALSE)
x1 <- as.numeric(levels(design$x1)[design$x1])
x2 <- as.numeric(levels(design$x2)[design$x2])
x3 <- as.numeric(levels(design$x3)[design$x3])
```

# Resolução

```
# Vetor de respostas:

y <- c(3.45, 4.80, 4.08, 4.07, 4.52, 4.30, 4.20, 4.96, 4.17, 4.14, 5.22, 3.94, 4.38,
5.15, 4.53, 4.26, 5.17, 4.86, 5.80, 6.21, 5.14, 5.48, 6.25, 4.99, 5.67, 6.03, 4.85,
3.36, 4.40, 3.65, 3.52, 4.44, 4.04, 3.68, 4.39, 3.88, 4.19, 4.70, 4.08, 4.26, 4.65,
4.08, 4.37, 4.75, 4.48, 5.23, 5.88, 4.49, 4.85, 6.20, 4.59, 5.58, 6.38, 4.90)

# Criaçao do modelo de regressão:

model.C3K <- lm(y ~ x1*x2*x3 + I(x1^2) + I(x2^2) + I(x3^2))

# Análise do modelo:

summary(model.C3K)
```

```
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.028704   0.097699  51.471  < 2e-16 ***
x1          -0.040000   0.045226  -0.884 0.381371
x2           0.106111   0.045226   2.346 0.023642 *
x3           0.683611   0.045226  15.116  < 2e-16 ***
I(x1^2)     -0.796111   0.078333 -10.163 5.27e-13 ***
I(x2^2)      0.020556   0.078333   0.262 0.794257
I(x3^2)      0.278056   0.078333   3.550 0.000949 ***
x1:x2        0.007083   0.055390   0.128 0.898839
x1:x3       -0.228750   0.055390  -4.130 0.000164 ***
x2:x3       -0.036667   0.055390  -0.662 0.511521
x1:x2:x3     0.040625   0.067839   0.599 0.552417
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.2714 on 43 degrees of freedom
Multiple R-squared:  0.8955,    Adjusted R-squared:  0.8712
F-statistic: 36.86 on 10 and 43 DF,  p-value: < 2.2e-16
```

# Refinamento do modelo

```
model.c3k_1<-lm(y~x1*x2*x3-x1-x1:x2-x2:x3-x1:x2:x3+I(x1^2)+I(x3^2))
summary(model.c3k_1)
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.04241    0.07965  63.307  < 2e-16 ***
x2           0.10611    0.04363   2.432  0.01878 *
x3           0.68361    0.04363  15.670  < 2e-16 ***
I(x1^2)     -0.79611    0.07556 -10.536 4.46e-14 ***
I(x3^2)      0.27806    0.07556   3.680  0.00059 ***
x1:x3       -0.22875    0.05343  -4.281 8.85e-05 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.2618 on 48 degrees of freedom
Multiple R-squared:  0.8915,    Adjusted R-squared:  0.8802
F-statistic: 78.87 on 5 and 48 DF,  p-value: < 2.2e-16
```

# PlanejamentoBox-Behnken

- 14 ensaios (12 +2 replicatas no ponto central)

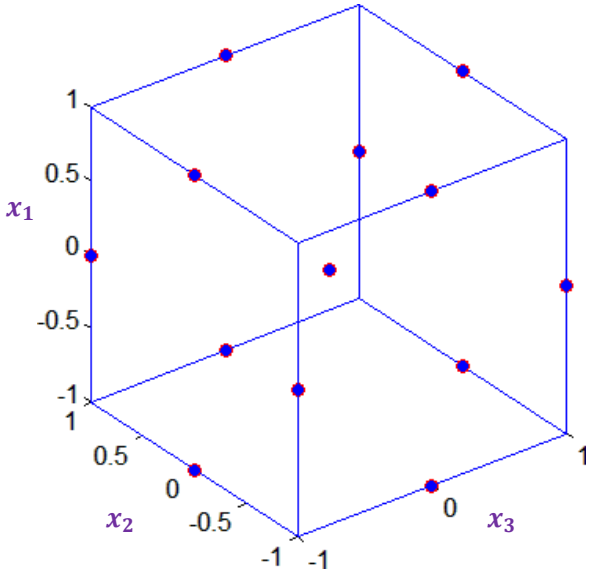


| Run | Order | Worker $x_1$ | Bottle $x_2$ | Shelf $x_3$ | y |
|---|---|---|---|---|---|
| 1 | 9 | -1.00 | -1.00 | 0.00 | 4.14 |
| 2 | 7 | 1.00 | -1.00 | 0.00 | 3.94 |
| 3 | 14 | -1.00 | 1.00 | 0.00 | 4.26 |
| 4 | 6 | 1.00 | 1.00 | 0.00 | 4.86 |
| 5 | 1 | -1.00 | 0.00 | -1.00 | 4.07 |
| 6 | 10 | 1.00 | 0.00 | -1.00 | 4.3 |
| 7 | 8 | -1.00 | 0.00 | 1.00 | 5.48 |
| 8 | 12 | 1.00 | 0.00 | 1.00 | 4.99 |
| 9 | 11 | 0.00 | -1.00 | -1.00 | 4.8 |
| 10 | 13 | 0.00 | 1.00 | -1.00 | 4.96 |
| 11 | 4 | 0.00 | -1.00 | 1.00 | 6.21 |
| 12 | 3 | 0.00 | 1.00 | 1.00 | 6.03 |
| 13 | 5 | 0.00 | 0.00 | 0.00 | 4.65 |
| 14 | 2 | 0.00 | 0.00 | 0.00 | 5.15 |

# Planejamento Box-Behnken

```
# Requisição do pacote:
library(rsm)
# Criação do planejamento Box-Behnken:
design.bbd <- bbd(3, n0 = 2, randomize = FALSE)
y <- c(4.14, 3.94, 4.26, 4.86, 4.07, 4.30, 5.48, 4.99, 4.80, 4.96, 6.21, 6.03, 4.65, 5.15)
# Criação do modelo:
model <- lm(y ~ x1*x2*x3 + I(x1^2) + I(x2^2) + I(x3^2), data = design.bbd)
# Análise do modelo:
summary(model)
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   4.9000     0.2055  23.840 1.84e-05 ***
x1            0.0175     0.1028   0.170  0.87305
x2            0.1275     0.1028   1.241  0.28252
x3            0.5725     0.1028   5.571  0.00509 **
I(x1^2)      -0.6950     0.1625  -4.277  0.01288 *
I(x2^2)       0.0950     0.1625   0.585  0.59017
I(x3^2)       0.5050     0.1625   3.108  0.03594 *
x1:x2         0.2000     0.1453   1.376  0.24080
x1:x3        -0.1800     0.1453  -1.239  0.28324
x2:x3        -0.0850     0.1453  -0.585  0.59004
x1:x2:x3          NA         NA      NA       NA
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.2907 on 4 degrees of freedom
Multiple R-squared:  0.9471,    Adjusted R-squared:  0.8282
F-statistic: 7.965 on 9 and 4 DF,  p-value: 0.03051
```

## Planejamento Completo $3^k$

$x_3 = 0{,}68$

$x_1 x_3 = -0{,}23$

$x_1^2 = -0{,}80$

$x_3^2 = 0{,}28$

## Planejamento Box-Behnken

$x_3 = 0{,}57$

$x_1^2 = -0{,}70$

$x_3^2 = 0{,}50$

# Planejamento e Otimização de Experimentos (DoE)

~~Planejamento Composto Central~~
~~Planejamento Híbrido~~
~~Planejamentos Ótimos~~
~~Planejamento Box-Behnken (BBD)~~
Planejamento Doehlert

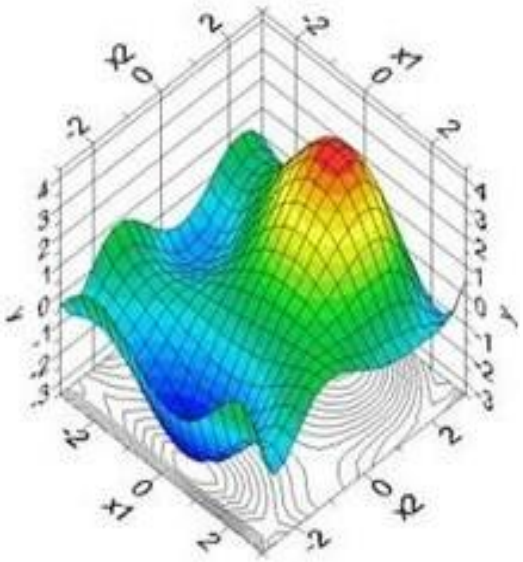

# Planejamento Doehlert

- O planejamento de Doehlert investiga os fatores em diferentes níveis, um em três, um em cinco e todos os outros em sete níveis.
- O planejamento é de preenchimento uniforme de espaço, sendo possível introduzir variações em novos fatores durante o curso de um estudo experimental, sem perder as corridas já realizadas.
- O planejamento Doehlert pode ser deslocado para regiões mais promissoras, preservando algumas das corridas já realizadas.
- O planejamento NÃO é ortogonal nem rotacionável, e a variação dos valores previstos não é uniforme ao longo do intervalo experimental.

# Planejamento Doehlert para dois fatores

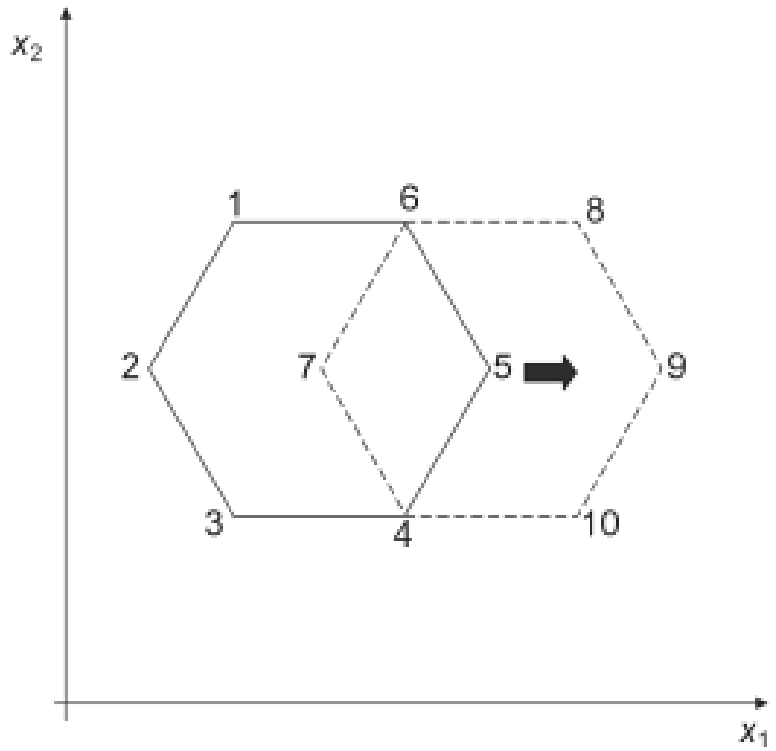


Mínimo = 7 ensaios, podendo ser aumentando para 10 ensaios.

# Planejamento Doehlert para três fatores

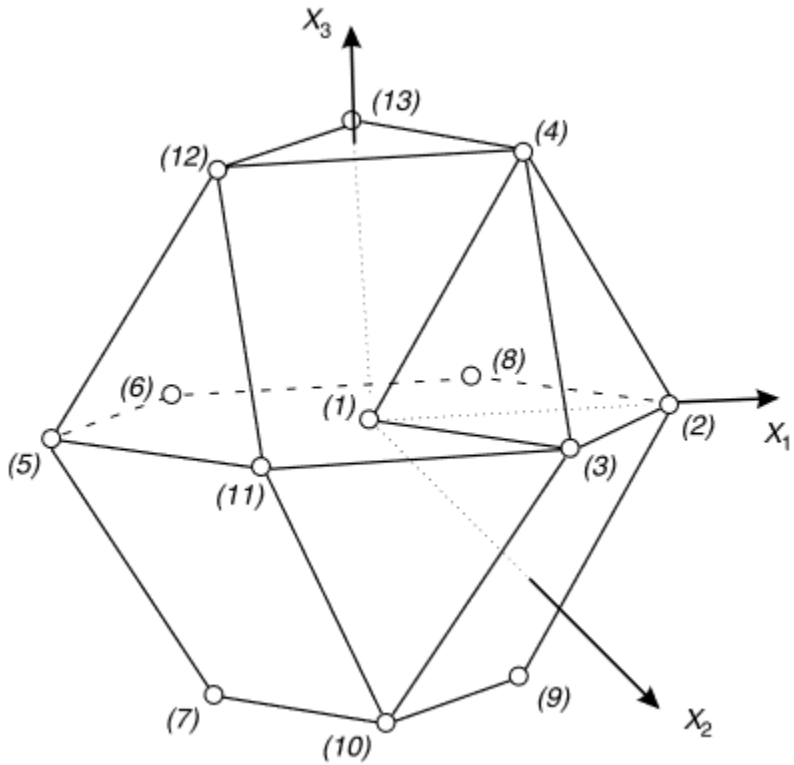


Equação do modelo

$$Y = b_0 + b_1X_1 + b_2X_2 + b_3X_3 + b_{11}X_1^2 + b_{22}X_2^2 + b_{33}X_3^2 + b_{12}X_1X_2 + b_{13}X_1X_3 + b_{23}X_2X_3$$

# Planejamento Doehlert

- **Pacote VdgRsm**
- Geração de Planejamento Doehlert para k = 2 -6
- Comando no R
- gen.USD(k, alpha = 1)
- Arguments
- k = Número de fatores ou variáveis independentes.
- Alpha = fator de escalamento
- Reference:
- Doehlert, D. H (1970), Uniform Shell Designs, Journal of the Royal Statistical Society, 19(3):231-239

# Exemplo de Planejamento Doehlert

- Um fabricante de inseticida pretende adaptar os seus produtos para os desejos do cliente. Ele deve equilibrar o seu produto, isto é, adequar as concentrações dos vários ingredientes para obter melhores resultados. Ele estudou os três componentes básicos que constituem o seu produto comercial:
- Inseticida: o componente que mata os vermes
- Knock down: uma substância que rapidamente adormece os vermes
- Sinérgico: um componente que reforça a ação do inseticida.

# Domínio Experimental/ Respostas

| Fator | Nível -1 | Nível 0 | Nível +1 |
|---|---|---|---|
| Inseticida (1), % | 0,01 | 0,03 | 0,05 |
| Knock down (2), % | 0,1 | 0,4 | 0,7 |
| Sinérgico (3), % | 0 | 1 | 2 |

- As respostas usadas neste exemplo são:
- **M24**: é a percentagem de vermes mortos em 24 horas. O objetivo é a obter este valor o mais alto possível.
- **KT50**: é o tempo em minutos para reduzir a população em 50%. Um valor de 5 minutos ou menos seria o ideal, mas um KT50 compreendido entre 5 e 10 minutos seria um bom resultado.

# Tabela de resultados Parte 1

| Ensaio | Inseticida | Knock down | Sinérgico | KT50 | M24 |
|---|---|---|---|---|---|
| 1 | 0 | 0 | 0 | 11 | 75 |
| 2 | + 1 | 0 | 0 | 15 | 57 |
| 3 | + 0,5 | + 0,866 | 0 | 11 | 56 |
| 4 | - 0,5 | + 0,866 | 0 | 6 | 65 |
| 5 | - 1 | 0 | 0 | 8 | 60 |
| 6 | - 0,5 | - 0,866 | 0 | 14 | 66 |
| 7 | + 0,5 | - 0,866 | 0 | 15 | 72 |
| 8 | 0 | 0 | 0 | 10 | 75 |

# Tabela de resultados Parte 2

| Ensaio | Inseticida | Knock down | Sinérgico | KT50 | M24 |
|---|---|---|---|---|---|
| 9 | - 0,5 | + 0,289 | + 0,816 | 2 | 91 |
| 10 | 0 | - 0,577 | + 0,816 | 8 | 99 |
| 11 | + 0,5 | + 0,289 | + 0,816 | 10 | 81 |
| 12 | - 0,5 | - 0,289 | - 0,816 | 11 | 72 |
| 13 | 0 | + 0,577 | - 0,816 | 8 | 81 |
| 14 | + 0,5 | - 0,289 | - 0,816 | 11 | 80 |
| 15 | 0 | 0 | 0 | 12 | 74 |

# Resolução

```
# Criar o objeto

B <- gen.USD(3)
```

| | x1 | x2 | x3 |
|---|---|---|---|
| 1 | 0.0 | 0.00000 | 0.0000 |
| 2 | 1.0 | 0.00000 | 0.0000 |
| 3 | -1.0 | 0.00000 | 0.0000 |
| 4 | 0.5 | 0.86602 | 0.0000 |
| 5 | -0.5 | -0.86602 | 0.0000 |
| 6 | 0.5 | -0.86602 | 0.0000 |
| 7 | -0.5 | 0.86602 | 0.0000 |
| 8 | 0.5 | 0.28868 | 0.8165 |
| 9 | -0.5 | -0.28868 | -0.8165 |
| 10 | 0.5 | -0.28868 | -0.8165 |
| 11 | 0.0 | 0.57735 | -0.8165 |
| 12 | -0.5 | 0.28868 | 0.8165 |
| 13 | 0.0 | -0.57735 | 0.8165 |

# Resolução

```
# Adicionar os ensaios 14 e 15 e alterar o planejamento
B2 <- matrix(rep(0, 6), nrow = 2, ncol = 3)
rownames(B2) <- c("14", "15")
colnames(B2) <- c("X1", "X2", "X3")
B <- rbind(B, B2)
KT50 <- c(11, 15, 8, 11, 14, 15, 6, 10, 11, 11, 8, 2, 8, 10, 12)
M24 <- c(75, 57, 60, 56, 66, 72, 65, 81, 72, 80, 81, 91, 99, 75, 74)
length(KT50) == length(M24)
```

| | X1 | X2 | X3 | KT50 | M24 |
|---|---|---|---|---|---|
| 1 | 0.0 | 0.00000 | 0.0000 | 11 | 75 |
| 2 | 1.0 | 0.00000 | 0.0000 | 15 | 57 |
| 3 | -1.0 | 0.00000 | 0.0000 | 8 | 60 |
| 4 | 0.5 | 0.86602 | 0.0000 | 11 | 56 |
| 5 | -0.5 | -0.86602 | 0.0000 | 14 | 66 |
| 6 | 0.5 | -0.86602 | 0.0000 | 15 | 72 |
| 7 | -0.5 | 0.86602 | 0.0000 | 6 | 65 |
| 8 | 0.5 | 0.28868 | 0.8165 | 10 | 81 |
| 9 | -0.5 | -0.28868 | -0.8165 | 11 | 72 |
| 10 | 0.5 | -0.28868 | -0.8165 | 11 | 80 |
| 11 | 0.0 | 0.57735 | -0.8165 | 8 | 81 |
| 12 | -0.5 | 0.28868 | 0.8165 | 2 | 91 |
| 13 | 0.0 | -0.57735 | 0.8165 | 8 | 99 |
| 14 | 0.0 | 0.00000 | 0.0000 | 10 | 75 |
| 15 | 0.0 | 0.00000 | 0.0000 | 12 | 74 |

# Análise do modelo (KT50)

```
# Análise do modelo (KT50)
lm.DO.1 <- rsm(KT50 ~ FO(X1, X2, X3) + TWI(X1, X2) + TWI(X1, X3) + SO(X1, X2, X3), data = B)
summary(lm.DO.1)
```

```
            Estimate Std. Error t value  Pr(>|t|)
(Intercept) 11.00000    0.42818 25.6903 1.669e-06 ***
x1           3.50000    0.37081  9.4387 0.0002254 ***
x2          -3.31977    0.37081 -8.9527 0.0002898 ***
x3          -2.04122    0.37081 -5.5047 0.0027048 **
x1:x2        2.30942    0.85636  2.6968 0.0429489 *
x1:x3        4.08245    0.95743  4.2640 0.0079846 **
x2:x3        0.70710    0.95742  0.7385 0.4933700
x1^2         0.50000    0.67701  0.7385 0.4933700
x2^2         0.50001    0.67702  0.7385 0.4933700
x3^2        -4.24997    0.64226 -6.6172 0.0011861 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.9834,    Adjusted R-squared:  0.9535
F-statistic: 32.93 on 9 and 5 DF,  p-value: 0.0006336
```

```
Analysis of Variance Table

Response: KT50
                 Df  Sum Sq Mean Sq F value    Pr(>F)
FO(X1, X2, X3)    3 109.750  36.583  66.514 0.0001887
TWI(X1, X2)       1  10.000  10.000  18.182 0.0079842
TWI(X1, X3)       1  10.000  10.000  18.181 0.0079846
TWI(X1, X2, X3)   1   0.333   0.333   0.606 0.4715203
PQ(X1, X2, X3)    3  32.900  10.967  19.939 0.0032727
Residuals         5   2.750   0.550
Lack of fit       3   0.750   0.250   0.250 0.8575659
Pure error        2   2.000   1.000
```

```
Stationary point of response surface:
       x1        x2        x3
 3.068173 -4.380380  0.869073

Eigenanalysis:
eigen() decomposition
$values
[1]  2.1421335 -0.3845513 -5.0075462

$vectors
        [,1]       [,2]        [,3]
x1 0.7577136  0.5508341  0.34993117
x2 0.5919517 -0.8058647 -0.01323715
x3 0.2747057  0.2171723 -0.93668188
```

# Resolução

```
# Análise do modelo (M24)
lm.DO.2 <- rsm(M24 ~ FO(X1, X2, X3) +
               TWI(X1, X2) + TWI(X1, X3) + TWI(X2, X3) +
               SO(X1, X2, X3), data = B)
summary(lm.DO.2)
```

```
            Estimate Std. Error  t value  Pr(>|t|)
(Intercept)  74.66667    0.24721 302.0376 7.550e-12 ***
x1           -1.37500    0.21409  -6.4225  0.001359 **
x2           -4.83532    0.21409 -22.5854 3.163e-06 ***
x3            7.75670    0.21409  36.2312 3.015e-07 ***
x1:x2        -8.66031    0.49442 -17.5160 1.112e-05 ***
x1:x3        -7.96074    0.55278 -14.4014 2.911e-05 ***
x2:x3        -9.78155    0.55277 -17.6954 1.057e-05 ***
x1^2        -16.16667    0.39087 -41.3604 1.558e-07 ***
x2^2         -7.83343    0.39088 -20.0406 5.718e-06 ***
x3^2         19.99992    0.37081  53.9356 4.143e-08 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Multiple R-squared:  0.9995,    Adjusted R-squared:  0.9987
F-statistic:  1217 on 9 and 5 DF,  p-value: 8.268e-08
```

```
Analysis of Variance Table

Response: M24
                 Df  Sum Sq Mean Sq F value    Pr(>F)
FO(X1, X2, X3)    3  341.75  113.92  621.35 7.533e-07
TWI(X1, X2)       1   99.23   99.23  541.22 2.731e-06
TWI(X1, X3)       1   38.02   38.02  207.40 2.911e-05
TWI(X2, X3)       1  108.00  108.00  589.05 2.213e-06
PQ(X1, X2, X3)    3 1421.69  473.90 2584.82 2.147e-08
Residuals         5    0.92    0.18
Lack of fit       3    0.25    0.08    0.25    0.8576
Pure error        2    0.67    0.33
```

```
Stationary point of response surface:
         x1          x2          x3
 0.06843111 -0.20291180 -0.22991931

Eigenanalysis:
eigen() decomposition
$values
[1]  21.114337  -6.289793 -18.824724
```