UNIVERSIDADE DO ESTADO DO RIO DE JANEIRO

Instituto de Química

Departamento de Química Analítica

Programa de Pós-Graduação em Engenharia Química

MINICURSO DE CORRELAÇÃO, REGRESSÃO LINEAR SIMPLES E ANOVA

Prof. Dr. Aderval S. Luna

Rio de Janeiro, 2016

Programa 3:

- Correlação e Regressão linear simples;
- ANOVA.

CORRELAÇÃO E REGRESSÃO LINEAR SIMPLES

A regressão e a correlação são técnicas utilizadas para estimar uma relação entre duas variáveis medidas simultaneamente nas medidas amostrais a uma população. A análise de correlação e de regressão compreende os pontos complementares de análise de dados amostrais para saber como duas variáveis estão relacionadas uma com a outra. (Silva et al., 2009).

Correlação

O **coeficiente de correlação** linear (ou coeficiente de correlação de Pearson) mede a força ou o grau de dependência entre duas variáveis, o qual varia entre -1 e 1 (refere ao coeficiente de correlação de Pearson). Podemos ver a relação entre duas variáveis pela construção de um gráfico chamado diagrama de dispersão.

Diagrama de Dispersão – é um gráfico no qual os dados amostrais emparelhados são plotados com um eixo horizontal *x* e um eixo vertical *y*. Cada par individual (x,y) é plotado como único ponto (Triola, 2005).

O coeficiente de correlação *r* é dado por:

$$r = \frac{n\sum xy - \left(\sum x\right)\left(\sum y\right)}{\sqrt{n\left(\sum x^2\right) - \left(\sum x\right)^2}\sqrt{n\left(\sum y^2\right) - \left(\sum y\right)^2}}.$$

No R é calculado podemos calcular pela função `cor(x,y)`.

Temos os seguintes tipos de correlações:

- **Correlação Fraca ou Nula -** quando o diagrama de dispersão não permite o ajustamento de nenhuma reta, o que significa que $r = 0$. Diz-se, então, que não existe nenhuma relação entre as variáveis da Distribuição Bidimensional.

Para gerar amostra de uma distribuição multivariada precisa-se baixar o pacote MASS.

```
# no R:
> library(MASS)  # abrir pacote para utilizar suas funções
> sigma<-matrix(c(400,80,80,80,80,400,80,80,80,80,400,80,80,
80,80,400), 4, 4)
> mu <- c(100,150,200,250)
> bi <- mvrnorm(n=100, mu=mu, Sigma=sigma)
> cor(bi)
> plot(bi,main="correlação fraca"))
```

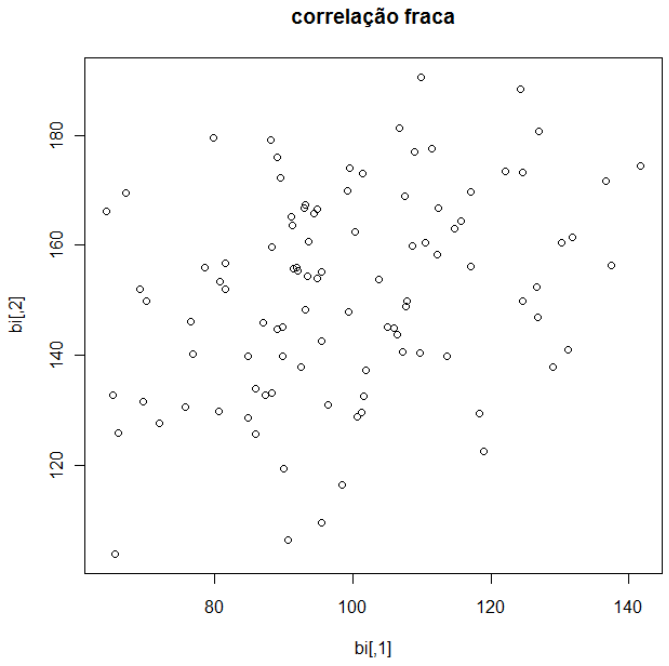

- **Correlação Negativa Forte** - quando a reta de regressão, obtida a partir do diagrama de dispersão, tem declive negativo. A correlação é negativa quando *r* varia entre -1 e 0 e será tanto mais forte quanto *r* se aproxima de -1.

```
> sigma <- matrix(c(10,-3,-3,2),2,2)
> sigma
> u<-mvrnorm(n=500, rep(0, 2), sigma)
> plot(u, main="correlação negativa forte")
> cor(u)
```

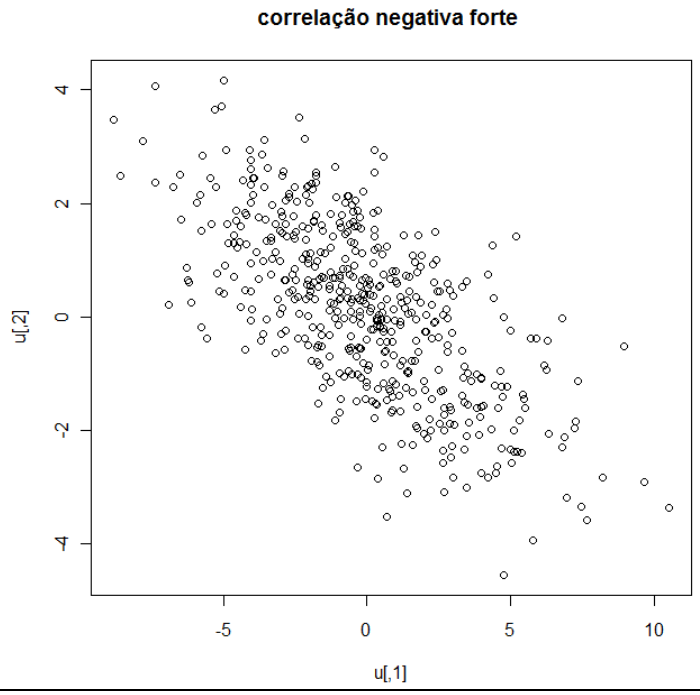

- **Correlação Negativa Perfeita ou Linear -** quando a reta de regressão, obtida a partir do diagrama de dispersão, tem declive negativo com $r = -1$.

```
> sigma <- matrix(c(1,-1,-1,1),2,2)
> b<-mvrnorm(n=500, rep(0,2), sigma)
> plot(b, main="correlação negativa perfeita")
> cor(b)
```

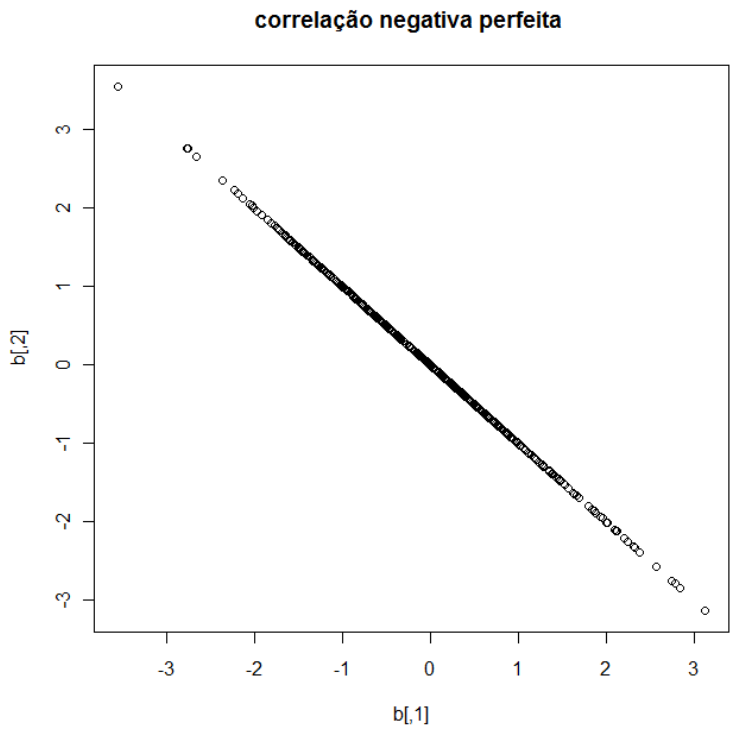

- **Correlação Positiva Forte -** quando a reta de regressão, obtida a partir do diagrama de dispersão, tem declive positivo. A correlação é positiva quando r varia entre 0 e 1 e será tanto mais forte quanto r se aproxima de 1.

```
> sigma <- matrix(c(10,3,3,2),2,2)
> sigma
> a<-mvrnorm(n=500, rep(0, 2), sigma)
> plot(a, main="correlação positiva forte")
> cor(a)
```

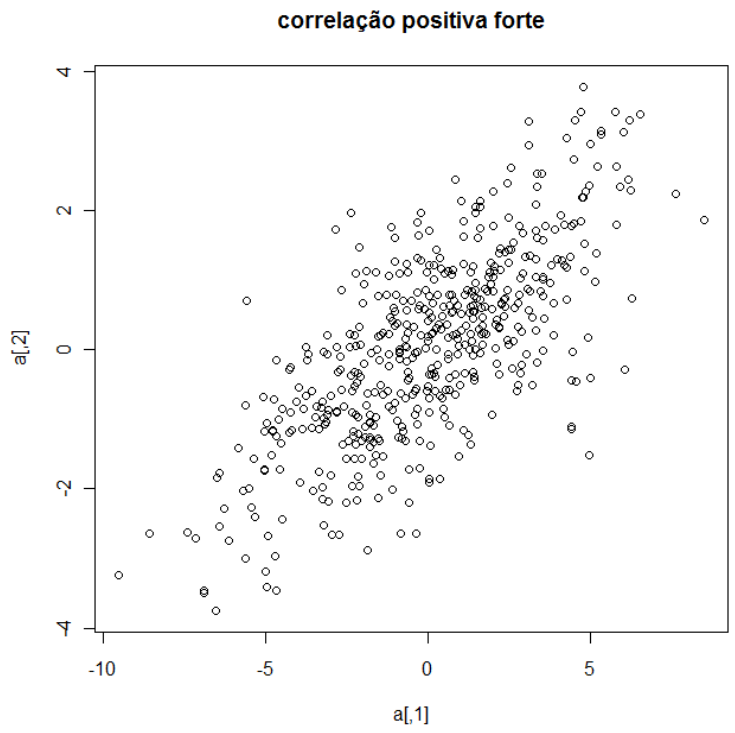

- **Correlação Positiva Perfeita ou Linear** - quando a reta de regressão, obtida a partir do Diagrama de Dispersão, tem declive positivo.

```
> sigma <- matrix(c(1,1,1,1),2,2)
> sigma
> w<-mvrnorm(n=500, rep(0, 2), sigma)
> plot(w, main="correlação positiva perfeita")
> cor(w)
```

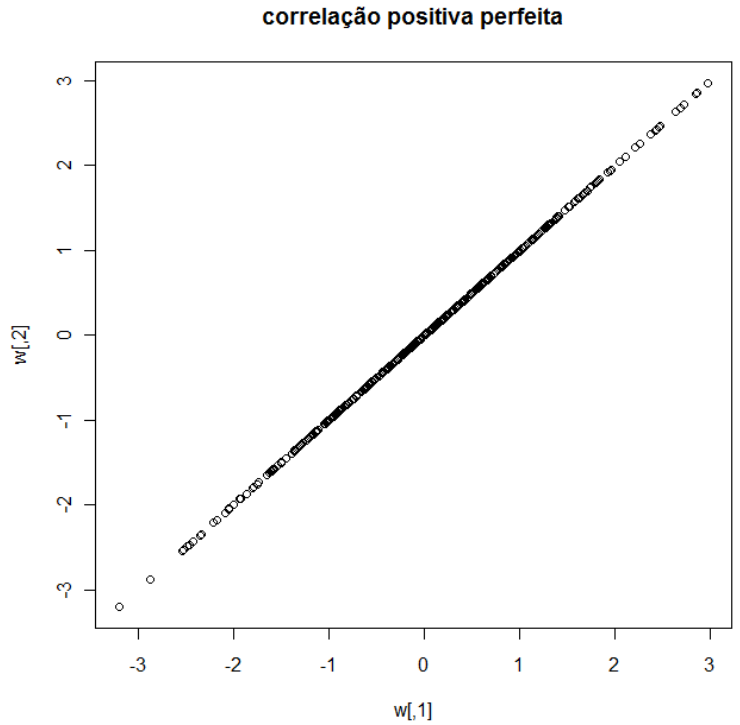

TESTE DE HIPÓTESE PARA CORRELAÇÃO

Hipótese:

$$H_0 : \rho = 0 \qquad (\textit{não há correlação})$$
$$H_1 : \rho \neq 0 \qquad (\textit{há correlação})$$

A estatística de teste é dada por: $t = \dfrac{r - \rho}{\sqrt{\dfrac{1 - r^2}{n - 2}}}$

No R é calculado pela função `cor.test(x,y)`.

Aplicação

Para uma amostra de oito operadores de máquina, foram coletados o número de horas de treinamento (x) e o tempo necessário para completar o trabalho (y). Os dados coletados encontram-se na tabela abaixo (Silva et al., 2009):

y	5,2	5,1	4,9	4,6	4,7	4,8	4,6	4,9
x	13	15	18	20	19	17	21	16

Pede-se:

a) Faça o gráfico de dispersão para esses dados.

b) Calcule e interprete os coeficientes de correlação (*r*) e faça o teste de hipótese.

a) #dados:

```
> y <- c(5.2,5.1,4.9,4.6,4.7,4.8,4.6,4.9)
> x <- c(13,15,18,20,19,17,21,16)
> x
[1] 13 15 18 20 19 17 21 16
> y
[1] 5.2 5.1 4.9 4.6 4.7 4.8 4.6 4.9

> plot(x,y)
```

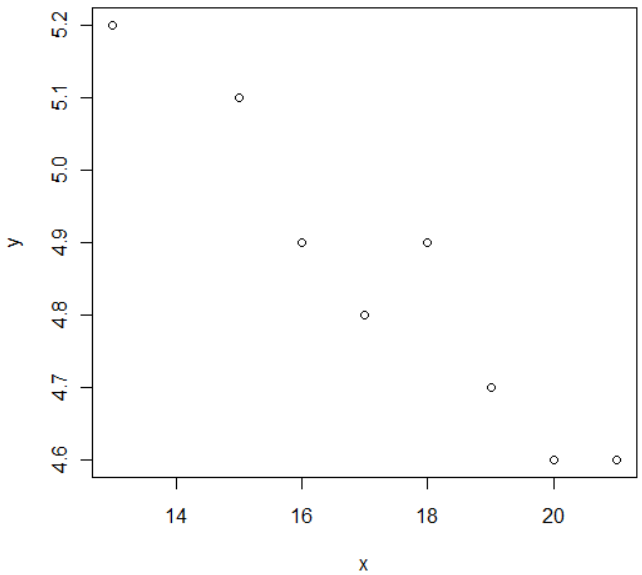

Figura 1: Dispersão dos dados

b) #calculando a correlação:

```
> cor(x,y)
```

[1] -0.9592155

Podemos interpretar o sinal negativo como sendo causado pelo decrescimento do valor de y ao longo de x. Por outro lado, se tomarmos o módulo de *r*, terá uma correlação forte, o que indica que o tempo necessário para completar o trabalho decresce quase que na mesma proporção com que aumenta o número de horas do treinamento. Em outras palavras, *y* decresce quase na mesma velocidade com que *x* cresce.

Teste de hipótese

```
> cor.test(x,y)
        Pearson's product-moment correlation
data:  x and y
t = -8.312, df = 6, p-value = 0.0001645
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.9928131 -0.7854632
sample estimates:
       cor
-0.9592155
```

Portanto, rejeita-se H_0, ou seja, o p-valor acima mostra que a correlação encontrada de -0.96 difere significativamente de zero.

Regressão linear simples

A **regressão** dá a equação que descreve o relacionamento em termos matemáticos, pressupondo alguma relação de causa e efeito entre as variáveis. Por exemplo: a idade e a altura de cada indivíduo. A regressão linear simples constitui uma tentativa de estabelecer uma equação matemática linear (reta) com apenas uma variável dependente que descreva o relacionamento entre duas variáveis (Silva et al., 2009). A equação é dada por

$$y = a + bx + \varepsilon$$

Onde *x* é a variável explicativa, independente ou preditora; *y* é a variável explicada, dependente ou resposta; **ε** é chamado de erro que corresponde ao desvio entre o valor real e o aproximado (pela reta) de *y*. Isso porque sempre teremos observações amostrais que não são pontos da reta.

Para podermos verificar se a correlação é linear devemos fazer uma análise gráfica do fenômeno em estudo. Para isso, devemos traçar um esboço do gráfico de dispersão.

OBS: Existe uma distinção importante entre correlação e regressão.
Correlação – (x,y): analisa os dados em conjunto (elementos bidimensionais).
Regressão – (y/x): y é condicionado a x fixado.

A equação linear pode ser obtida no R por meio da função `lm()` que serve para calcular a regressão linear simples.

#Sintaxe

```
> lm(y~x,dados)          #lê-se "y~x" = y depende de x
```

Aplicação

Considerando os dados x e y apresentados anteriormente, podemos determinar:

a) O modelo de regressão linear simples entre as variáveis “x” e “y”.

b) Trace a reta de regressão juntamente com o gráfico de dispersão.

a) #obtendo o modelo de regressão

```
> y <- c(5.2,5.1,4.9,4.6,4.7,4.8,4.6,4.9)
> x <- c(13,15,18,20,19,17,21,16)
> reg<-lm(y~x)
```

```
> reg
```

#resposta do R:
Call:
lm(formula = y ~ x)
Coefficients:
(Intercept) x
  6.2261 -0.0792

Podemos concluir que a equação da reta que melhor aproxima os pontos é

$\hat{y}_x = 6{,}2261 - 0{,}0792x.$

b) # traçando a reta de regressão juntamente com o gráfico de dispersão:

```
>z<-plot(x,y)
>grid(z)
>abline(reg)
```

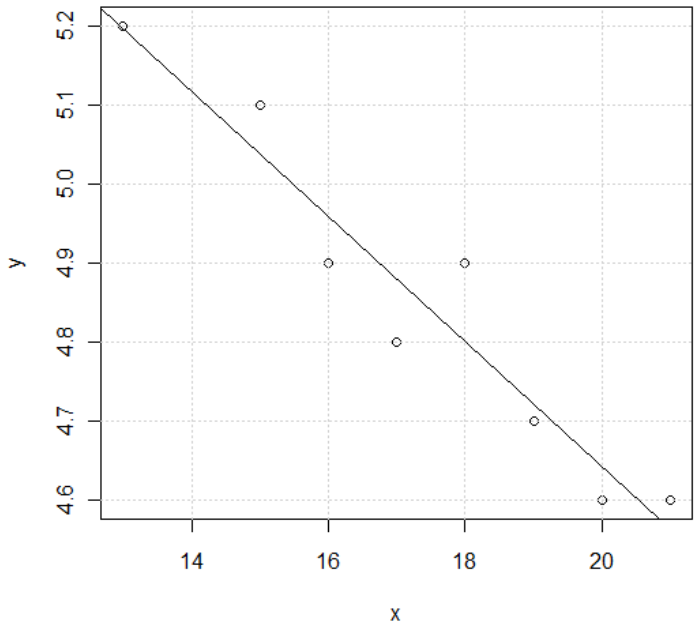

Figura 2: Reta de regressão

Verificando os resultados da função *lm():*

```
> summary(reg)
```

#resposta do R:
Call:
lm(formula = y ~ x)

```
Residuals:
     Min          1Q         Median         3Q          Max
-0.079699   -0.046303   -0.008897    0.043296   0.099499

Coefficients:
                Estimate    Std. Error     t value    Pr(>|t|)
(Intercept)   6.226065    0.167253     37.225    2.51e-08 ***
x              -0.079198   0.009528    -8.312     0.000164 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.06729 on 6 degrees of freedom
Multiple R-squared: 0.9201,     Adjusted R-squared: 0.9068
F-statistic: 69.09 on 1 and 6 DF,  p-value: 0.0001645
```

Como o valor retornado pela função `lm()` é uma lista, podemos verificar isso da seguinte forma:

```
> is.list(reg)        #verifica se “reg” é uma lista
[1] TRUE

> names(reg)              #lista o que está armazenado em reg
 [1] "coefficients"  "residuals"     "effects"       "rank"
 [5] "fitted.values" "assign"        "qr"            "df.residual"
 [9] "xlevels"       "call"          "terms"         "model"
```

Os comandos mais importantes listados são os seguintes:

- `reg$fitted.values` ou `predict()`: calcula os valores preditos da variável resposta para cada elemento da amostra (faz uma previsão);
- `reg$residuals`: calcula o erro ou os resíduos (valor observado - valor predito)para cada ponto da amostra;
- `reg$coefficients`: obtém uma estimativa dos coeficientes da regressão.

Para obtermos outros gráficos para análise

```
>par(mfrow=c(2,2))
>plot(reg)
```

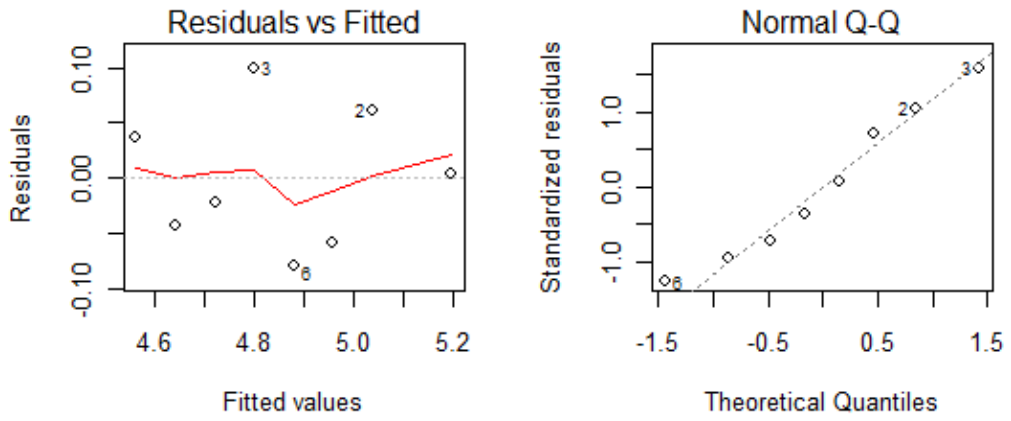

Figura 3: gráfico dos resíduos $(y - \hat{y})$ x valores ajustados $(\hat{y})$ e gráfico que indica a normalidade dos resíduos

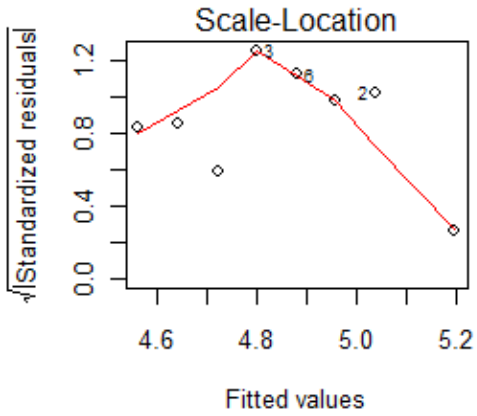

Figura 4: valores ajustados x raiz quadrada dos resíduos padronizados (verifica a homocedasticidade)

Aplicação 2

A tabela a seguir exibe dados aos pares de barcos/ peixe-boi para cada ano (exercício de Triola, 2005, p. 380)

Tabela 1 – Barcos de passeio registrados na Flórida (em dezenas de milhares) e mortes de peixes-boi relacionadas com os barcos.

Ano	**1991**	**1992**	**1993**	**1994**	**1995**	**1996**	**1997**	**1998**	**1999**	**2000**
x: Barcos	68	68	67	70	71	73	76	81	83	84
y: Mortes de peixes-boi	53	38	35	49	42	60	54	67	82	78

Podemos calcular o coeficiente de correlação *r*

```
> x<-c(68,68,67,70,71,73,76,81,83,84)
> y<-c(53,38,35,49,42,60,54,67,82,78)
> r<-cor(x,y)
[1] 0.921523
```

Calculando o coeficiente de determinação

```
> r2<-r^2
> r2
[1] 0.8492045
```

Concluímos que cerca de 85% das mortes dos peixes-boi por barcos pode ser explicada pela relação linear entre o número de registros de barcos e o número de mortes de peixes-boi por barcos. Isto implica que cerca de 15% da variação em tais mortes são explicados por outros fatores.

```
> cor.test(x,y)

        Pearson's product-moment correlation
data:  x and y
t = 6.7121, df = 8, p-value = 0.0001508
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.6953480 0.9816064
sample estimates:
     cor
0.921523
```

A estatística *t*=6.71 indica que rejeitaríamos Ho, pois o *t* encontra-se na área de rejeição, onde os valores críticos de *t* tabelados são $\pm 2{,}306$. Concluímos que há uma correlação entre *x* e *y*.

```
> lm(y~x)
Call:
lm(formula = y ~ x)
```

```
Coefficients:
(Intercept)          x
  -112.710       2.274
```

A reta de regressão ajustada será $\hat{y}_x = -112.7 + 2.27x$

Adaptando o exercício acima, podemos ajustar a reta de regressão da seguinte maneira no R:

```
> x<- c(68,68,67,70,71,73,74,76,80,81,83,84)
> n<- length(x)
> a<-(-113)
> b<- 2.27
> y<-rnorm(n,a+b*x,6)
> plot(x,y)
> y.aj <- lm(y~x)
> abline(y.aj)
> summary(y.aj)
Call:
lm(formula = y ~ x)

Residuals:
   Min     1Q Median     3Q    Max
-7.423 -3.044  1.164  2.475  8.501

Coefficients:
              Estimate    Std. Error   t value   Pr(>|t|)
(Intercept)   -74.1811    17.8630   -4.153    0.00197 **
x               1.7444     0.2388    7.306    2.58e-05 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 4.852 on 10 degrees of freedom      ## ajuste do resíduo (erro)
Multiple R-squared: 0.8422,     Adjusted R-squared: 0.8264
F-statistic: 53.38 on 1 and 10 DF,  p-value: 2.583e-05
```

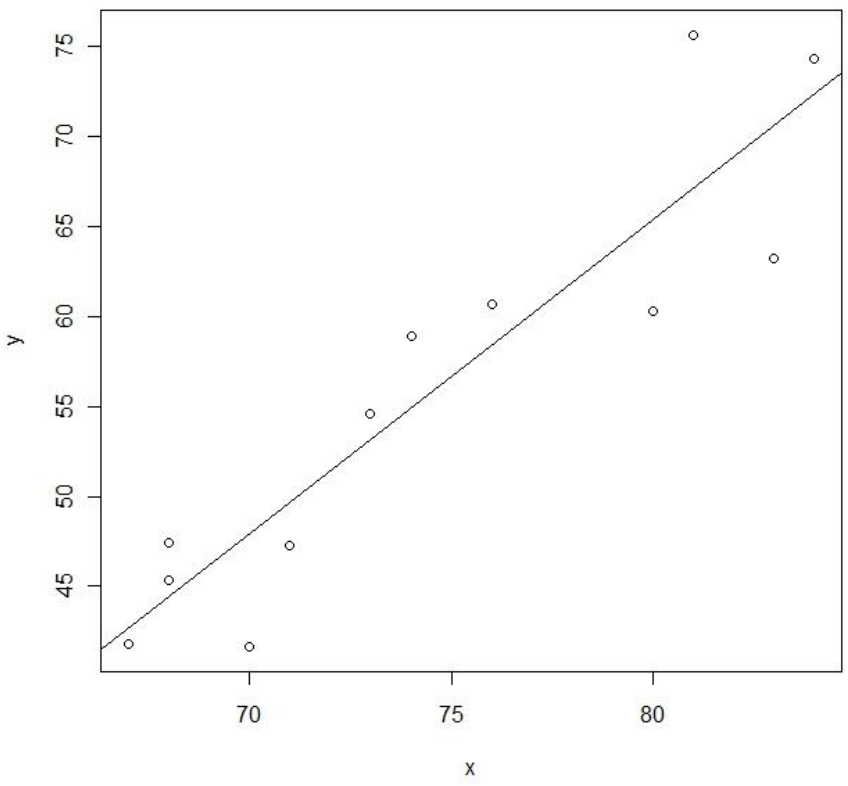

Figura 5: gráfico de dispersão com a reta de regressão ajustada

ANÁLISE DA VARIÂNCIA (ANOVA)

Definição: Variância (σ^2) é a medida que permite avaliar o grau de dispersão dos valores da variável em relação à média.

Interpretação de (y ~ x) = y depende de x.

Os dados utilizados para análise da variância são de Box, Hunter e Hunter (1978), os quais também foram utilizados na apostila de Julian J. Faraway (2002), e da apostila do professor Paul G. Kinas.

Experimentos inteiramente ao acaso: Fatores Fixos

O modelo: $Y_{ij} = \mu + \tau_i + e_{ij}$ para $i = 1, ..., k$ e $j = 1,..., r_i$

$E(e_{ij}) = 0$ $V(e_{ij}) = \sigma^2$

Análise Estatística:

Hipóteses: H_0: $\mu_1 = \mu_2 = ... = \mu_k$ $[\tau_1 = \tau_2 = ... = \tau_k = 0]$

H_1: ao menos um μ_i é diferente (i = 1, 2,..., k)

Suposições: e_{ij} : $N(0, \sigma^2)$ e H_0 é verdadeiro.

Análise no R: exemplo

Os dados que usaremos é um conjunto de 24 tempos de coagulação de sangue. Foram nomeados aleatoriamente 24 animais para quatro dietas diferentes e as amostras foram escolhidas em ordem aleatória (em anexo os dados completos).

	coag	diet
1	62	A
2	60	A
⋮	⋮	⋮
22	64	D
23	63	D
24	59	D

Rodamos a análise de variância pelo teste `aov` para verificar diferenças em tempo de coagulação media (variável coag) entre as amostras tiradas em diferentes dietas (fator diet)

importando tabela de dados:

```
>dados<-read.table("coagulation.txt", header = T)
>coag<-dados$coag
>diet<-dados$diet
> coag
 [1] 62 60 63 59 63 67 71 64 65 66 68 66 71 67 68 68 56 62 60 61 63 64 63 59
> diet
 [1] A A A A B B B B B B C C C C C C D D D D D D D D
Levels: A B C D

> tapply(coag,diet,mean)      # média por dieta
```

```
#realizando análise ANOVA
>tab.anova<-aov(formula = coag~diet)
> tab.anova

Terms:
                    diet    Residuals
Sum of Squares   228       112
Deg. of Freedom    3         20
```

```
Residual standard error: 2.366432
Estimated effects may be unbalanced
```

```
>summary(tab.anova)                    #olhar a tabela de anova

            Df    Sum Sq    Mean Sq    F value    Pr(>F)
diet         3     228       76.0       13.571    4.658e-05 ***
Residuals   20     112       5.6
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
>coef(tab.anova)          #ler os coeficientes   ou  lm(dados$coa ~ dados$diet),
                          # serve para ajustar o modelo  y = a.x + b aos dados.

(Intercept)        dietB              dietC              dietD
 6.100000e+01   5.000000e+00   7.000000e+00   -1.071287e-14

>residuos<-resid(tab.anova)     #obtendo os resíduos
>residuos
```

```
>TukeyHSD(tab.anova, ordered=T)

Fit: aov(formula = coag ~ diet)
$diet
          diff              lwr          upr          p adj
A-D   1.421085e-14   -4.0560438   4.056044   1.0000000
B-D   5.000000e+00   1.4229056   8.577094   0.0044114
C-D   7.000000e+00   3.4229056   10.577094  0.0001268
B-A   5.000000e+00   0.7245544   9.275446   0.0183283
C-A   7.000000e+00   2.7245544   11.275446  0.0009577
C-B   2.000000e+00   -1.8240748  5.824075   0.4766005
```

```
> plot(TukeyHSD(tab.anova,ordered=T))
```

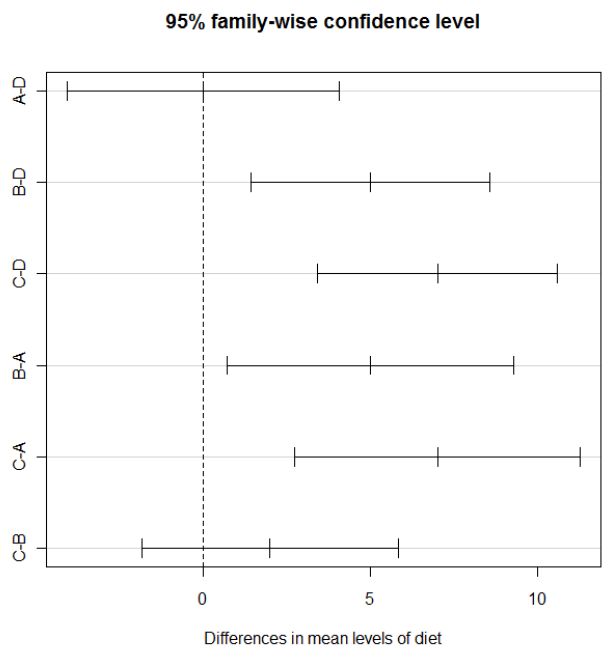

Figura 6: gráfico das diferenças ordenadas

Alguns gráficos

```
>boxplot(coag~diet)
```

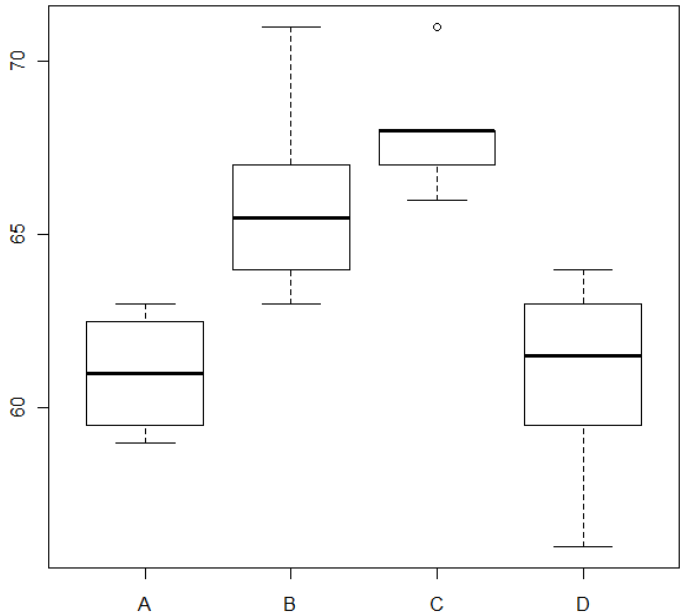

Figura 7: médias por dietas

```
>plot(diet,residuos)
>abline(h=0)
```

traçar uma linha horizontal sobre o valor zero dos resíduos

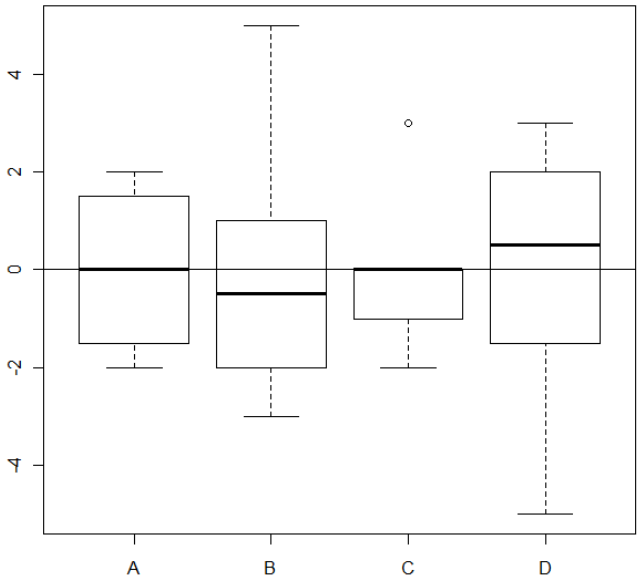

Figura 8: gráfico dos resíduos em função das dietas

Gráficos de diagnóstico

```
par(mfrow=c(2,2))
plot(tab.anova)
```

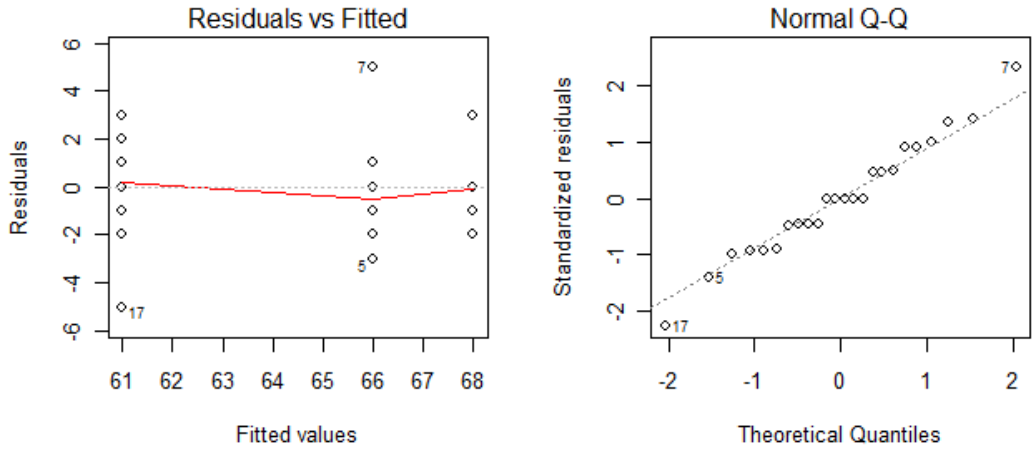

Figura 9: gráfico dos resíduos x valores ajustados e gráfico que indica a normalidade dos resíduos

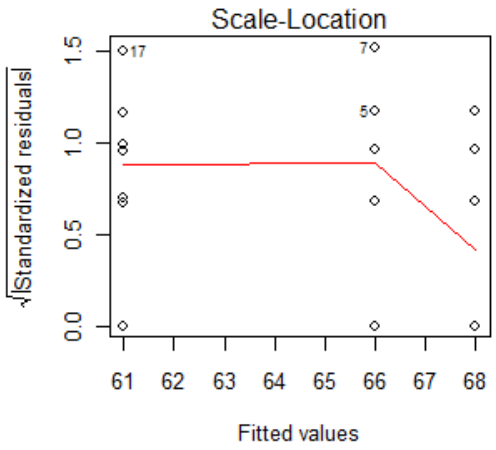

Figura 10: valores ajustados x raiz quadrada dos resíduos padronizados (verifica a homocedasticidade)

#ou também, é possível plotar alguns dos mesmos gráficos feitos acima de forma separada:

```
>qqnorm(residuos)        #ou qqnorm(tab.anova$res)
>qqline(residuos)        #traçar uma linha
>plot(tab.anova$fit,tab.anova$res,xlab="Fitted",ylab="Residuals"
,main="Residual-Fitted plot")
```

Referências

Box, G. P.; Hunter, W. G. e Hunter J. S. (1978). *Statistics for Experimenters*. New York: Wiley.

Faraway, J. J. (2002). *Practical Regression and Anova using R*. Disponível em: cran.**r**-project.org/doc/contrib/Faraway-PRA.pdf. Acesso em: set. 2010.

Silva, B. F. et al.(2009). Minicurso de Estatística Básica: Introdução ao software R. Programa de Educação Tutorial - Engenharia Elétrica. Universidade Federal de Santa Maria. Santa Maria. Disponível em: http://www.ufsm.br/pet-ee .

Triola, M. F. Introdução à Estatística. Tradução V. R. L. F. Flores. Rio de Janeiro: LTC: 2005.

ANEXO

#dados de um conjunto de 24 tempos de coagulação de sangue.
24 animais foram selecionados aleatoriamente para 4 diferentes dietas e as amostras foram tomadas em uma ordem aleatória (Box, Hunter e Hunter,1978).

	coag	diet
1	62	A
2	60	A
3	63	A
4	59	A
5	63	B
6	67	B
7	71	B
8	64	B
9	65	B
10	66	B
11	68	C
12	66	C
13	71	C
14	67	C
15	68	C
16	68	C
17	56	D
18	62	D
19	60	D
20	61	D
21	63	D
22	64	D
23	63	D
24	59	D